



STROJNO UČENJE

1. predavanje

Uvodno predavanje
(1 sat)

AI Center Lipik
THE FUTURE IS HERE

1.1. Terminologija




Značajke (features)


patient id	height	weight	sex	age	smoker	hr	sys bp	dia bp
007	5'2"	120	M	11	no	75	120	80
2139	5'4"	140	F	41	no	65	115	75
1111	5'11"	185	M	41	no	52	125	75

Ciljana vrijednost (target) i predikcija

- Ciljana vrijednost – vrijednost koju želimo predvidjeti
- Podjela:
 - Klasifikacija
 - Regresija



1.2. Vrste strojnog učenja




Nadzirano učenje - klasifikacija

- Klasifikacija
- Klasifikatori – modeli koji na osnovu ulaznih podataka daju izlaz koji je jedna od malobrojnih klasa ili grupa
- Primjeri ?




Klasifikacija slika



Aktivnosti na burzi



Medicinska dijagnostika



Nadzirano učenje - regresija


- Regresija
- Regresori – modeli koji na osnovu ulaznih podataka daju izlaz koji je numerička vrijednost na kontinuiranoj skali
- Primjeri ?



Uspjeh učenika/studenta



Cijena dionica



Ponašanje korisnika web preglednika



1.3. Evaluacija sustava učenja

- ispravnost
- resursi




Ispravnost



Potrošnja resursa



1.4. Proces izrade sustava učenja



Koraci na visokoj razini:

1. Razviti razumijevanje našeg zadatka (razumijevanje zadatka).
2. Prikupiti i razumjeti naše podatke (prikupljanje podataka).
3. Pripremiti podatke za modeliranje (priprema podataka).
4. Graditi modele odnosa u podacima (modeliranje).
5. Ocijeniti i usporediti jedan ili više modela (evaluacija).
6. Prebacivanje modela u sustav koji se može primijeniti (deployment).



1.5. Pretpostavke i stvarnost učenja

- Temeljna ograničenja strojnog učenja:

- Relevantnost uzoraka
- Količina uzoraka

