



3.1. Uvodni pojmovi

- Binarni klasifikator ?
- {Da, Ne}, {Crveno, Crno} ili {True, False}
- Vrste:
 - a) izravan pristup (k-NN)
 - b) dvostupanjski pristup sa izradom modela (NB)




3.2. Iris Dataset

- Jedan od najpoznatijih skupova podataka, sredina prošlog stoljeća
- Hrvatski naziv je perunika
- Tri vrste/klase:
 - Setosa
 - Versicolor
 - virginica





Iris Dataset

- Značajke:
 - Širina latice (petal)
 - Dužina latice (petal)
 - Širina čašice (sepal)
 - Dužina čašice (sepal)
- Target/ciljna varijabla
 - Klasa (setosa, versicolor ili Virginica)



Google
colab






Naziv klase ?

```
print('targets: {}'.format(iris.target_names), iris.target_names[0])
```

3.3. Fizika, povijest i funkcija `train_test_split`

- Fizika –zakoni, formule, primjeri; testiranje na drugim primjerima
- Povijest – činjenice; testiranje poznavanja činjenica ☹




Nazivi ?

- `iris_train_ftrs`,
- `iris_test_ftrs`,
- `iris_train_tgt`,
- `iris_test_tgt`,
- `iris.data`,
- `iris.target`,

3.4. Evaluacija

- $\text{točnost} = \frac{\text{brojtočnihodgovora}}{\text{brojpitanja}}$






3.5. Klasifikator broj 1 – najbliži susjedi (k-NN)




3.5.1. Što je sličnost ?

- sličnost = udaljenost(primjer_jedan, primjer_dva)



3.5.2. Što je k u k-NN ?




3.5.3. Parametarske i neparametarske metode

- Parametarske metode –
 - Model se opisuje s unaprijed zadanim brojem parametara θ koji ne raste s količinom podataka.
 - Trening se svodi na pronalazak optimalne vrijednosti tih parametara
 - Prije učenja pretpostavimo kako izgleda
 - Nakon učenja model „pamti” samo vektor parametara; sirovi podaci se mogu odbaciti. a funkcija koja povezuje ulaze i izlaze
 - Brza predikcija, mala memorija, često dobra interpretabilnost



3.5.3. Parametarske i neparametarske metode

- Neparametarske metode
 - Model nema unaprijed fiksiran niz parametara; složenost raste ovisno o strukturi podataka.
 - Ne pretpostavljamo eksplicitan funkcijski oblik — model „uči” strukturu iz podataka lokalno ili putem sličnosti.
 - Za predikciju je često potrebno pohraniti (velik dio) trenirnog skupa i neko pravilo pretraživanja
 - Visoka fleksibilnost, mogućnost hvatanja složenih, nelinearnih odnosa bez formuliranja eksplicitnog oblika.
 - Troši više memorija i sporije su predikcije



3.5.4. Izgradnja modela

1. Želimo koristiti 3-NN—tri najbliža susjeda—kao naš model
2. Želimo da taj model nauči odnos između trening značajki irisa i ciljnih vrijednosti
3. Želimo upotrijebiti taj model za predviđanje — na dosad neviđenim testnim primjerima
4. želimo procijeniti kvalitetu tih predviđanja, koristeći točnost

```
from sklearn.model_selection import train_test_split
from sklearn import datasets
iris = datasets.load_iris()

(iris_train_ftrs, iris_test_ftrs, iris_train_tgt,
 iris_test_tgt) = train_test_split(iris.data, iris.target,
 test_size=.25)
print("Oblik polja značajki za treniranje:", iris_train_ftrs.shape)
print("Oblik polja značajki za testiranje:", iris_test_ftrs.shape)
```

Oblik polja značajki za treniranje: (112, 4)
Oblik polja značajki za testiranje: (38, 4)

3 kod 3-NN je hiperparametar!