

3.6. Klasifikator broj 2 – Naivni Bayes

- Apriorna vrijednost - Pretpostavka o parametru prije promatranja podataka
- Izglednost - Vjerojatnost podataka za danu vrijednost parametra
- Vjerojatnost podataka - ukupna vjerojatnost dobivanja podataka
- Aposteriorna vjerojatnost - ažurirana vjerojatnost parametra nakon što smo vidjeli podatke

$$P(\theta|x) = \frac{P(x|\theta) \cdot P(\theta)}{P(x)}$$

$$\text{Aposteriorna vjerojatnost} = \frac{\text{Izglednost} \cdot \text{Apriorna vjerojatnost}}{\text{Vjerojatnost podataka}}$$

Zadatak

Imamo medicinski test za bolest. Znamo:

- U populaciji od 100 ljudi, 1 osoba ima bolest $\Rightarrow$
- $P(\text{bolestan}) = 0.01$
- $P(\text{zdrav}) = 1 - 0.01 = 0.99$
- Test ima:
 - Osjetljivost = $P(\text{pozitivan} | \text{bolestan}) = 0.99$ (znači: 99% bolesnih će test biti pozitivan)
 - Specifičnost = $P(\text{negativan} | \text{zdrav}) = 0.95$ (znači: 95% zdravih će test biti negativan)
 - pa je:
 - $P(\text{pozitivan} | \text{zdrav}) = 1 - 0.95 = 0.05$

Ako je test pozitivan, kolika je stvarna vjerojatnost da osoba ima bolest?
Odnosno: kolika je $P(\text{bolestan} | \text{pozitivan test})$?

$$P(\text{bolestan} | \text{pozitivan}) = \frac{P(\text{pozitivan} | \text{bolestan}) \cdot P(\text{bolestan})}{P(\text{pozitivan})}$$

$$P(\text{bolestan} | \text{pozitivan}) = \frac{P(\text{pozitivan} | \text{bolestan}) \cdot P(\text{bolestan})}{P(\text{pozitivan})}$$

• Brojnik:

$$P(\text{pozitivan} | \text{bolestan}) \cdot P(\text{bolestan}) = 0.99 \cdot 0.01 = \mathbf{0.0099}$$

• Nazivnik:

Vjerojatnost da test bude pozitivan (ukupno), bilo da je osoba bolesna ili zdrava:

$$P(\text{pozitivan}) = P(\text{pozitivan} | \text{bolestan}) \cdot P(\text{bolestan}) + P(\text{pozitivan} | \text{zdrav}) \cdot P(\text{zdrav})$$

$$P(\text{pozitivan}) = (0.99 \cdot 0.01) + (0.05 \cdot 0.99) = 0.0099 + 0.0495 = \mathbf{0.0594}$$

• Konačno:

$$P(\text{bolestan} | \text{pozitivan}) = \frac{0.0099}{0.0594} \approx \mathbf{0.1667} \text{ ili } \mathbf{16.67\%}$$

- Iako test ima 99% osjetljivost i 95% specifičnost, ako osoba ima pozitivan test:
 - I dalje postoji 83% šanse da je zdrava!
 - Jer je bolest rijetka, a lažno pozitivnih ima mnogo više.

Status	Broj ljudi	Pozitivan test	Negativan test
Bolesni (1%)	10	9,9	0,1
Zdravi (99%)	990	49,5	940,5
Ukupno	1000	59,4	940,6

Primjer sa mailovima

Blue envelopes (8 total):

- drugi - 8 - 8/17 = 0,47
- priatelj - 5 - 5/17 = 0,29
- ruok - 3 - 3/17 = 0,18
- novac - 1 - 1/17 = 0,06

Red envelopes (4 total):

- drugi - 2 - 2/7 = 0,29
- priatelj - 1 - 1/7 = 0,14
- ruok - 0 - 0/7 = 0
- novac - 4 - 4/7 = 0,57

Calculations for P(H) and P(S):

$$P(H) = \frac{8}{4+8} = 0,67$$

$$P(S) = \frac{4}{4+8} = 0,33$$

NORMALAN MAIL ?

$$p = P(L) \times p(\text{dragij}/L) \times p(\text{prijatelj}/L)$$

$$= 0,67 \times 0,47 \times 0,79 = 0,09 \quad \boxed{90\%}$$

 dragij
prijatelj

SPAM ?


$$p = P(S) \times p(\text{dragij}/S) \times p(\text{prijatelj}/S)$$

$$= 0,33 \times 0,29 \times 0,14 = 0,01 \quad \boxed{10\%}$$

3.6. Klasifikator broj 2 – Naivni Bayes - COLAB

• ...


Google
colab



3.7.1. Usporedba

- Usporedba točnosti

Google
colab




3.7.2. Korištenje resursa u klasifikaciji

- Zašto se bavimo resursima ?
 - Ekstrapolacija
 - Ograničenja teorijske analize

3.7.2.1. Ekstrapolacija




3.7.2.2. Ograničenja teorijske analize




3.7.2.3. Vrijeme



- `%timeit -r1 -n1`
- `%%timeit -r1 -n1`



3.7.2.4. Memorija

- `!pip install memory_profiler`
- `%load_ext memory_profiler`





3.7.2.5. Lokalni test

- cmd
- C:\Users\kristian
- python --version
- pip install memory_profiler
- pip install scikit-learn
- (Pokrećemo Notepad i pišemo program knn_memtest.py)

```
knn_memtest.py - Blok za pisanje
Datoteka Uređivanje Oblikovanje Prikaz Pomoć
import memory_profiler, sys
from sklearn import (datasets, metrics,
                     model_selection as skms,
                     naive_bayes, neighbors)
@memory_profiler.profile(precision=4)
def knn_memtest(train, train_tgt, test):
    knn = neighbors.KNeighborsClassifier(n_neighbors=3)
    fit = knn.fit(train, train_tgt)
    preds = fit.predict(test)

if __name__ == "__main__":
    iris = datasets.load_iris()
    tts = skms.train_test_split(iris.data,
                                iris.target,
                                test_size=.25)
    (iris_train_ftrs, iris_test_ftrs,
     iris_train_tgt, iris_test_tgt) = tts
    tup = (iris_train_ftrs, iris_train_tgt, iris_test_ftrs)
    knn_memtest(*tup)
```

- (spremamo ga na lokaciju C:\Users\kristian pod imenom knn_memtest.py)
- (pokrećemo ga iz cmd)
- python knn_memtest.py

```
C:\Users\kristian>python knn_memtest.py
Filename: C:\Users\kristian\knn_memtest.py

line #   Mem usage   Increment Occurrences Line Contents
=====
6 135.5742 MiB 135.5742 MiB      1 @memory_profiler.profile(precision=4)
7
8 135.5781 MiB  0.0039 MiB      1 def knn_memtest(train, train_tgt, test):
9 135.8594 MiB  0.2812 MiB      1     knn = neighbors.KNeighborsClassifier(n_neighbors=3)
10 135.9844 MiB  0.1250 MiB      1     fit = knn.fit(train, train_tgt)
11     preds = fit.predict(test)

C:\Users\kristian>
```

