




- Interpretabilnost strojnog učenja odnosi se na sposobnost razumijevanja i objašnjavanja predviđanja i odluka koje donose modeli strojnog učenja.
- Metode: SHAP, LIME i ELIS



- Ove se metode mogu grubo podijeliti u dvije vrste:
 - a) Globalna interpretabilnost, koja objašnjava ponašanje modela u cjelini,
 - b) Lokalna interpretabilnost, koja objašnjava pojedinačna predviđanja

Dataset ?



SHAP (SHapley Additive exPlanations)




Metoda SHAP (SHapley Additive exPlanations)

- SHAP se temelji na Shapley vrijednostima iz teorije kooperativnih igara — svaka značajka se smatra “igračem” koji doprinosi konačnoj “nagradi” (predikciji modela).
- SHAP izračunava koliko se predikcija modela promijeni kada uključimo ili isključimo pojedinu značajku
- Kombiniranjem svih mogućih redoslijeda uključivanja značajki, SHAP osigurava fer dodjelu zasluga (ili “krivnje”) svakoj značajci u odluci modela.
- SHAP može prikazati globalnu važnost značajki (na cijelom datasetu) i lokalno objašnjenje (za pojedini uzorak/predikciju).
- SHAP nudi grafove (bar, summary, force, waterfall) koji pokazuju koliko i u kojem smjeru svaka značajka utječe na konačnu predikciju.

Argumenti i metodi...


- TreeExplainer: koristi se jer RandomForest spada u "tree-based" modele (brz i točan izračun SHAP vrijednosti).
- shap_values: matrica SHAP vrijednosti (za svaku klasu).
- shap.summary_plot(..., plot_type="bar"): prikazuje globalni utjecaj svake značajke — koliko u prosjeku doprinosi promjeni predikcije.



Značajka	Prosječni SHAP utjecaj	Tumačenje
petal length (cm)	najveći	Najvažnija značajka za razlikovanje vrsta irisa.
petal width (cm)	visoki utjecaj	Također važna, posebno za setosu vs. virginicu.
sepal length (cm)	srednji utjecaj	Doprinosi, ali manje.
sepal width (cm)	najmanji utjecaj	Najmanje važna za klasifikaciju.

petal length (cm)	0.199841
petal width (cm)	0.197118
sepal length (cm)	0.035753
sepal width (cm)	0.007791

Pojedinačna vrijednost, red=0, klasa=1 ?



Vrsta modela	SHAP Explainer koji se koristi	Način rada	Prednosti / Napomene
Modeli temeljeni na stablima (Random Forest, XGBoost, LightGBM, CatBoost, DecisionTree, Gradient Boosting...)	TreeExplainer	Koristi analitički izračun SHAP-ovih vrijednosti iz strukture stabla.	Brz i točan; preporučan za sve "tree-based" modele.
Linearni modeli (Linear Regression, Logistic Regression, Ridge, Lasso...)	LinearExplainer	SHAP vrijednosti se računaju izravno iz koeficijenta modela.	Većo precizan i jednostavan; posebno pogodan za male modele.
Neurotske mreže / duboki modeli (Keras, TensorFlow, PyTorch model)	DeepExplainer	Koristi gradient-based aproksimaciju SHAP vrijednosti.	Radi samo na diferencijabilnim modelima; koristi GPU, spor.
Bilo koji model (black-box) (SVM, kNN, ensembles, custom model, rpi, scikit-learn pipeline)	KernelExplainer	Koristi Monte Carlo aproksimaciju (sampling svih kombinacija značajki).	Univerzalan, ali spor (posebno kod mnogo značajki).
Veliki modeli s vektorsima izlaza (OpenAI GPT, embedding model, klasifikatori s mnogo klasa)	PerititExplainer (ili ShapLingExplainer)	Optimizirana verzija KernelExplainer s hijerarhijskim uzorkovanjem.	Koristi se kod kompleksnih modela kad KernelExplainer postane prespor.

Tip modela	Preporučeni explainer
RandomForest, XGBoost, LightGBM	TreeExplainer
LogisticRegression, LinearRegression	LinearExplainer
Keras / PyTorch neuronske mreže	DeepExplainer
SVM, kNN, bilo koji "black-box"	KernelExplainer
Kompleksni modeli s puno značajki / multimodalni	PartitionExplainer

LIME - Local Interpretable Model-agnostic Explanations


- !pip install lime




LIME - Local Interpretable Model-agnostic Explanations

- LIME objašnjava pojedinačnu predikciju tako da analizira lokalno ponašanje modela oko jednog uzorka (instance), a ne cijelog modela.
- Stvara brojne nasumične varijacije izabrane instance i gleda kako se predikcije modela mijenjaju kada se značajke malo promijene.
- LIME pokazuje koje značajke su najviše pridonijele konkretnoj odluci modela (pozitivno ili negativno), čime omogućuje intuitivno i transparentno razumijevanje "zašto" je model donio tu odluku.

Vrlo jednostavno	Namjena	Opis
"classification"	Klasifikacija	Koristi se kad model vraća vjerojatnosti po klasama (npr. predikt_proba). LIME objašnjava zašto je model izabrao određenu klasu.
"regression"	Regresija	Koristi se kad model vraća kontinuiranu vrijednost (npr. predviđa cijenu, temperaturu, visinu...). LIME objašnjava kako svaka značajka doprinosi numeričkom rezultatu.



ELI5 - Explain Like I'm 5



ELI5 - Explain Like I'm 5

- ELI5 je Python biblioteka koja omogućuje da se brzo i jednostavno vidi koje značajke najviše utječu na odluku modela (posebno scikit-learn modele).
- Radi s linearnim modelima, ansamblima (RandomForest, XGBoost) i tekstualnim modelima (npr. CountVectorizer, TfidfVectorizer)
- Pruža funkcije poput:
 - eli5.show_weights(model) → prikazuje važnost značajki
 - eli5.show_prediction(model, sample) → objašnjava pojedinačnu predikciju

Weight	Feature
0.2158 ± 0.0211	petal width (cm)
0.1684 ± 0.1134	petal length (cm)
0 ± 0.0000	sepal width (cm)
0 ± 0.0000	sepal length (cm)

Utjecaj značajki na pojedinačnu odluku

y=setosa (probability 0.000) top features		y=versicolor (probability 0.990) top features		y=virginica (probability 0.010) top features	
Contribution ¹	Feature	Contribution ¹	Feature	Contribution ¹	Feature
+0.337	<BIAS>	+0.343	<BIAS>	+0.320	<BIAS>
-0.004	sepal width (cm)	+0.314	petal length (cm)	+0.026	sepal length (cm)
-0.060	sepal length (cm)	+0.285	petal width (cm)	-0.010	sepal width (cm)
-0.133	petal width (cm)	+0.034	sepal length (cm)	-0.152	petal width (cm)
-0.140	petal length (cm)	+0.014	sepal width (cm)	-0.174	petal length (cm)

Probajmo sa novim datasetom

- Body Performance Data
- U literaturi se koristi za “nacionalni test tjelesne kondicije” u istraživanjima



Značajke

- age → dob sudionika (20 – 64 godina).
- gender → spol („F” ili „M”).
- height_cm → visina u centimetrima.
- weight_kg → težina u kilogramima.
- body fat_% → postotak tjelesne masnoće.
- diastolic → dijastolički krvni tlak (mmHg) – minimalni tlak.
- systolic → sistolički krvni tlak (mmHg) – maksimalni tlak.
- Force → snaga stiska ruke (npr. mjerenje u kg ili N, ovisno o jedinici).
- sit and bend forward_cm → fleksibilnost tijela: koliko se osoba može saviti prema naprijed (cm).
- sit-ups counts → broj trbušnjaka u određenom vremenu (ili standardizirani uvjet) – mjera kondicije.
- broad jump_cm → udaljenost skoka s mjesta (čuđanj-skok) u centimetrima – mjeri eksplozivnu snagu nogu.
- class → ciljna varijabla: razina tjelesne kondicije označena slovima A, B, C, D (gdje „A” predstavlja najbolju razinu).

Redom:

- SHAP
- LIME
- ELI5

