

Obrada slike i računalni vid



Plan za danas

- Kratko ponavljanje do sada naučenih tehnika obrade slike
- Detekcija (proizvoljnih) kontura na slici
 - Teorija
 - 2 praktična zadatka
- Oduzimanje pozadine
 - Samo „teorija”, na idućim vježbama praktični zadaci

Ponavljjanje...

- **Predstavljanje digitalne slike**
- Slika se učitava iz datoteke kao matrica piksela (najčešće u BGR formatu – plavi, zeleni, crveni kanal)
- Često se radi i sa slikom u sivim tonovima (jedan kanal, intenzitet) jer su mnogi algoritmi jednostavniji i brži na sivim slikama.
 - Većina algoritama za rubove, threshold, konture... podrazumijeva da radimo na grayscale ili binarnoj slici, ne na RGB/BGR slici.

Ponavljjanje...

- **Filtriranje i uklanjanje šuma**
- Šum je nasumična varijacija intenziteta piksela (točkice, mrlje) koja često negativno utječu na kasnije korake u algoritmima računalnog vida
- Najčešći filteri koji se koriste za potiskivanje šuma:
 - Gaussian blur – zaglađuje sliku, smanjuje šum, ali malo “razmaže” rubove.
 - Median blur – jako koristan za “salt & pepper” šum, čuva rubove bolje od Gaussiana.
 - Box blur, bilateral filter ...
- Osnovna ideja je: kompromis između uklanjanja šuma i očuvanja detalja.
- Prije detekcije rubova ili primjene metode praga, često se radi blago filtriranje da se stabiliziraju rubovi i ukloni sitni šum.

Ponavljanje...

- **Ujednačavanje histograma**
- Histogram pokazuje kako su intenziteti piksela
- Ako je slika “isprana” ili previše tamna, kontrast je loš → teško je razlikovati objekt od pozadine.
- Ujednačavanje histograma rasteže raspodjelu intenziteta tako da se kontrast poveća.
- Klasično ujednačavanje radi globalno na cijeloj slici.
- CLAHE (adaptivna ujednačavanje) radi lokalno po manjim blokovima, pa bolje radi na neujednačeno osvijetljenim slikama.
- Bolji kontrast = jasniji rubovi i lakša segmentacija

Ponavljjanje...

- **Detekcija rubova (Sobel, Canny i sl.)**
- Rub je mjesto gdje se intenzitet naglo mijenja.
- Sobel operator računa aproksimaciju derivacije u x i y smjeru -> daje gradijent u x (G_x), gradijent u y (G_y), iz njih se može dobiti iznos gradijenta (jačina ruba) i smjer.
- Rubove možemo dobiti primjenom praga na iznos gradijenta.
- Poznati detektor rubova je Canny detektor
- Canny daje relativno čiste, tanke rubove koji su idealni kao ulaz za detekciju linija (Hough) ili kao pomoć kod pronalaska općenitih kontura.

Ponavljjanje...

- **Binarizacija slike metodom praga (amplitudna segmentacija, thresholding)**
- Primjenom metode praga dobivamo binarnu sliku svaki piksel je ili “pozadina” (0) ili “objekt” (255).
- Klasični (globalni) threshold - bira se jedna vrijednost praga T
 - Svi pikseli s intenzitetom $> T$ postaju bijeli (255), ostali crni (0) – ili obrnuto, ovisno o načinu.
 - Problem: ako je slika neujednačeno osvijetljena, jedan globalni prag često nije dovoljno dobar.
- Otsu metoda je način automatskog odabira praga T
 - Pretpostavlja da se histogram može približno podijeliti na dvije klase: pozadina i object
 - Traži vrijednost praga koja maksimalno razdvaja te dvije klase
 - Praktično: ne moramo ručno tražiti “dobar” prag.
- Kad slika ima jake promjene osvjetljenja, globalni ili Otsu prag često nisu dovoljni.
 - Adaptivni threshold računa prag lokalno, po malim blokovima (npr. 11×11 , 15×15):

Ponavljjanje...

- **Geometrijske transformacije**
- Promjena položaja piksela
 - Translacija, Rotacija, Skaliranje...
 - Perspektivna transformacija – omogućuje promjenu perspektive
 - Kada je slika objekta (npr. papir) slikana pod kutem, ravne linije ostaju ravne, ali paralelne linije više ne izgledaju paralelne – to je perspektivna deformacija.
 - Pomoću perspektivne transformacije možemo sliku „izravnati”, kao da ju gledamo odozgor

Ponavljjanje...

- **Morfološko filtriranje**
- Radi se nad binariziranom slikom (piksel je pozadina ili objekt: 0/255).
- Osnovne operacije:
 - Eroziya – “stanjuje” objekte, smanjuje ih. Uklanja male bijele točkice, prekida tanke veze.
 - Dilatacija – “deblja” objekte, povećava bijela područja, zatvara male rupe.
 - Opening = eroziya pa dilatacija
 - Closing = dilatacija pa eroziya.
- Poanta: morfološki filtri se koriste kako bi se očistila binarna slika prije brojanja objekata, pronalaska kontura i sl.

Ponavljjanje...

- **Detekcija linija i krugova – Houghova transformacija**
- S detekcijom rubova (Sobel, Canny) dobiju se pikseli koji pripadaju rubu, ali ne znamo kojoj liniji ili krugu pripadaju.
- Houghova transformacija je metoda koja iz rubova izvlači idealne geometrijske oblike (pravce, krugove).
- Houghova transformacija je dobra kada unaprijed znamo da tražimo prave linije ili krugove, zanima nas više geometrija scene (nagib linije, položaj kruga) nego točna “maska” objekta.

Detekcija kontura na slici

Detekcija kontura na slici...

- **Kontura** je skup piksela koji čine rub nekog objekta na slici, tako da tvore neku krivulju (obično zatvorenu) oko tog objekta.
- Može se dobiti složeniji oblik od pravca odnosno ravne linije
- Konture će nam omogućiti da od binarne slike ili slike koja sadrži rubove dobijemo oblike objekata
 - Npr. rubovi nekakvih predmeta na stolu, proizvoda na proizvodnoj traci i sl.
- Kad imamo konturu, možemo:
 - mjeriti površinu,
 - nalaziti centar,
 - provjeravati oblik (kvadrat, krug, i sl.)
 - uzeti točke konture za perspektivnu transformaciju i sl.

OpenCV detekcija kontura

- Ulaz je binarna slika (npr. na sliku se najprije primijeni detekcija rubova ili samo thresholding)
- OpenCV pruža dvije funkcije:

`cv2.findContours()`

- vraća konture u obliku liste, gdje je svaki element jedna kontura
- kontura je numpy polje koje sadrži pozicije piksela (x,y) koji joj pripadaju

`cv2.drawContours()`

- iscrtava konture na ulaznoj slici


OpenCV detekcija kontura

- Kod funkcije `cv2.findContours()` kontura se interno sprema u obliku svih točaka ruba koji pripadaju konturi (svaka točka ima x, y koordinate)
- Nije uvijek potrebno čuvati svaku točku ruba.
- Konture se mogu aproksimirati tako da se rub opiše:
 - pomoću vodoravnih, okomitih i dijagonalnih segmenata,
 - ili općenito s manjim brojem značajnih točaka (manji memorijskih zahtjevi)
- U OpenCV-u se to kontrolira parametrom metode aproksimacije konture:
 - `CHAIN_APPROX_NONE` čuva sve točke ruba → veći memorijski zahtjevi.
 - `CHAIN_APPROX_SIMPLE` uklanja suvišne točke na ravnim segmentima (npr. između dva kuta čuva samo krajnje točke) → manji memorijski zahtjevi, a oblik ostaje isti za većinu primjena.

OpenCV detekcija kontura

- **Hijerarhija kontura**
- Kod složenijih slika jedan objekt može imati:
 - vanjsku konturu (rub cijelog objekta),
 - jednu ili više unutarnjih kontura (rupe, otvori).
 - Primjer: slovo "O" ima jednu vanjsku i jednu unutarnju konturu; podloška (metalni prsten) isto tako.
- Hijerarhija omogućuje da se zna koja je kontura roditelj (vanjska), koja je dijete (unutarnja), koja je brat/sestra (ista razina)
- To je važno kada treba razlikovati npr. pune objekte od prstenastih (npr. podloške vs. vijci) i sl.
- Kod funkcije `cv2.findContours()` to je `cv2.RETR_EXTERNAL` (samo vanjske), `cv2.RETR_LIST` (sve konture bez hijerarhije), `cv2.RETR_CCOMP` (konture organizirane u dvije razine: vanjske i njihove unutarnje), `cv2.RETR_TREE` (cijelo stalo odnosa među konturama)

OpenCV detekcija kontura



Za svaku konturu i , $hierarchy[0, i]$ je:

`[next, prev, first_child, parent]`

- `next` – indeks sljedeće konture na istoj razini (isto "brat/sestra" u hijerarhiji), ili `-1` ako je nema
- `prev` – indeks prethodne konture na istoj razini, ili `-1`
- `first_child` – indeks prvog djeteta (unutarnja kontura – npr. rupa u objektu), ili `-1`
- `parent` – indeks roditeljske konture, ili `-1` ako je na vrhu (npr. vanjski rub objekta)


OpenCV detekcija kontura

- Primjer upotrebe:


```
contours, hierarchy = cv2.findContours(image=img_th,  
mode=cv2.RETR_TREE, method=cv2.CHAIN_APPROX_NONE)
```

```
cv2.drawContours(image=img, contours=contours,  
contourIdx=-1, color=(0, 0, 255), thickness=1,  
lineType=cv2.LINE_AA)
```


OpenCV detekcija kontura - primjer



Ulazna slika



mode = cv2.RETR_TREE



mode = cv2.RETR_EXTERNAL

Zadatak 1


- Na raspolaganju je slika na kojoj se nalazi više okruglih keksa snimljenih odozgor. Jedan od keksa je vidljivo oštećen.



Zadatak 1

- Napisati program koji:
 - automatski pronađe sve kekse na slici,
 - prepozna koji je keks oštećen,
 - vizualno označi rezultat tako da:
 - svi *cijeli* kekci budu prekriveni zelenim poluprozirnim overlay-em,
 - *oštećeni* keks bude prekriven crvenim poluprozirnim overlay-em,
 - na kraju prikaže konačnu sliku rezultata (original s obojenim kekcima), a po mogućnosti i sažeti prikaz važnih međukoraka obrade (npr. original, binarna slika, konture, rezultat).

Zadatak 1




Zadatak 1

- **Upute (smjernice, ne nužno doslovno ovim redoslijedom, niti se sve mora primijeniti)**
 - pretvoriti sliku u grayscale,
 - ukloniti šum (npr. Gaussian blur),
 - napraviti binarnu sliku (npr. Otsu threshold),
 - primijeniti morfološke operacije (npr. closing) kako bi keksi bili kompaktni objekti,
 - pronaći konture keksa (findContours) i filtrirati samo veće objekte (kekse) prema njihovoj površini,
 - za svaki keks izračunati površinu konture i na temelju toga odrediti koji keks se značajno razlikuje od ostalih (npr. najmanja površina ili najveće odstupanje od medijana površine),
 - nacrtati obojani overlay za svaki keks:
 - cijeli → zeleno,
 - oštećeni → crveno,
 - kombinirati overlay s originalnom slikom (npr. addWeighted) tako da se original još uvijek vidi ispod boje.

Zadatak 2

- Na raspolaganju je slika lista papira s tekstom (A4 format), slikana pod kutem, a u kadru se vidi i dio stola.



Zadatak 2

- Cilj je napisati program koji će:
 - automatski detektirati rub papira na slici,
 - ispraviti perspektivu tako da papir izgleda kao skeniran odozgor,
 - iz ispravljenog papira dobiti čistu crno–bijelu verziju teksta (kao skenirani dokument)
- Na raspolaganju je template (skripta) koji većinu posla već obavlja, vi trebate proučiti postojeći dio i dodati programski kod vezan za konture

Upute za postavljanje kućne Wi-Fi mreže

1. Priprema

Pripremite router, modem (ako ga imate), jedan LAN kabel i podatke od operatera (korisničko ime/lozinka ako trebaju). Isključite modem i router iz struje prije spajanja.

2. Spajanje opreme

1. Modem spojite na utičnicu za internet (telefonska, koaksijalni ili optički kabel).
2. LAN kabel: jedan kraj u **LAN/Ethernet** modema, drugi u **WAN** priključak routera.
3. Uključite modem, pričekajte da se lampice ustabile.
4. Uključite router, pričekajte Wi-Fi lampicu.

3. Pristup routeru

1. Spojite računalo na router (LAN kabel ili zadani Wi-Fi s naljepnice).
2. U preglednik upišite IP adresu routera (npr. 192.168.0.1).
3. Ulogirajte se zadanim podacima (admin/admin ili prema uputama).

4. Internet (WAN) postavke

1. U meniju otvorite **Internet/WAN**.
2. Odaberite tip veze:
 - **DHCP/Dynamic IP** – obično bez dodatnih podataka
 - **PPPoE** – upišite korisničko ime i lozinku operatera
3. Spremite i pričekajte da se upali indikator interneta.

5. Wi-Fi postavke

1. Otvorite **Wireless/Wi-Fi settings**.
2. Postavite **SSID** (naziv mreže), npr. Kuća_WiFi.
3. Zaštita: **WPA2-PSK** ili **WPA3-PSK**.
4. Upišite jaku lozinku (min. 8 znakova).
5. Spremite – Wi-Fi će se kratko restartirati.


**Pokret općenito. Oduzimanje
pozadine i izdvajanje prednjeg
plana.**

Pokret općenito

- Pokret je jedan od aspekata 3D vida kojeg ljudi s lakoćom interpretiraju
- Omogućiti računalima da jednostavno i točno interpretiraju pokret
 - Detektirati objekt
 - Pratiti detektirani objekt i bilježiti njegov položaj
 - Predvidjeti buduću putanju kretanja detektiranog objekta (izbjegavanje kolizije/sudara)
 - ...
- Primjena u autonomnim vozilima
 - Praćenje pokreta detektiranih sudionika prometa (pješak, automobil,...)
 - Predviđanje kretanja ostalih sudionika prometa
 - ...

Pokret općenito

- Scene s pokretnim objektima
 - Analiza scene puno složenija nego za stacionarne scene (varijacije intenziteta, tj. osvjetljenja moraju se uzeti u obzir)
 - Segmentirati pokretne objekte na temelju njihova pokreta
 - Razlika susjednih okvira videa bi to trebala omogućiti – međutim, nije tako jednostavno



- Primjer – objekt se pomiče s lijeva na desno (gornje dvije slike)
- Razlika ta dva okvira (donja slika):
 - (I) područja konstantnog intenziteta ne odaju znakove pokreta
 - (II) rubovi paralelni sa smjerom pokreta ne odaju znakove pokreta

Oduzimanje pozadine i izdvajanje prednjeg plana

- *Background subtraction* - BS
- Često se naziva i detekcija prednjeg plana (engl. *foreground detection*)
 - Od ulazne slike oduzima se pozadina kako bi se dobili pokretni objekti
- BS je jedan od glavnih koraka predobrade u mnogima aplikacijama zasnovanim na računalnom vidu
- **Vrlo korisna tehnika za detekciju pokretnih objekata u videu sa statičnom kamerom**
- Općenito, područja interesa u slici su objekti (ljudi, auti, tekst, ...)

Oduzimanje pozadine i izdvajanje prednjeg plana

- Omogućava odvajanje pozadine od pokretnih objekata, različite primjene
 - Praćenje pješaka i vozila
 - Prebrojavanje posjetitelja u nekom prostoru, vozila na nekoj prometnici,...
 - Prepoznavanje osoba
 - Nadzorni sustavi
- ... u svima njima prvo treba izdvojiti objekt od interesa, tj. tehnički gledano, izdvojiti pokretni objekt u prednjem planu od statične pozadine
- Oduzima je pozadine samo kaže: „ovdje se nešto promijenilo / pomiče“, bez znanja što je točno!

Oduzimanje pozadine i izdvajanje prednjeg plana

- Ako nam je poznata slika pozadine (prostora) bez pokretnih objekata
 - Lako je identificirati pokretne objekte kada se oni pojave
- Kako ?
 - Jednostavno se oduzme nova slika od poznate slike pozadine → dobiju se pokretni objekti
- No je li to baš tako jednostavno?

Oduzimanje pozadine i izdvajanje prednjeg plana

- Većina realnih slučajeva → nepoznata slike pozadine
 - Potrebno ju je identificirati i izdvojiti iz slika koje su na raspolaganju
 - Pozadina se može polako mijenjati (promjene osvjetljenja - sunce, oblaci, noć/dan, drveće koje se njiše, ekran koji treperi, valovi...)
 - Posao je složeniji kada u sceni postoje i sjene pokretnih objekata
 - Budući da se sjene također pomiču, jednostavno oduzimanje označilo bi i sjene kao pokretne objekte tj. kao dio prednjeg plana
- Algoritmi koji uče iz uzastopnih video okvira – sposobni su identificirati masku prednjeg plana (engl. *foreground mask*)
 - Rezultat je obično binarna slika (sa segmentiranom pozadinom i prednjim planom)
 - Označava područja nestacionarnih (pokretnih) objekata na statičnoj pozadini

Oduzimanje pozadine i izdvajanje prednjeg plana


- Većina BS tehnika zasnovane na pikselima polaze od istih pretpostavki
 - Video sekvenca / sastoji se od statične pozadine B , ispred koje se nalaze pokretni objekti
 - Svaki pokretni objekt je boje (ili raspodjele boje) različite od one u pozadini (B)
- Razlika između pojedinih modela → kako je modelirana B i koja mjera udaljenosti (prag) se koristi pri odluci je li nešto dio pozadine ili prednjeg plana

Oduzimanje pozadine i izdvajanje prednjeg plana

- Zadatak nije uvijek jednostavan – razni izazovi
 - Loša kvaliteta ulaznog videa (prisutnost šuma, vidljivi artefakti kompresije,...)
 - Promjena osvjetljenja
 - Nestacionarni pozadinski objekti (valovi, lišće koje pada, kiša, snijeg, ...)
 - *Camouflage effect* – pomični objekt je boje slične onima u pozadini
 - Rad u stvarnom vremenu
 - ...


Oduzimanje pozadine i izdvajanje prednjeg plana

Dijagram toka općenitog BS algoritma




Oduzimanje pozadine i izdvajanje prednjeg plana

- BS algoritam računa masku prednjeg plana oduzimajući model pozadine (background - B , koji mu je poznat u tom trenutku) od trenutnog okvira




Oduzimanje pozadine i izdvajanje prednjeg plana



- **Pred-procesiranje**

- Niz zadataka obrade slike koji mijenjaju ulazni video u format koji se može uspješno procesirati sljedećim koracima


Oduzimanje pozadine i izdvajanje prednjeg plana



- **Modeliranje pozadine**

- Koristi novi video okvir da proračuna i ažurira model pozadine
- Ovaj model daje statistički opis cijele pozadine scene


Oduzimanje pozadine i izdvajanje prednjeg plana



- **Detekcija prednjeg plana**

- Identificira piksele u okviru koji nisu na odgovarajući način svrstani u modelu pozadine
- Izlaz je maska prednjeg plana – binarna maska (pikseli s „1“ su potencijalno pokretni objekti / dijelovi pokretnog objekta)

Oduzimanje pozadine i izdvajanje prednjeg plana




- **Post-procesiranje**

- Validacija maske prednjeg plana
- Eliminacija piksela koji ne pripadaju stvarnom pokretnom objektu
- Izlaz je konačna maska prednjeg plana

Oduzimanje pozadine i izdvajanje prednjeg plana

Pred-procesiranje


- Jednostavno vremensko i/ili prostorno izgladivanje
 - Npr. za uklanjanje šuma same okoline (npr. kiša i snijega u pozadini)
- Smanjene prostorne i vremenske rezolucije videa
 - Za brži rad u stvarno-vremenskim aplikacijama
- Registracija slika (engl. *image registration*) između uzastopnih okvira - ukoliko se kamera pomiče
- Oblikovanje podataka
 - Slika u razinama sive ili u boji
 - Format boja (RGB, HSV,...)
 - ...
- ... Međutim, neke od tih tehnika povećavaju složenost algoritma za rad u stvarnom vremenu



Oduzimanje pozadine i izdvajanje prednjeg plana

Modeliranje pozadine

- „Srce“ svakog algoritma oduzimanja pozadine
- Razviti model pozadine koji je
 - Robustan na promjene u samoj okolini (npr. kiša, snijeg, lišće...)
 - Dovoljno osjetljiv da identificira sve pokretne objekte od interesa
- Najjednostavnije – jedna prosječna slika $B(x,y)$
- Tehnike modeliranje pozadine klasificiraju se često u dvije kategorije
 - Ne-rekurzivne
 - Rekurzivne



Oduzimanje pozadine i izdvajanje prednjeg plana

Modeliranje pozadine - NE-REKURZIVNE tehnike


- Koriste pristup klizajućeg prozora (engl. *sliding window*) za procjenu pozadine
- U spremnik (*buffer*) pohranjuju prethodnih L okvira videa
 - Procjenjuju sliku pozadine na osnovu vremenske varijacije svakog piksela unutar spremnika
- Ne ovise o povijesti prije okvira koji su u spremniku
- Potreban veliki spremnik kako bi se uspješno nosile sa sporo pokretnim objektima
- Ako je spremnik nužno fiksne veličine
 - Problem se djelomično rješava spremanjem okvira s nižim *frame rate*-om (manje okvira u određenom vremenskom intervalu)

Oduzimanje pozadine i izdvajanje prednjeg plana

Modeliranje pozadine - NE-REKURZIVNE tehnike

Razlika okvira

- Najjednostavnija metoda modeliranja pozadine
- Okvir videa u trenutku $t-1$ koristi se kao model pozadine za okvir u trenutku t
- Koristi samo jedan prethodni okvir ($L = 1$) → ne može identificirati unutarnje piksele slike velikog, uniformno-obojanog pokretnog objekta
 - Poznato kao problem otvora (aperture problem) – objašnjen u drugom dijelu predavanja



Oduzimanje pozadine i izdvajanje prednjeg plana

Modeliranje pozadine - NE-REKURZIVNE tehnike

Medijan filtriranje

- Jedna od najčešće korištenih tehnika modeliranja pozadine
- Procjena pozadine je definirana kao medijan na svakoj lokaciji piksela svih L okvira koji su u spremniku
- Pretpostavka je da piksel stoji u pozadini u više od polovice okvira u spremniku

Oduzimanje pozadine i izdvajanje prednjeg plana

Modeliranje pozadine - NE-REKURZIVNE tehnike

Ne-parametarski (*non-parametric*) model

- Nešto složeniji model
 - Nećemo se baviti detaljima kako radi...
 - Fokusirat ćemo se na primjenu
- Rješava probleme poput
 - Ljuljanja stabla
 - Padanja lišća
 - ...

Oduzimanje pozadine i izdvajanje prednjeg plana

Modeliranje pozadine - REKURZIVNE tehnike

- Ne koriste spremnik (*buffer*) za procjenu pozadine
- Rekursivno ažuriraju model pozadine na osnovu ulaznog okvira
- Kao rezultat toga, ulazni okviri iz daleke prošlosti mogu imati utjecaj na trenutni model pozadine
- Nasuprot ne-rekursivnim tehnikama
 - Trebaju manje prostora za pohranu
 - Bilo kakva pogreška u modeliranju pozadine može potrajati puno dulje
- Većina shema uključuju eksponencijalne težinske faktore kako bi se umanjivao utjecaj dalje prošlosti

Oduzimanje pozadine i izdvajanje prednjeg plana

Modeliranje pozadine - REKURZIVNE tehnike

Aproksimirani medijan filter

- Motiviran uspjehom ne-rekurzivne metode medijan filtriranja
- Koristi se jednostavni rekurzivni filter kako bi se procijenio median – često se koristi baš u nadzoru prometa u gradovima

Oduzimanje pozadine i izdvajanje prednjeg plana

Modeliranje pozadine - REKURZIVNE tehnike

Mixture of Gaussian (MoG) modeli

- Naprednija tehnika, računalno zahtjevnija
- Parametarski model – parametri modela se adaptivno ažuriraju bez potrebe za velikim spremnikom
- Nekoliko različitih modela predloženo
- Najbolji od dosad nabrojanih
 - Računalno vrlo zahtjevan i zahtjeva pažljivo podešavanje parametara
 - Vrlo osjetljiv na iznenadne promjene globalnog osvjetljenja (npr. scena je dugo stacionarna → varijacija pozadine je dosta mala → promijeni se globalno osvjetljenje → cijeli okvir se detektira kao prednji plan)
- Noviji modeli se bolje prilagođavaju promjenama osvjetljenja i detekciji sjena
- Implementirani u OpenCV-u !!!

Oduzimanje pozadine i izdvajanje prednjeg plana

Modeliranje pozadine - REKURZIVNE tehnike

Mixture of Gaussian 2 (MoG2) algoritam

- Uveden 2004. godine
 - Članci:
 - „Improved adaptive Gaussian mixture model for background subtraction” (2004)
 - „Efficient Adaptive Density Estimation per Image Pixel for the Task of Background Subtraction” (2006)
- Bolja prilagodljivost na promjenjive scene zbog promjene osvjetljenja
- Opcija – može se odabrati da li detektirati sjene ili ne ?
 - *detectShadows* = True → detektira i označava sjene (sivom bojom), ali radi sporije

Oduzimanje pozadine i izdvajanje prednjeg plana

Modeliranje pozadine - REKURZIVNE tehnike

Usporedba MoG i MoG2



MoG




MoG2

Oduzimanje pozadine i izdvajanje prednjeg plana

Detekcija prednjeg plana

- Uspoređuje se ulazni video okvir s modelom pozadine
- Identificiraju se pikseli prednjeg plana u ulaznom okviru
- **Pristup 1** - najčešće korišten pristup za detekciju prednjeg plana - je li ulazni piksel znatno različit od odgovarajućeg piksela u trenutnoj slici pozadine ?



$$|I_t(x, y) - B_t(x, y)| > T$$


Oduzimanje pozadine i izdvajanje prednjeg plana

Detekcija prednjeg plana

- **Pristup 2** - korištenje praga na osnovu normalizirane statistike

$$\frac{|I_t(x, y) - B_t(x, y) - \mu_d|}{\sigma_d} > T_s$$

- ...gdje su μ^d i σ^d srednja vrijednost i standardna devijacija od $(I_t(x,y)-B_t(x,y))$ za sve prostorne lokacija (x,y)
- T i T_s iz prethodnih izraza utvrđuju se eksperimentalno
- U idealnom slučaju, prag bi trebao biti funkcija prostorne lokacije (x,y) – npr. niži prag za područja s manjim kontrastom



Oduzimanje pozadine i izdvajanje prednjeg plana

Detekcija prednjeg plana

- **Pristup 3** - modifikacija prethodnog pristupa – korištenje relativne razlike umjesto apsolutne razlike, kako bi se naglasio kontrast u tamnijim (mračnijim) područjima (kao što su sjene)

$$\frac{|I_t(x, y) - B_t(x, y)|}{B_t(x, y)} > T_c$$

- Mana ovog pristupa → ova tehnika se ne može koristiti da se naglasi kontrast u svijetlim slikama kao što su vanjske scene, npr. po jakoj magli


Oduzimanje pozadine i izdvajanje prednjeg plana

Detekcija prednjeg plana

- **Pristup 4** - korištenje dva različita praga s histerezom
- Ideja
 - prvo identificirati „sigurne” piksele prednjeg plana čija apsolutna razlika u odnosu na pozadinu premašuje zadani **VISOKI** prag
 - područja prednjeg plana nakon toga se povećavaju, krenuvši od tih piksela, uključujući susjedne piksele čija je apsolutna razlika u odnosu na pozadinu veća od zadanog **NIŽEG** praga
- **Zaključak** – primjena pojedinog pristupa ovisi o samoj sceni/slici – potrebno poznavati materiju

Oduzimanje pozadine i izdvajanje prednjeg plana


Post-procesiranje



- Vrednovanje podataka dobivenih procesom detekcije prednjeg plana
- Proces poboljšavanja dobivene maske prednjeg plana na osnovu informacija dobivenih sa strane („izvana”) u odnosu na model pozadine
- Zašto je potrebno raditi ovo ???
- Svi spomenuti modeli pozadine imaju tri ograničenja
 - ignoriraju sličnost između susjednih piksela (ne „razmišljaju” o samom sadržaju slike niti o činjenici da su susjedni pikseli vjerojatno/najčešće dio istog objekta ili iste pozadine)
 - brzina prilagodbe ne mora odgovarati brzini pokreta objekata u prednjem planu
 - ne-stacionarni pikseli od pokretnog lišća ili sjena pokretnih objekata se često označavaju kao pravi pokretni objekti

Oduzimanje pozadine i izdvajanje prednjeg plana

Post-procesiranje




- Problem brzine prilagodbe modela brzini pokreta objekata u prednjem planu
 - model pozadine se presporo prilagođava u odnosu na brzinu objekata prednjeg plana
 - rezultat → velika područja lažnog prednjeg plana (poznato kao „duhovi”)
 - model pozadine se prebrzo prilagođava u odnosu na brzinu objekata prednjeg plana
 - rezultat → ne identificira se određeni dio objekta prednjeg plana
- moguća rješenja
 - korištenje višestrukih modela pozadine koji se odrađuju uz različite brzine prilagodbe i periodičko vrednovanje različitih modela
 - naprednije tehnike - računanje optičkog toka (*optical flow*) – eliminira „duhove”
 - segmentacija po boji (filtriranje) – objekt bi trebao imati sličnu boju duž cijelog objekta

Oduzimanje pozadine i izdvajanje prednjeg plana


Post-procesiranje

- Problem ne-stacionarnih piksela od pokretnog lišća ili sjena pokretnih objekata
 - pokretno lišće - rješava se korištenjem sofisticiranijih modela pozadine (npr. MoG) i morfološkog filtriranja za „pročišćavanje”
 - problem pokretnih sjena – problematičnija stvar, posebno za video u skali sivog
 - rješava se naprednijim tehnikama



Oduzimanje pozadine i izdvajanje prednjeg plana

- Općeniti video primjeri na web-u
 - <https://www.youtube.com/watch?v=oAuWKQv6B3k>
 - <http://vip.bu.edu/projects/vsns/background-subtraction/fa/>



Oduzimanje pozadine i izdvajanje prednjeg plana

Oduzimanje pozadine (Python & OpenCV)

- Implementirana 3 različita BS algoritma u OpenCV-u
 - *BackgroundSubtractorMOG*
 - *BackgroundSubtractorMOG2* (bolja prilagodba na promjene osvjetljenja i na detekciju sjene)
 - *Geometric Multigrid*



Oduzimanje pozadine i izdvajanje prednjeg plana

Primjer 2 (Python & OpenCV) - *MoG Background/Foreground segmentation algorithm*

```
# OpenCV 2.4.13 only
import numpy as np
import cv2

cap = cv2.VideoCapture('walking.avi')

# Initlaize background subtractor
foreground_background = cv2.BackgroundSubtractorMOG()

while True:

    ret, frame = cap.read()

    # Apply background subtractor to get our foreground mask
    foreground_mask = foreground_background.apply(frame)

    cv2.imshow('Output', foreground_mask)
    if cv2.waitKey(1) == 13:
        break

cap.release()
cv2.destroyAllWindows()
```

- pozadina uspješno uklonjena
- ostali pokretni objekti

Oduzimanje pozadine i izdvajanje prednjeg plana

Primjer 3 (Python & OpenCV) - *MoG Background/Foreground segmentation algorithm + web kamera*

```
# OpenCV 2.4.13 only
import numpy as np
import cv2

# Intialize Webcam
cap = cv2.VideoCapture(0)

# Initlaize background subtractor
foreground_background = cv2.BackgroundSubtractorMOG()

while True:

    ret, frame = cap.read()

    # Apply background subtractor to get our foreground mask
    foreground_mask = foreground_background.apply(frame)

    cv2.imshow('Output', foreground_mask)
    if cv2.waitKey(1) == 13:
        break

cap.release()
cv2.destroyAllWindows()
```

- Razlika samo u načinu učitavanja videa

Oduzimanje pozadine i izdvajanje prednjeg plana

Primjer 4 (Python & OpenCV) - *MoG2 Background/Foreground segmentation algorithm*

```
# OpenCV 2.4.13
import numpy as np
import cv2

cap = cv2.VideoCapture('walking.avi')

# Initlaize background subtractor
foreground_background = cv2.BackgroundSubtractorMOG2()

while True:
    ret, frame = cap.read()

    # Apply background subtractor to get our foreground mask
    foreground_mask = foreground_background.apply(frame)

    cv2.imshow('Output', foreground_mask)
    if cv2.waitKey(1) == 13:
        break

cap.release()
cv2.destroyAllWindows()
```

- Nije tako učinkovita po pitanju kretanja/nekretanja pozadine (vidimo lagane pomake u pozadini)
- Vidimo detekciju sjena koja je ovdje prilično uspješna

Oduzimanje pozadine i izdvajanje prednjeg plana

Primjer 5 (Python & OpenCV) - *MoG2 Background/Foreground segmentation algorithm + web kamera*

```
# OpenCV 2.4.13
import numpy as np
import cv2

# Intialize Webcam
cap = cv2.VideoCapture(0)

# Initlaize background subtractor
foreground_background = cv2.BackgroundSubtractorMOG2()

while True:
    ret, frame = cap.read()

    # Apply background subtractor to get our foreground mask
    foreground_mask = foreground_background.apply(frame)

    cv2.imshow('Output', foreground_mask)
    if cv2.waitKey(1) == 13:
        break

cap.release()
cv2.destroyAllWindows()
```

- Razlika samo u načinu učitavanja videa

Oduzimanje pozadine i izdvajanje prednjeg plana

Primjer 5 (Python & OpenCV) - *Foreground subtraction*

- Oduzimanje prednjeg plana
- Želimo da ostane samo statična pozadina
- Npr. nadzor prometa
- Ukloniti
 - Pješake
 - Automobile
 - Ostale pokretne objekte
- **Pogodno za kodiranje**
 - **Izdvojena pozadina**

```
import cv2
import numpy as np

# Initialize webcam and store first frame
cap = cv2.VideoCapture(0)
ret, frame = cap.read()

# Create a float numpy array with frame values
average = np.float32(frame)

while True:
    # Get webcam frame
    ret, frame = cap.read()

    # 0.01 is the weight of image, play around to see how it changes
    cv2.accumulateWeighted(frame, average, 0.01)

    # Scales, calculates absolute values, and converts the result to 8-bit
    background = cv2.convertScaleAbs(average)

    cv2.imshow('Input', frame)
    cv2.imshow('Disapearing Background', background)

    if cv2.waitKey(1) == 13: #13 is the Enter Key
        break

cv2.destroyAllWindows()
cap.release()
```


Oduzimanje pozadine i izdvajanje prednjeg plana

Korisna literatura

- Y. Benezeth, P-M. Jodoin, B. Emile, H. Laurent, C. Rosenberger, „Comparative study of background subtraction algorithms”, Journal of Electronic Imaging, SPIE and IST, 2012, vol. 19
- S-C. S. Cheung, C. Kamath, „Robust techniques for background subtraction in urban traffic video”, 2004.
- A. Kunštek, „Algoritmi za prepoznavanje pokreta i primjena na automatsko praćenje objekata”, Diplomski rad, Sveučilište u Zagrebu, Prirodoslovno–matematički fakultet, 2016.
- OpenCV: Background Subtraction,
https://docs.opencv.org/3.3.0/db/d5c/tutorial_py_bg_subtraction.html