

Popis projektnih zadataka za modul Računalni vid

Uvod

U nastavku je definirano 13 projektnih zadataka. Iza svakog zadatka stoji ime osobe koja radi određeni zadatak.

Neke zadatke rade dvije različite osobe, što ne znači da ga rade zajedno. Rade ga odvojeno jer želimo vidjeti dva različita rješenja (pristupa problemu). Izlaganje rješenja projektnih zadataka održat će se u Lipiku uživo u subotu 17.01.2026. godine, a točan termin bit će javljen na vrijeme

Popis projektnih zadataka

1. Izraditi aplikaciju za analizu gustoće prometa pješaka. Snimiti 10 video signala pješačke zone iz statične pozicije. Koristeći metode detekcije pokreta i segmentacije, pratiti količinu kretanja u kadru i određivati razinu gustoće prometa. Implementirati vizualizaciju "toplinske mape" koja pokazuje najfrekventnije rute kretanja kroz kadar. **(Ivan Bašić)**
2. Izraditi aplikaciju za detekciju i brojanje novčića različitih apoena na slici. Snimiti 10 video signala gdje se na ravnoj površini nalaze različiti novčići (kovanice). Koristeći metode detekcije kružnica (npr. Hough transformaciju) i analizu boja/veličina, prepoznati različite apoene te izračunati ukupan iznos novca na slici. Aplikacija treba raditi u realnom vremenu i biti otporna na različite uvjete osvjetljenja. **(Glorija Bertelović)**
3. Izraditi aplikaciju za mjerenje dimenzija predmeta pravokutnog oblika. Snimiti 10 video signala gdje se uz predmet nalazi referentni objekt poznate veličine (npr. kreditna kartica). Koristeći metode detekcije rubova i geometrijske transformacije, izračunati stvarne dimenzije predmeta na temelju poznate reference. Rezultate prikazati u realnom vremenu na video prikazu. **(Haris Hadžagić)**
4. Izraditi aplikaciju za detekciju i praćenje određene boje u video signalu. Snimiti 10 video signala gdje se pojavljuju objekti zadane boje u pokretu. Implementirati praćenje objekta korištenjem HSV prostora boja i morfoloških operacija. Iscrtati putanju kretanja objekta i izračunati njegovu prosječnu brzinu kretanja kroz kadar. **(Marko Hiki)**
5. Izraditi aplikaciju za detekciju i analizu prometnih znakova prema obliku. Snimiti 10 video signala prometnih znakova. Koristeći detekciju specifičnih geometrijskih oblika (trokut, krug, pravokutnik) i analizu boja, identificirati osnovne vrste prometnih znakova. Implementirati praćenje znaka kroz video sekvencu i prikaz udaljenosti od kamere na temelju promjene veličine znaka. Ne implementirati prepoznavanje specifičnih znakova, već samo njihovu kategorizaciju prema obliku. **(Bruno Horvat) (Davorin Špičko)**
6. Izraditi aplikaciju za analizu popunjenosti parkirališta. Snimiti 10 video signala parkirališta iz ptičje perspektive. Koristeći segmentaciju slike i analizu zauzetosti označenih parkirnih mjesta, odrediti broj slobodnih i zauzetih mjesta. Implementirati prikaz postotka popunjenosti i označavanje slobodnih mjesta na slici. Rješenje treba biti robusno na različite uvjete osvjetljenja tijekom dana. **(Dejan Ilić) (Mislav Zlomislić)**

7. Izraditi aplikaciju koja će stvarati panoramski prikaz minimlano triju fotografija. Potrebno je kreirati pripadne skupove fotografija zakrećući kameru mobilnog telefona s jedne strane u drugu. U konačnici, na konačnoj slici treba biti panoramski prikaz koji će obuhvaćati prostor koji prikazuje sve od najlijevijeg dijela lijeve fotografije do najdesnijeg dijela desne fotografije. **(Monika Ivanović)**
8. Izraditi aplikaciju za transformaciju pogleda objekta u top-view perspektivu. Snimiti 10 slikovnih skupova u kojima se za svaki objekt nalaze fotografije snimljene s prednje, stražnje, lijeve i desne strane. Korištenjem perspektivnih transformacija i geometrijskih operacija potrebno je rekonstruirati prikaz objekta iz pogleda odozgo te ga prikazati kao jedinstvenu sliku. Potrebno je osigurati korektno poravnanje rubova objekta te vizualno prikazati rezultat transformacije za svaki skup slika. **(Marko Karešin)**
9. Izraditi aplikaciju za detekciju i klasifikaciju objekata na simuliranoj industrijskoj traci. Snimiti 10 video signala trake iz gornje perspektive na kojima se pojavljuju pravokutni, kružni i neispravni (deformirani) objekti. Koristeći segmentaciju slike i analizu kontura, potrebno je prepoznati oblik svakog objekta te ih klasificirati u kategorije pravokutnih, kružnih i neispravnih. Implementirati označavanje detektiranih objekata na slici s pripadajućom klasom i rednim brojem te izračunati ukupan broj objekata u svakoj kategoriji. **(Marinko Klarić) (Helena Papak)**
10. Izraditi aplikaciju za procjenu udaljenosti poznatog pravokutnog objekta u videu. Snimiti 10 video signala u kojima se pojavljuje pravokutni predmet poznatih fizičkih dimenzija. Potrebno je detektirati taj objekt u svakom okviru videa te na temelju njegove veličine u slici procijeniti udaljenost od kamere. Izračunata udaljenost mora se prikazivati u stvarnom vremenu na videu tijekom obrade. **(Mirta Lasić)**
11. Izradite aplikaciju koja u video snimci biljara detektira i prati kugle te ih preslikava u ptičju perspektivu. Nakon što dobijete pozicije kugli u novom prikazu, za svaki frame izračunajte udaljenost bijele kugle do svih ostalih kugli i označite koja je trenutno najbliža. Prikažite udaljenosti kao overlay, npr. top 3 najbliže (npr. Najbliže bijeloj: Crvena 12.4 cm, Plava 18.1 cm, Žuta 24.7 cm.) **(Zdravko Matičević) (Ana Pajalić)**
12. Izradite aplikaciju koja provodi seam carving (content-aware resizing) nad slikama kako bi se slika mogla smanjiti ili povećati po širini i/ili visini uklanjanjem/dodavanjem "seamova" minimalne energije. Potrebno je implementirati izračun energetske mape (npr. Sobel) te pronalazak minimalnog "seama" dinamičkim programiranjem i iterativno mijenjati dimenzije do zadane ciljne rezolucije. Aplikacija mora omogućiti export videa procesa, tj. generirati video u kojem se vidi postupno uklanjanje/dodavanje seamova (frameovi međukoraka), uz overlay koji prikazuje trenutnu dimenziju i broj uklonjenih seamova. Testirajte rješenje na najmanje 20 vlastitih fotografija i priložite usporedbu s klasičnim skaliranjem (resize). **(Saša Nikolaus) (Mario Paravac)**
13. Izradite aplikaciju za brojanje osoba koje prelaze virtualnu liniju u video snimci iz stacionarne kamere. Koristite oduzimanje pozadine i morfološke operacije za izdvajanje pokretnih objekata te pronađite njihove centre (centroid) i pratite ih kroz vrijeme. Kada centroid osobe prijeđe zadanu liniju, povećajte brojač i odredite smjer prelaska (ulaz/izlaz). Rezultat prikažite kao overlay na videu (trenutni brojači) i spremite izlazni video. **(Kristina Nikolić) (Josip Smoljić)**