

Uvod u strojno učenje



Sadržaj


- Umjetna inteligencija, strojno učenje i duboko učenje
- Motivacija i primjeri
- Vrste strojnog učenja
- Notacije i konvencije
- Mapa za izgradnju sustava strojnog učenja
- Alati i biblioteke za strojno učenje
- Primjeri skupova podataka

Umjetna inteligencija (UI) – Artificial Intelligence (AI),

Strojno učenje (SU) – Machine Learning (ML)


Duboko učenje (DU) – Deep learning (DL)

Umjetna inteligencija, strojno učenje, duboko učenje



- **Strojno učenje** (engl. *machine learning*) je praksa korištenja algoritama da parsiraju (raščlane, analiziraju) podatke, uče iz njih, i onda odluče o nečemu ili predvide nešto
 - Stroj se trenira koristeći **velike količine podataka** i algoritme koji mu daju sposobnost da uči kako provesti zadatak
 - Ima širok skup različitih algoritamskih pristupa, arhitektura i rješenja za različite probleme


Umjetna inteligencija, strojno učenje, duboko učenje



- **Duboko učenje** (engl. *deep learning*) je jedan od oblika strojnog učenja
 - Inspirirano je strukturom ljudskog mozga koju pokušava implementirati višeslojnim umjetnim neuronskim mrežama
 - Koristi također **velike količine podataka**
 - Za razliku od strojnog učenja, duboko učenje je dosta uniformno i prilično jednostavno po pitanju arhitekture (kod različitih primjena)
 - Prepoznavanje objekata na fotografiji
 - Generiranje prijevoda iz jednog jezika u drugi
 - Opis riječima slike koja se pojavi
 - Autonomna vožnja
 - ...

Računalni algoritmi

- Kako bi se riješio problem na računalu, potrebno je imati odgovarajući algoritam
- Algoritam je niz instrukcija koji se treba izvesti kako bi se neki ulaz transformirao u odgovarajući izlaz
- **Primjer:** algoritam za sortiranje podataka
- Međutim za mnoge probleme ne postoji odgovarajući algoritam za rješavanje



Što je strojno učenje?

- Strojno učenje (SU) je područje računalne znanosti koje je nastalo iz raspoznavanja uzoraka i računalne teorije učenja u području umjetne inteligencije (engl. *Artificial Intelligence* - AI)
- SU jest programiranje računala na način da optimiziraju neki kriterij uspješnosti temeljem podatkovnih primjera ili prethodnog iskustva
- Neka imamo iskustvo E , zadatak T i mjeru performansi P
 - Učiti znači zadatak T obavljati sve uspješnije s obzirom na mjeru performansi P kako se iskustvo E povećava

Što je strojno učenje?

- Ovi algoritmi izgrađuju model iz primjera, kako bi se mogla provoditi predviđanja ili odluke na temelju podataka, bez da se striktno izvode statičke programske instrukcije
- U novije vrijeme SU se koristi u različitim primjenama gdje dizajn i programiranje eksplicitnih algoritama nisu mogući
- Područje SU je jedno od najbrže rastućih polja računalne znanosti
- Raspoznavanje uzoraka upravo koristi algoritme SU

Spam filter kao primjer strojnog učenja

- Primjer: e-mail klijent, prikaz dobivene pošte, sortiranje na ulazne i poslane poruke
 - Za ove zadatke postoji jasno definiran algoritam
- Međutim za izgradnju spam filtra ne postoji odgovarajući algoritam
 - Ulaz: e-mail je niz karaktera
 - Izlaz: da ili ne (e-mail je spam ili nije spam)
 - Ne znamo kako transformirati ulaz u izlaz
 - Spam se mijenja tijekom vremena i ovisi o pojedincu
- Budući da nemamo dovoljno znanja za osmišljavanje algoritma za dani problem, znanje tražimo u dostupnim podacima
- Npr. iz velikog broja podataka za koje znamo jesu li spam ili ne, moguće je pomoću računala automatski izlučiti algoritam za ovaj problem

Spam filter kao primjer strojnog učenja

- Ovo se često naziva i postupak učenja; iz podataka se želi naučiti što je spam (nekakve skrivene značajke spama)
- Dani problem se ne može u potpunosti naučiti (identificirati), ali se često može postići dobra i zadovoljavajuća aproksimacija
- Točnije, nije moguće u potpunosti identificirati proces, ali se mogu detektirati određene pravilnosti
- [Google says its machine learning tech now blocks 99.9% of Gmail spam and phishing messages](#)

P i t a n j a ?

Motivacija i primjeri

Strojno učenje - zašto baš sada?

- Dostupne su velike količine pohranjenih podataka; pri tome se spremaju svakojaki podaci (tekstualni, grafički, zvučni, videozapisi i sl.)
- Računalna obrada postaje sve moćnija i jeftinija
- Pohrana podataka je sve jeftinija
- Sve veća mrežna povezivost
- Kako izvući korisnu informaciju iz tih podataka?
 - Potrebni su algoritmi koji mogu izgraditi modele na temelju kojih će se analizirati veliki i kompleksni skupovi podataka te su u stanju brzo donositi točne predikcije odgovarajućih veličina
 - Na temelju ovih predikcija moguće je donositi bolje odluke i pametnije akcije u realnom vremenu bez ljudske intervencije

Podatkovna revolucija

- Svake godine skupovi podataka (engl. *datasets*) su sve veći
- Ne samo da se povećava broj mjerenja, već se značajno povećava i broj atributa
- Podaci više nisu samo brojevi i znakovni nizovi već uključuju slike, zvučne zapise, grafove i sl.
- Svaki puta kada kupimo neki artikl online, posudimo film, posjetimo web stranicu, društvenu mrežu, *tweetamo*, ...
→ zapravo generiramo podatke
- Senzori u pametnim telefonima, kućama i sl.
- *Big data* i internet objekata (IoT) su jedan od glavnih razloga sve veće popularnosti SU



Podatkovna revolucija

- *Big data* je popularni izraz za opisivanje eksponencijalnog rasta podataka i dostupnosti podataka
- *Big data* postaje jednako važan za poslovanje i za društvo
- Više podataka može doprinijeti točnijim analizama i pouzdanijim procjenama prilikom poslovanja



Primjene strojnog učenja, dubinska analiza podataka

- Jedna od važnih primjena SU je dubinska analiza podataka (engl. data mining)
- To je primjena SU na velika baze podataka kako bi se iz ogromne količine podataka ekstrahirale važne informacije
- Banke analiziraju svoje transakcije i povijesne podatka za izgradnju različitih modela: kreditne aplikacije, aplikacije za detekciju prevara, aplikacije za analizu i predikciju tržišta dionica,...
- Facebook koristi SU u detekciji spama, sortiranju *newsfeeda* za pojedinog korisnika, odabiru oglasa koji će se prikazivati pojedinom korisniku,...
- Google search predikcija unosa; rangiranje stranica prilikom pretraživanja,...


Primjene strojnog učenja, dubinska analiza podataka

- U medicini se modeli koriste za medicinske dijagnoze, predikciju vremena čekanja u prostorijama prve pomoći,...
- U telekomunikacijama pokušavaju se prepoznati određene pravilnosti kako bi se optimizirala mreža i kvaliteta usluge (engl. QoS)
- U znanosti analiziraju se velike količine podataka (fizika, astronomija, biologija, genetika,...)
- U industriji za predviđanje kada će doći do ispada uređaja
- ...

Primjene strojnog učenja u obradi zvuka i govora

- Prepoznavanje/razumijevanje govora
 - Ne govore svi ljudi jednako (različit naglasak, dubina glasa, razumljivost, itd.)
 - Google Now, Siri, Cortana – „osobni asistenti“
- Razumijevanje konteksta tekstova, prevođenje i sl.

Natural Language Understanding



Primjene strojnog učenja u obradi prirodnog jezika

- Strojno učenje se intenzivno koristi i u obrada prirodnog jezika (engl. *natural language processing*)
 - Spam filtri
 - Analiziranje blogova ili postova na društvenoj mreži s ciljem ekstrahiranja "trending" tema
 - Računalni prijevod teksta
 - Google news - automatsko grupiranje sličnih priča (prati se velik broj izvora vijesti)
 - Skype prevoditelj omogućuje dvosmjernu komunikaciju dviju osoba koje pričaju različitim jezikom
 - ...

Primjene strojnog učenja u obradi slike

- Prepoznavanje osoba
 - Npr. Facebook koristi strojno učenje u auto tagging opciji - 98% preciznost
 - Može vas prepoznati na jednoj slici od 800 milijuna u manje od 5 sekundi
 - Čak i ako se vaše lice ne vidi u potpunosti (na temelju ostalih elemenata u slici i podataka koji pripadaju slici)
 - Koriste konvolucijske neuronske mreže
- [Applying machine learning science to Facebook products](#)
- [How Facebook is teaching computers to see](#)


Primjene strojnog učenja u obradi slike

- Prepoznavanje rukom pisanih znakova
- Vrlo čest problem (npr. poštanske omotnice)
- Ne postoji formalni opis svakog znaka; ljudi imaju različite stilove pisanja (veća/manja slova, nakošena)
- Ideja - na temelju primjera naučiti model koji će moći raspoznavati rukom pisane brojeve (barem se u određenoj mjeri približiti čovjekovoj sposobnosti raspoznavanja znakova)
- [Yann Lecun Convolutional Network Demo from 1993](#)




Primjene strojnog učenja u obradi slike

- ImageNet – natjecanje u klasifikaciji slika





Primjene strojnog učenja u obradi slike

- ImageNet – natjecanje u klasifikaciji slika
- 2012. godine prvi su puta upotrijebljene metode dubokog učenja
- Rezultati ImageNet natjecanja →



Strojno učenje i IoT – autonomna vozila




Primjene strojnog učenja u autonomnoj vožnji

- Detekcija objekata
- Identifikacija objekata ili prepoznavanje objekata
- Lokalizacija objekata i predikcija kretanja

Big Data meets Machine Learning in the Car

- Real world is a Big Data problem
- Driving in human world required intelligent perception of the world




Primjene strojnog učenja u autonomnoj vožnji

- Detekcija objekata i klasifikacija objekata
 - Ulaz u algoritam za detekciju – cijela slika
 - Ulaz u algoritam za klasifikaciju – izdvojeni dio slike na kojem je objekt




Primjene strojnog učenja u autonomnoj vožnji

- Detekcija objekata i klasifikacija objekata



Primjene strojnog učenja u autonomnoj vožnji

- Detekcija objekata
- Segmentacija scene



Primjene strojnog učenja u robotici

- SU primjenjuje se i u robotici i osnovna je stavka umjetne inteligencije
- Upravljanje hodom humanoidnih robota
- Upravljanje/manevriranje helikopterima
- Robotski vid ...

Konačno, što je strojno učenje i što se od vas očekuje?

- Strojno učenje
 - Programiranje računala s ciljem optimiziranja određenog kriterija koristeći podatkovne primjere ili prošlo iskustvo
 - Postoji model definiran do neke parametre i proces učenja je optimizacija parametara
 - Model se može koristiti za predikciju (u budućnosti) i/ili za dobivanje znanja o problemu iz podataka (deskriptivni modeli)
- Što bi trebala/trebao "znati/napraviti"?
 - Poznavati osnovne algoritme strojnog učenja
 - Razumjeti matematičku pozadinu algoritama
 - Primijeniti algoritme strojnog učenja u različitim područjima (obrada prirodnog jezika, obrada teksta, obrada slike, obrada zvuka, ...)

P i t a n j a ?

Vrste strojnog učenja

Vrste strojnog učenja

Nadzirano učenje

- Označeni podaci
- Izravne povratne informacije
- Predviđanje ishoda/budućnosti

Nenadzirano učenje

- Neoznačeni podaci (nema oznaka)
- Nema povratnih informacija
- Otkrivanje skrivene strukture u podacima

Podržano učenje


- Proces odlučivanja
- Sustav nagrađivanja
- Učenje niza akcija

Nadzirano učenje (engl. *supervised learning*)

- Nadzirano učenje je način SU gdje je cilj:
 - Odrediti nepoznatu funkcionalnu ovisnost između ulaznih veličina i izlazne veličine na temelju podatkovnih primjera
 - Naučiti model iz označenih trening podataka, što nakon toga omogućuje predviđanje izlaza (ishoda) za neviđene ili buduće podataka
- Pojam „nadzirano” odnosi se na skup trening primjera (ulaznih podataka), gdje su željeni izlazni signali (labele, tj. oznake) već poznati
- Primjeri trening podataka su parovi koji se sastoje od vektora ulaznih veličina i vrijednosti izlazne veličine

Nadzirano učenje

- Tipičan tok rada nadziranog učenja



- Trening podaci su proslijeđeni u algoritam strojnog učenja za usklađivanje prediktivnog modela koji potom može izvršiti predviđanje na novim, neoznačenim ulaznim podacima

Nadzirano učenje

- Broj ulaznih veličina označava se s n pa se vektor ulaznih veličina može zapisati u obliku:

$$\mathbf{x}^{(i)} = [x_1^{(i)}, x_2^{(i)}, \dots, x_n^{(i)}]^T$$

- Raspoloživi podatkovni primjeri (mjerni uzorci) na temelju kojih se određuje nepoznata funkcionalna ovisnost primjenom algoritama SU često se nazivaju i skup za učenje


$$\{(\mathbf{x}^{(1)}, y^{(1)}), (\mathbf{x}^{(2)}, y^{(2)}), \dots, (\mathbf{x}^{(n_{train})}, y^{(n_{train})})\}$$

- Ako je veličina y diskretna veličina, tada se ovaj problem naziva klasifikacija
- Ako je veličina y kontinuirana, tada se ovaj problem naziva regresija

Nadzirano učenje

Binarna klasifikacija – primjer


- 30 trening podataka;
 - 15 trening podataka označeno je kao negativna klasa (minus znakovi)
 - 15 trening podataka označeno je kao pozitivna klasa (znakovi plus)
- Skup podataka je dvodimenzionalan $\rightarrow$ svaki podatak ima dvije pridružene vrijednosti: x_1 , x_2
- Upotrijebiti algoritam nadziranog strojnog učenja kako bi naučili pravilo – granicu odluke predstavljenu isprekidanom linijom – koja može razdvojiti te dvije klase i klasificirati nove podatke u svaku od te dvije kategorije s obzirom na njihove vrijednosti x_1 , x_2



Nadzirano učenje

Regresija – predviđanje kontinuiranih ishoda

- Naziva se i **regresijska analiza**
- Na raspolaganju nam je niz prediktorskih (objašnjavajućih) varijabli i kontinuirana varijabla odgovora (ishod), a mi pokušavamo pronaći odnos između tih varijabli koji nam omogućuje predviđanje ishoda
- NAPOMENA: Prediktorske varijable obično se nazivaju "**značajke**", a varijable odgovora obično se nazivaju "**ciljne varijable**"



Jednodimenzionalna
linearna regresija

Nadzirano učenje

Primjeri nadziranog učenja

- **Klasifikacija (y je diskretna veličina)**
 - prepoznavanje pisanih brojeva (0 - 9)
 - prepoznavanje lica
 - spam/not spam (*true/false*)
 - medicinska dijagnostika (tumor/nije tumor)
- **Regresija (y iz skupa realnih brojeva)**
 - procjena temperature idućeg dana
 - procjena cijena kuća, automobila
 - procjena potrošnje plina, emisije plinova

Nadzirano učenje

- **Koja je svrha modela dobivenog nadziranim učenjem?**
 - Dvije su osnovne namjene dobivenog modela
 - **Predviđanje** (engl. *prediction*)
 - na temelju modela i vektora ulaznih veličina x procijeniti vrijednost izlazne veličine y
 - pri tome se model obično tretira kao crna kutija (engl. *black box*), tj. nije od velike važnosti oblik/forma modela, već koliko ima dobre sposobnosti predviđanja (koliko točno daje predikciju izlazne veličine)
 - obično glavna svrha modela u problemima SU
 - **Zaključivanje** (engl. *inference*)
 - koje su ulazne veličine u vezi s izlaznom veličinom ?
 - kakav je oblik funkcionalne povezanosti između svake ulazne veličine i izlazne veličine?
 - ovo je češće u području statističkog učenja (engl. *statistical learning*)

Nenadzirano učenje (engl. *unsupervised learning*)

- Kod nenadziranog učenja na raspolaganju su samo podaci o ulaznim veličinama, a izlazna veličina ne postoji
- Potrebno je naći određene pravilnosti u podacima (između mjernih uzoraka ili veličina)
 - **Grupiranje podataka** ili klaster analiza (engl. *clustering*)
 - **Smanjivanje dimenzionalnosti podataka** (engl. *dimensionality reduction*)
 - Procjena gustoće vjerojatnosti (engl. *density estimation*)
- Primjeri:
 - **Grupiranje podataka**: segmentacija tržišta/kupaca (npr. iz anketa kupaca), grupiranje sličnih dokumenata (npr. prema temi), analiza društvenih mreža
 - **Smanjivanje dimenzionalnosti**: kompresija podataka, vizualizacija podataka, hibridizacija s modelima koji se dobivaju nadziranim učenjem

Nenadzirano učenje


Grupiranje podataka/Klasteriranje

- Klasteriranje je istraživačka tehnika analize podataka koja omogućava da organiziramo grupu informacija u značajne podgrupe (klasterne), bez potrebe da imamo neko predznanje o članovima grupe
- Svaki klaster koji se pojavi u toku analize definira grupu objekata koji dijele određeni stupanj sličnosti, ali su više različiti od objekata u drugim klasterima → zbog toga se klasteriranje ponekad naziva i nenadzirana klasifikacija
- Klasteriranje je odlična tehnika za strukturiranje informacija i za izvođenje značajnih odnosa algoritmom iz podataka

Nenadzirano učenje

Grupiranje podataka/Klasteriranje → Primjer

- Organiziranje neoznačenih podataka u tri različite grupe na osnovu sličnosti njihovih atributa/značajki x_1 i x_2




Nenadzirano učenje

Smanjivanje dimenzionalnosti

- Podaci su često visoke dimenzionalnosti – svako opažanje uključuje velik broj mjerenja → može predstavljati izazov za ograničeni prostor za pohranu i računalne performanse za algoritme strojnog učenja
- Nenadzirano smanjenje dimenzionalnosti često je korišten pristup u pretprocesiranju značajki za
 - Uklanjanje šuma iz podataka, koji također može degradirati prediktivnu performansu određenih algoritama
 - **Kompresiju podataka u manje-dimenzionalni podprostor, zadržavajući najrelevantnije informacije**

Nenadzirano učenje

Smanjivanje dimenzionalnosti → Primjer




Podržano učenje (engl. *reinforcement learning*)

- Podržano učenje omogućava agentu da samostalno otkrije optimalno ponašanje metodom pokušaja i pogrešaka
- Kod podržanog učenja, postoji agent koji poduzima akcije u svom okolišu kako bi riješio problem
- Agent dobiva odgovarajuću povratnu informaciju za svaku akciju koju izvede (*penalty or reward*)
- Nakon određenog (velikog) broja pokušaja, agent bi trebao naučiti najbolji način odabira akcije u svakom koraku, što je zapravo niz akcija koji maksimizira ukupnu nagradu
- Budući da informacije o trenutnom stanju okoline obično uključuju i tzv. signal nagrade, podržano učenje možemo zamisliti kao polje povezano s nadziranim učenjem
 - Međutim, u podržanom učenju, ova povratna informacija nije točna oznaka ili stvarna vrijednost, već je to mjera koliko je dobro funkcija nagrade izmjerila akciju


Podržano učenje

- Primjeri

- stroj koji igra šah
- mobilni robot koji traži izlaz iz labirinta
- kretanje humanoidnih robota, letjelica
- [robot koji okreće palačinke](#)
- potpuno autonomno vozilo od točke A do točke B (najkraći/najjeftiniji put ?)



Da sumiramo...Vrste strojnog učenja



Da vidimo jeste li shvatili ...? Pitanje glasi...

- Od navedenih problema, koji pripadaju grupi nenadziranog učenja?
1. Dani skup postova/blogova potrebno ih je grupirati u skupine koji se bave istom tematikom
 2. Za dani skup podataka koji se sastoji od mjerenja provedenih na osobama koje imaju i koje nemaju dijabetes, potrebno je izgraditi model koji će predviđati imaju li novi pacijenti dijabetes ili ne
 3. Potrebno je izgraditi spam filter na temelju prikupljenih e-mail poruka koje su označene kao „spam“ ili „not spam“
 4. Na temelju ankete provedene na kupcima trgovačkog centra, potrebno je kupce grupirati u tri različite skupine (veliki, srednji i mali potrošači)
 5. Na temelju vremenskih prilika, veličine, sadržaja i posjećenosti zabavnog parka potrebno je izgraditi software koji će predviđati broj posjetitelja parka

Da vidimo jeste li shvatili ...? Pitanje glasi...

- Od navedenih problema, koji pripadaju grupi nenadziranog učenja?
1. Dani skup postova/blogova potrebno ih je grupirati u skupine koji se bave istom tematikom
 2. Za dani skup podataka koji se sastoji od mjerenja provedenih na osobama koje imaju i koje nemaju dijabetes, potrebno je izgraditi model koji će predviđati imaju li novi pacijenti dijabetes ili ne
 3. Potrebno je izgraditi spam filter na temelju prikupljenih e-mail poruka koje su označene kao „spam“ ili „not spam“
 4. Na temelju ankete provedene na kupcima trgovačkog centra, potrebno je kupce grupirati u tri različite skupine (veliki, srednji i mali potrošači)
 5. Na temelju vremenskih prilika, veličine, sadržaja i posjećenosti zabavnog parka potrebno je izgraditi software koji će predviđati broj posjetitelja parka

Da vidimo jeste li shvatili ...? Pitanje glasi...

- Radite u firmi koja održava različite online servise. Vaš šef hoće softver koji procjenjuje je li neki račun kompromitiran (hakiran) ili nije. Pri tome su vam na raspolaganju informacije o računima kao primjerice broj spajanja, trajanje sesije i sl., kao i informacija je li se takav račun smatra kompromitiran od strane službe održavanja. Koji biste pristup primijenili u ovom slučaju?
1. Nenadzirano učenje, grupiranje računa u dvije skupine
 2. Podržano učenje, nagradili biste korisnike koji imaju kompromitiran račun
 3. Nije potrebno primijeniti strojno učenje jer se točno zna koji račun je kompromitiran
 4. Nadzirano učenje, metode klasifikacije
 5. Nadzirano učenje, regresijske metode

Da vidimo jeste li shvatili ...? Pitanje glasi...

- Radite u firmi koja održava različite online servise. Vaš šef hoće softver koji procjenjuje je li neki račun kompromitiran (hakiran) ili nije. Pri tome su vam na raspolaganju informacije o računima kao primjerice broj spajanja, trajanje sesije i sl., kao i informacija je li se takav račun smatra kompromitiran od strane službe održavanja. Koji biste pristup primijenili u ovom slučaju?
1. Nenadzirano učenje, grupiranje računa u dvije skupine
 2. Podržano učenje, nagradili biste korisnike koji imaju kompromitiran račun
 3. Nije potrebno primijeniti strojno učenje jer se točno zna koji račun je kompromitiran
 4. Nadzirano učenje, metode klasifikacije
 5. Nadzirano učenje, regresijske metode

Da vidimo jeste li shvatili ...? Pitanje glasi...


- Predložite probleme koji bi bili riješeni različitim tipovima strojnog učenja i opišite koje bi bile ulazne varijable (značajke), a koje izlazne varijable?
1. Nadzirano učenje, 5-klasna klasifikacija, 6 ulaznih značajki
 2. Nadzirano učenje, regresija, tri ulazne značajke
 3. Nenadzirano učenje, klasteriranje podataka u 5 grupa, 4 ulazne značajke
 4. Nadzirano učenje, 5-klasna klasifikacija, 2073600 ulaznih značajki

P i t a n j a ?

Notacije i konvencije


Notacije i konvencije

- Dio [Iris skupa podataka](#), koji je klasičan primjer u području strojnog učenja
- Iris skup podataka sadrži mjere 150 cvjetova perunike iz triju različitih vrsta – Setosa, Versicolor i Virginica
- Svaki primjer cvijeta predstavlja jedan redak u skupu podataka, a mjere cvijeta u centimetrima pohranjuju se kao stupci, koji se također nazivaju značajkama (atributima) skupa podataka



Notacije i konvencije

- Za označavanje podataka koriste se matrični i vektorski zapisi
- Općenito, slijedi se uobičajena konvencija za predstavljanje svakog primjera kao zasebnog retka u matrici značajki, **X**, gdje je svaka značajka pohranjena kao zaseban stupac
- Skup podataka Iris, koji se sastoji od 150 primjera i četiri značajke, može se zatim napisati kao matrica 150×4



$$\begin{bmatrix} x_1^{(1)} & x_2^{(1)} & x_3^{(1)} & x_4^{(1)} \\ x_1^{(2)} & x_2^{(2)} & x_3^{(2)} & x_4^{(2)} \\ \vdots & \vdots & \vdots & \vdots \\ x_1^{(150)} & x_2^{(150)} & x_3^{(150)} & x_4^{(150)} \end{bmatrix}$$

Notacije i konvencije

Konvencije

- Eksponent (i) se koristi da bi ukazali na i-ti trening primjer
- Indeks j koristi se za označavanje j-te dimenzije skupa podataka za trening
- Mala, podebljana slova koriste se za označavanje vektora (npr. **x**)
- Velika, podebljana slova koriste se za označavanje matrica (npr. **X**)
- Kosa slova koriste se za označavanje pojedinačnih elemenata u vektoru ili matrici $x^{(n)}$ ili $x_m^{(n)}$
- Npr. $x_1^{(150)}$ odnosi se na prvu dimenziju primjera cvijeta 150, odnosno *Sepal length*


$$\begin{bmatrix} x_1^{(1)} & x_2^{(1)} & x_3^{(1)} & x_4^{(1)} \\ x_1^{(2)} & x_2^{(2)} & x_3^{(2)} & x_4^{(2)} \\ \vdots & \vdots & \vdots & \vdots \\ x_1^{(150)} & x_2^{(150)} & x_3^{(150)} & x_4^{(150)} \end{bmatrix}$$

Samples
(instances, observations)

	Sepal length	Sepal width	Petal length	Petal width	Class label
1	5.1	3.5	1.4	0.2	Setosa
2	4.9	3.0	1.4	0.2	Setosa
...					
50	6.4	3.5	4.5	1.2	Versicolor
...					
150	5.9	3.0	5.0	1.8	Virginica

Features
(attributes, measurements, dimensions)

Class labels
(targets)



Notacije i konvencije

Konvencije

- Svaki red u ovoj matrici značajki predstavlja jednu instancu cvijeta i može se napisati kao četvero-dimenzionalni redni vektor

$$\mathbf{x}^{(i)} = [x_1^{(i)} \quad x_2^{(i)} \quad x_3^{(i)} \quad x_4^{(i)}]$$

- Svaka dimenzija značajke je 150-dimenzionalni stupčasti vektor
- Slično, ciljne varijable (ovdje, oznake klasa) pohranjuju se kao 150-dimenzionalni stupčasti vektor


$$\begin{bmatrix} x_1^{(1)} & x_2^{(1)} & x_3^{(1)} & x_4^{(1)} \\ x_1^{(2)} & x_2^{(2)} & x_3^{(2)} & x_4^{(2)} \\ \vdots & \vdots & \vdots & \vdots \\ x_1^{(150)} & x_2^{(150)} & x_3^{(150)} & x_4^{(150)} \end{bmatrix}$$

$$\mathbf{x}_j = \begin{bmatrix} x_j^{(1)} \\ x_j^{(2)} \\ \dots \\ x_j^{(150)} \end{bmatrix}$$

$$\mathbf{y} = \begin{bmatrix} y^{(1)} \\ \dots \\ y^{(150)} \end{bmatrix} \quad (y \in \{\text{Setosa}, \text{Versicolor}, \text{Virginica}\})$$

Mapa za izgradnju sustava strojnog učenja

Mapa za izgradnju sustava strojnog učenja



Predprocesiranje – oblikovanje podataka



- Neobrađeni podaci rijetko dolaze u obliku koji je potreban za optimalnu izvedbu algoritma strojnog učenja
- Predobrada podataka jedan je od najvažnijih koraka u bilo kojoj aplikaciji strojnog učenja
- **Odabir korisnih značajki (atributa)** – možda su neke značajke manje važne ili nekorisne
- **Skaliranje značajki** – sve odabrane značajke na istoj skali (npr. u rasponu $[0,1]$)

Predprocesiranje – oblikovanje podataka




- **Smanjivanje dimenzionalnosti** – ako su neke od odabranih značajki visoko korelirane, one su redundantne do određenog stupnja → moguće je komprimirati značajke na potprostor niže dimenzionalnosti
 - Manje prostora za pohranu
 - Algoritam za učenje može raditi mnogo brže
 - U određenim slučajevima smanjenje dimenzionalnosti također može poboljšati prediktivnu izvedbu modela ako skup podataka sadrži velik broj nevažnih značajki (ili šuma)

Predprocesiranje – oblikovanje podataka




- **Nasumična podjela skupa podataka u zaseban skup podataka za treniranje i testiranje** → kako bi se utvrdilo ima li naš ML algoritam ne samo dobre performanse na skupu podataka za učenje, već i da dobro generalizira na novim podacima
- Skup trening podataka - za obuku i optimizaciju našeg ML modela
- Skup test podataka - za procjenu konačnog modela

Trening i odabir prediktivnog modela




- U praksi je važno usporediti barem nekoliko različitih algoritama kako bi se naučio i odabrao model s najboljim performansama
- Međutim, prije nego što možemo usporediti različite modele, prvo moramo donijeti odluku **o metrici za mjerenje performansi**
- U slučaju klasifikacije, često korištena metrika je točnost klasifikacije, koja se definira kao udio ispravno klasificiranih instanci

Trening i odabir prediktivnog modela



- Kako znamo koji model ima dobre performanse na konačnom testnom skupu podataka i podacima iz stvarnog svijeta ako ne koristimo ovaj testni skup podataka za odabir modela, već ga zadržavamo za konačnu evaluaciju modela?
- Korištenje tehnika unakrsne validacije → dalje razdvajamo skup podataka u podskupove za trening i validaciju kako bi procijenili performansu generalizacije modela


Trening i odabir prediktivnog modela



- Na kraju, ne možemo očekivati da će podrazumijevani parametri različitih algoritama za učenje koje pružaju softverske biblioteke biti optimalni za naš specifični problemski zadatak
- Korištenje tehnika **optimizacije hiperparametara** koje nam pomažu u finom podešavanju performansi našeg modela
- Te hiperparametre možemo shvatiti kao parametre koji nisu naučeni iz podataka, već predstavljaju ručice modela koje možemo okretati kako bi poboljšali performanse konkretnog modela

Evaluacija modela i predviđanje neviđenih instanci podataka

- Odabrali smo model koji je usklađen na trening skupu podataka → možemo upotrijebiti skup podataka za testiranje da bi procijenili koliko model dobro radi s ovim neviđenim podacima, tj. da bi procijenili tzv. pogrešku generalizacije
 - Zadovoljni → možemo koristiti ovaj model za predviđanje novih, budućih podataka
- **NAPOMENA:**
 - Parametri za prethodno spomenute postupke, kao što su skaliranje značajki i smanjivanje dimenzionalnosti, **dobivaju se isključivo iz trening skupa podataka**
 - Isti parametri kasnije se ponovno primjenjuju za transformaciju testnog skupa podataka, kao i svih novih instanci podataka



Alati i biblioteke za strojno učenje

Najbolji programski jezici za podatkovnu znanost i ML

- Python
 - R
 - SQL
 - Java
 - Julia
 - Scala
 - C/C++
 - JavaScript
 - Swift
 - Go
 - MATLAB
 - SAS
- Više diskusije o alatima dostupno [ovdje](#)
 - Naš fokus → Python



Python

- Python – jedan od najpopularnijih programskih jezika za znanost o podacima i strojno učenje
- Vrlo aktivna developerska i open-source zajednica
- Velik broj korisnih biblioteka za znanstveno računarstvo i strojno učenje
- Opseg njegove primjene nije ograničen samo na rad s podacima
- Mogućnosti Pythona omogućuju vam da napišete program za zadatke strojnog učenja „od nule“ i korištenjem raznih biblioteka i alata
- Činjenice i statistika
 - Preko 60% znanstvenika koji se bave podacima svakodnevno koristi Python
 - Preko 80% koristi ga kao glavni jezik



Python biblioteke za znanost o podacima i strojno učenje

- **NumPy i SciPy**

- Popularni paket koji nudi opsežnu zbirku naprednih matematičkih funkcija
- Za brze vektorizirane operacije na višedimenzionalnim nizovima

- **Pandas**

- Ključna biblioteka u znanosti o podacima, koja se koristi za izvođenje svih vrsta manipulacija bazama podataka, također nazivanim i DataFrames
- Pruža dodatne alate za manipulaciju podacima više razine koji rad s tabličnim podacima čine još praktičnijim

- **Matplotlib** – standardna Python biblioteka za vizualizaciju podataka

Python biblioteke za znanost o podacima i strojno učenje

- **Scikit-learn**

- Izgrađen na temelju NumPy i SciPy, postao je najpopularnija Python biblioteka za razvoj algoritama strojnog učenja

- **TensorFlow**

- Snažan računalni okvir za razvoj strojnog učenja i algoritama dubokog učenja

- **Keras**

- Biblioteka otvorenog koda dizajnirana za obuku neuronskih mreža s visokim performansama

Primjeri skupova podataka

Skupovi podataka države i gradovi

- Veliki broj različitih skupova podataka dostupno je na data.gov stranicama pojedine države ili grada
 - [SAD](#)
 - [Ujedinjeno Kraljevstvo](#)
 - [Hrvatska](#)
 - [India](#)
 - [San Francisco](#)
- Prije korištenja provjeriti licencu (najčešće se zahtjeva citiranje izvora)

Specifični skupovi podataka i repozitoriji SU

- Postoji i niz web stranica koje sadrže specifične skupove podataka, npr.:
 - data.medicare.gov
 - ngrams
 - [milion song data set](http://million-song-data.com)
 - [open source sports](http://open-sports.com)
 - [time series datasets](http://time-series-datasets.com)
 - [face recognition database](http://face-recognition-database.com)
- I drugi repozitoriji raznoraznih skupova podataka:
 - [awesome public datasets](http://awesome-public-datasets.com)
 - [machine learning dataset repozitorij](http://machine-learning-dataset-repository.com)
 - [UC Irvine Machine Learning Repository](http://ucmlr.ucirvine.edu)
 - [UCI Knowledge Discovery in Databases Archive](http://kdd.uci.edu)
 - [KDD cup](http://kddcup.net)

- Python biblioteka scikit-learn sadrži veću količinu skupova podataka
 - *Boston house-prices dataset*
 - *Iris dataset*
 - *diabetes dataset*
 - *digits dataset ...*

Specifični skupovi podataka i repozitoriji SU

- Skupovi podataka koji mogu biti korišteni za razvoj ADAS algoritama
- [The KITTI Vision Benchmark Suite](#)
 - [Kako je nastala i zašto?](#)
- [Pedestrian Dataset](#)
- [Penn-Fudan Database for Pedestrian Detection and Segmentation](#)
- [Nexar Challenge #2 – Nexar](#)
- ...



Google *datasets*

- Google je u 2018. predstavio tražilicu za podatkovne skupove
- <https://toolbox.google.com/datasetsearch>

Google Dataset Search Beta

Try [boston education data](#) or [weather site:noaa.gov](#)

P i t a n j a ?