

Nadzirano učenje



Sadržaj

- Regresija – osnovni pojmovi
- Linearna regresija s jednom varijablom
- Višedimenzionalna linearna regresija
- Polinomska regresija
- Skaliranje ulaznih veličina
- *Underfitting* i *Overfitting*

Regresija – osnovni pojmovi

Podsjetimo se... Nadzirano učenje...

- Broj ulaznih veličina označava se s n pa se vektor ulaznih veličina može zapisati u obliku:

$$\mathbf{x}^{(i)} = [x_1^{(i)}, x_2^{(i)}, \dots, x_n^{(i)}]^T$$

- Raspoloživi podatkovni primjeri (mjerni uzorci) na temelju kojih se određuje nepoznata funkcionalna ovisnost primjenom algoritama SU često se nazivaju i skup za učenje

$$\{(\mathbf{x}^{(1)}, y^{(1)}), (\mathbf{x}^{(2)}, y^{(2)}), \dots, (\mathbf{x}^{(n_{\text{train}})}, y^{(n_{\text{train}})})\}$$

- Ako je veličina y nebrojčana veličina, tada se ovaj problem naziva klasifikacija
- Ako je veličina y brojčana, tada se ovaj problem naziva regresija

Regresija. Interpolacija.



- Kod binarne klasifikacije, za dani ulaz generira se izlazna vrijednost koja je binarna (0/1 ili da/ne)
- Kod višeklasne klasifikacije, za dani ulaz generira se izlazna vrijednost koja je diskretna (postoji više od dvije izlazne vrijednosti, ali je broj izlaznih vrijednosti, tj. klasa, KONAČAN)
- Kada je izlazna veličina kontinuirana numerička vrijednost, ne pokušavamo naučiti klasu, već hoćemo naučiti numeričku funkciju
- Ova funkcija nije poznata, ali imamo skup podataka za učenje, koji su primjeri ove funkcijske povezanosti:

$$D_{train} = \left\{ \mathbf{x}^{(i)}, y^{(i)} \right\}_{i=1}^{n_{train}} \quad y^{(i)} \in \mathbb{R}$$

- Ovaj zadatak često se naziva i INTERPOLACIJA
- Pokušava se pronaći funkcija $f(\mathbf{x})$ koja prolazi kroz dane podatke tako da je $y^{(i)} = f(\mathbf{x}^{(i)})$

Regresija. Ekstrapolacija.

- Npr. u polinomskoj regresiji, na temelju n_{train} podataka (točaka) traži se polinom $(n_{train} - 1)$. stupnja
- Dobivena funkcija može se koristiti za predikciju izlazne veličine za bilo koji x – ovo se naziva EKSTRAPOLACIJA ako je x izvan raspona podataka u skupu za učenje
- U predikciji kod vremenskih nizova (engl. *time series*), na raspolaganju su podaci do sadašnjeg trenutka, a želi se predvidjeti vrijednost u budućnosti



Regresija. Šum.

- Kod regresije pak, postoji šum ε u izlaznoj veličini nepoznate funkcionalne ovisnosti f :

- Zašto?

$$y^{(i)} = f\left(\mathbf{x}^{(i)}\right) + \varepsilon$$

- Šum postoji zato što postoje ekstra skrivene varijable $\mathbf{z}$ koje ne možemo opaziti (ili nisu izmjerene):


$$y^{(i)} = f^*\left(\mathbf{x}^{(i)}, \mathbf{z}^{(i)}\right)$$

- Nepoznata funkcionalna ovisnost $f(\mathbf{x}^{(i)})$ nastoji se aproksimirati modelom, odnosno odgovarajućom hipotezom $h(\mathbf{x})$

Regresija. Empirijska pogreška.

- Empirijska pogreška na skupu za učenje (primjer):

$$E(h | D_{train}) = \frac{1}{n_{train}} \sum_{i=1}^{n_{train}} \left(h(\mathbf{x}^{(i)}) - y^{(i)} \right)^2$$



- Kako su y i $h(x)$ numeričke kontinuirane vrijednosti, može se definirati udaljenost između ovih veličina
 - Kao npr. kvadrat razlike, što nam daje više informacije nego u slučaju klasifikacije (jednako, nije jednako)
- Kvadratna funkcija pogreške je samo jedna moguća mjera
 - Moguća su i druge mjere...više informacija kasnije

Regresija

- Cilj je pronaći aproksimacijsku funkciju (hipotezu) koja minimizira empirijsku pogrešku
- Može se pretpostaviti skup hipoteza s manjim brojem parametara
- Primjerice, pretpostavi se linearna aproksimacijska funkcija:

$$\hat{y}^{(i)} = h(\mathbf{x}^{(i)}) = \Theta_0 + \Theta_1 x_1 + \Theta_2 x_2 + \dots + \Theta_m x_m$$

Linearna regresija s jednom varijablom

Regresija - primjer

- Primjer: želimo sustav koji može procijeniti plaću zaposlenika na temelju atributa: starost, godine obrazovanja, godine iskustva, mjesto rada,...
- Zbog jednostavnosti, koristi se samo jedna ulazna varijabla – npr. godine iskustva
- Model je oblika:

$$\hat{y}^{(i)} = h(\mathbf{x}^{(i)}) = \Theta_0 + \Theta_1 x$$


gdje su θ_0 i θ_1 parametri koje treba naučiti, odnosno odrediti iz dostupnih podataka (ovo je primjer LINEARNE REGRESIJE s jednom varijablom)

- Do parametara je moguće doći minimizacijom empirijske pogreške koja ukazuje na veličinu pogreške procjene – nazivamo ju u ovom slučaju i KRITERIJSKA FUNKCIJA

Linearna regresija s jednom varijablom

- Jednostavan algoritam, dobar za ilustraciju ključnih koncepata poput definiranja kriterijske funkcije i njezinog minimiziranja
 - Temelj za razumijevanje naprednijih algoritama strojnog učenja
- Cilj linearne regresije s jednom varijablom je modelirati odnos između jedne značajke (ulazne varijable, x) i kontinuirane ciljne vrijednosti (izlazna veličina, y)
- To je ravna linija koja najbolje odgovara odnosu između jedne ulazne varijable (x) i izlazne varijable (y)

Linearna regresija s jednom varijablom



- **Kako pronaći ovu liniju?**
 - Moramo definirati kriterij koji će nam reći koliko dobro naš model odgovara dostupnim podacima
 - Ovo se zove kriterijska funkcija (engl. *cost function*)

Linearna regresija s jednom varijablom


- Kada je model određen, ostaje vidjeti na koji način se određuju parametri Θ za odabrani model
- Kod strojnog učenja, parametri Θ za odabrani model određuju se iterativnim procesom učenja
- Za provođenje iterativnog procesa potrebni su:
 - Odabrani model (prethodno definiran) – mi smo se trenutno odlučili za polinom 1. reda (linearna regresija)
 - Trening podaci - $(x^{(i)}, y^{(i)})$
 - Kriterijska funkcija (npr. srednja kvadratna pogreška, apsolutna pogreška, ...)
 - Govori nam koliko je model dobar
 - Želimo postići što manju vrijednost kriterijske funkcije

Linearna regresija s jednom varijablom

- Trening podaci $(x^{(i)}, y^{(i)})$
- Na raspolaganju je skup za učenje koji se sastoji od niza mjerenja jedne ulazne veličine x i izlazne veličine y
- Neka je odabran model oblika

$$\hat{y}(x) = h_{\theta}(x^{(i)}) = \Theta_1 x^{(i)}$$

(procijenili smo da nam ne treba Θ_0)




$$\hat{y}(x) = \Theta_1 x$$
$$\Theta_1 = ?$$

Linearna regresija s jednom varijablom

- Koje su optimalne vrijednosti parametra Θ_1 ?
- Ideja - odabrati parametar Θ_1 tako da je rezultirajuća funkcija (model) što bliže podacima za učenje
- Može se iskoristiti kriterijska funkcija:

$$J(\Theta_1) = \frac{1}{2n} \sum_{i=1}^n (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

$$\Theta_{ML} = \arg \min_{\Theta_0, \Theta_1} J(\Theta_1)$$




$$\hat{y}(x) = \Theta_1 x$$


$\Theta_1 = ?$

Linearna regresija s jednom varijablom

- Kakvog je oblika kriterijska funkcija J (ne model !!!) za ovaj primjer?




$$\theta_1 = 1 \quad J(\theta_1) = 0$$



$$\theta_1 = 0.5 \quad J(\theta_1) = 0.58$$


Linearna regresija s jednom varijablom

- Kakvog je oblika kriterijska funkcija za ovaj primjer?
- Algoritam optimizacije kreće od neke početne vrijednosti nepoznatog parametra te se kreće u smjeru negativnog gradijenta funkcije $J(\Theta)$
→ tzv. METODA GRADIJENTNOG SPUSTA




Linearna regresija s jednom varijablom

- Sljedeći primjer – nešto složeniji model, ali i dalje linearan
- Trening podaci $(x^{(i)}, y^{(i)})$ - na raspolaganju je skup za učenje koji se sastoji od niza mjerenja jedne ulazne veličine x i izlazne veličine y



Linearna regresija s jednom varijablom

- Linearna funkcija (model) ima najjednostavniji oblik, a često zadovoljavajuće opisuje problem
- Treba odabrati jednu od svih mogućih → procjena parametara



linearna funkcija

$$h_{\theta}(x) = \theta_0 + \theta_1 x$$

$$\underline{\theta} = [\theta_0 \ \theta_1]^T$$

koje su optimalne
vrijednosti parametara?

Linearna regresija s jednom varijablom

- Neka je odabran model oblika

$$\hat{y}(x) = h_{\theta}(x^{(i)}) = \Theta_0 + \Theta_1 x^{(i)}$$

- I neka su na raspolaganju mjerenja odnosno skup za učenje

$$\{(x^{(1)}, y^{(1)}), (x^{(2)}, y^{(2)}), \dots, (x^{(n)}, y^{(n)})\}$$

- Koje su optimalne vrijednosti vektora parametara Θ (u ovom slučaju Θ_0 i Θ_1)?
- Ideja - odabrati parametre Θ tako da je rezultirajuća funkcija što bliže podacima za učenje
- Može se iskoristiti kriterijska funkcija:


$$J(\Theta_0, \Theta_1) = \frac{1}{2n} \sum_{i=1}^n (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

$$\Theta_{ML} = \arg \min_{\Theta_0, \Theta_1} J(\Theta_0, \Theta_1)$$

Linearna regresija s jednom varijablom


- Kriterijska funkcija

$$J(\Theta_0, \Theta_1)$$



Linearna regresija s jednom varijablom

- Algoritam optimizacije kreće od neke početne vrijednosti nepoznatih parametara Θ_0 , Θ_1 te se kreće u smjeru negativnog gradijenta funkcije $J(\Theta)$, tj. $J(\Theta_0, \Theta_1)$
- Metoda gradijentnog spusta
- Kako ona radi???



Linearna regresija s jednom varijablom

Metoda gradijentnog spusta

- Iterativni postupak za traženje lokalnog minimuma derivabilne funkcije
- Tražimo lokalni minimum funkcije $J(\Theta)$ tj. $J(\Theta_0, \Theta_1)$ jer nju želimo minimizirati

$$J(\Theta_0, \Theta_1) = \frac{1}{2n} \sum_{i=1}^n (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

- Korišćenje gradijenta (prva derivacija ! Parcijalna derivacija po Θ_0, Θ_1) – zato se zove gradijentna metoda

$$\frac{\partial J(\Theta)}{\partial \Theta_0} = \frac{1}{n} \sum_{i=1}^n (h_{\theta}(x^{(i)}) - y^{(i)})$$

$$\frac{\partial J(\Theta)}{\partial \Theta_1} = \frac{1}{n} \sum_{i=1}^n (h_{\theta}(x^{(i)}) - y^{(i)})x^{(i)}$$

Linearna regresija s jednom varijablom

Metoda gradijentnog spusta

$$J(\Theta_0, \Theta_1) = \frac{1}{2n} \sum_{i=1}^n (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

Parcijalne derivacije po Θ_0 (kako se mijenja J s promjenom Θ_0 ?)

$$J(\Theta_0, \Theta_1) = \frac{1}{2n} \sum_{i=1}^n \left(\underbrace{\Theta_0 + \Theta_1 x^{(i)}}_{h_{\theta}(x^{(i)})} - y^{(i)} \right)^2$$

$$\frac{\partial J(\Theta_0, \Theta_1)}{\partial \Theta_0} = \frac{1}{2n} \cdot 2 \sum_{i=1}^n \left(\underbrace{\Theta_0 + \Theta_1 x^{(i)}}_{h_{\theta}(x^{(i)})} - y^{(i)} \right) \rightarrow \boxed{\text{SLOŽENA DERIVACIJA}}$$

$$\boxed{\frac{\partial J(\Theta_0, \Theta_1)}{\partial \Theta_0} = \frac{1}{n} \sum_{i=1}^n (h_{\theta}(x^{(i)}) - y^{(i)})}$$

$$\frac{\partial J(\Theta)}{\partial \Theta_0} = \frac{1}{n} \sum_{i=1}^n (h_{\theta}(x^{(i)}) - y^{(i)})$$

Linearna regresija s jednom varijablom

Metoda gradijentnog spusta

$$J(\Theta_0, \Theta_1) = \frac{1}{2n} \sum_{i=1}^n (h_{\theta}(x^{(i)}) - y^{(i)})^2$$

Parcijalne derivacije po Θ_1

$$\frac{\partial J(\Theta_0, \Theta_1)}{\partial \Theta_1} = \frac{1}{2n} \sum_{i=1}^n x \cdot (\underbrace{\Theta_0 + \Theta_1 x^{(i)}}_{h_{\theta}(x^{(i)})} - y^{(i)}) \cdot x^{(i)}$$

$$\boxed{\frac{\partial J(\Theta_0, \Theta_1)}{\partial \Theta_1} = \frac{1}{n} \sum_{i=1}^n (h_{\theta}(x^{(i)}) - y^{(i)}) \cdot x^{(i)}}$$

$$\frac{\partial J(\Theta)}{\partial \Theta_1} = \frac{1}{n} \sum_{i=1}^n (h_{\theta}(x^{(i)}) - y^{(i)}) x^{(i)}$$

TO SU PARCIJALNE DERIVACIJE KRITERIJSKE FUNKCIJE
PO PARAMETRIMA Θ_0 I Θ_1

Linearna regresija s jednom varijablom

Metoda gradijentnog spusta

1. Odaberi početne vrijednosti vektora parametara Θ ; definiraj duljinu koraka α
2. Ažuriraj svaki element vektora Θ :


$$\Theta_j := \Theta_j - \alpha \frac{\partial J(\Theta)}{\partial \Theta_j} \quad \text{za } j = 1, \dots, m$$

3. Ako nije zadovoljen kriterij zaustavljanja tada idi na 2.; u suprotnom zaustavi optimiranje
- Mogu se koristiti različiti kriteriji zaustavljanja (dostignut maksimalni broj iteracija algoritma, relativna promjena vektora parametara između dva koraka algoritma je manja od unaprijed zadanog ϵ i sl.)
 - Simultano se provodi ažuriranje svih parametara vektora Θ !
 - Ovo je batch metoda - svi trening uzorci se koriste u svakoj iteraciji algoritma

Linearna regresija s jednom varijablom

Metoda gradijentnog spusta

- U svakom koraku gradijent je vektor koji će iz određene točke pokazivati na „nizbrdicu” na kriterijskoj funkciji
- Kuda (u kojem smjeru) kriterijska funkcija ima najbrži pad (s gledišta promjene Θ_0 i Θ_1)



Linearna regresija s jednom varijablom

Metoda gradijentnog spusta – za slučaj optimiranja parametara modela

$$\hat{y}(x) = h_{\theta}(x^{(i)}) = \Theta_0 + \Theta_1 x$$

1. Odaberi početne vrijednosti vektora parametara Θ ; definiraj duljinu koraka α
2. Ažuriraj svaki element vektora Θ :

$$\Theta_0 := \Theta_0 - \alpha \frac{1}{n} \sum_{i=1}^n (h_{\theta}(x^{(i)}) - y^{(i)})$$

$$\Theta_j := \Theta_j - \alpha \frac{\partial J(\Theta)}{\partial \Theta_j} \quad \text{za } j = 1, \dots, m$$

$$\Theta_1 := \Theta_1 - \alpha \frac{1}{n} \sum_{i=1}^n (h_{\theta}(x^{(i)}) - y^{(i)}) x^{(i)}$$


3. Ako nije zadovoljen kriterij zaustavljanja tada idi na 2.; u suprotnom zaustavi optimiranje

Linearna regresija s jednom varijablom

Metoda gradijentnog spusta – Što je α ?

- Duljina koraka
- Brzina učenja (engl. *learning rate*)
- Kako ju odabrati ?

$$\Theta_j := \Theta_j - \alpha \frac{\partial J(\Theta)}{\partial \Theta_j} \quad \text{za } j = 1, \dots, m$$




[Izvor](#)

Linearna regresija s jednom varijablom

Metoda gradijentnog spusta – Što je α ?

- „loss” → greška (iznos kriterijske funkcije)
- Što je α veći, skok iz točke u točku pri kretanju prema minimumu iznosa kriterijske funkcije (greške) je veći
- Što je α manji → manji skokovi
- Male brzine učenja (npr. 0.0001) → trebat će velik broj iteracija da se dođe do optimalnih parametara Θ




[Izvor](#)

Linearna regresija s jednom varijablom

Metoda gradijentnog spusta – Što je α ?

- Velike brzine učenja $\rightarrow$ veliki skokovi prema optimalnoj točki $\rightarrow$ s takvim skokovima teško ćemo pogoditi minimum iznosa kriterijske funkcije (preskakat ćemo ga stalno)
 - Brzo smo u startu smanjili grešku, ali onda gotovo stagniramo („osciliramo” oko idealnih parametara, ali nikako da „doskočimo” na njih)
- Vrlo velike brzine učenja $\rightarrow$ još veći skokovi iz točke u točku $\rightarrow$ moguće da greška počne rasti




[Izvor](#)

Verzije gradijentnog spusta


- **Batch verzija gradijentne metode**
 - U svakoj iteraciji svi trening podaci se koriste za izračun kriterijske funkcije, tj. promjene parametara modela
 - Epoha – jedan prolaz kroz sve trening podatke (1 epoha = 1 iteracija kod batch metode)
 - S velikim skupovima podataka (npr. milijuni podatkovnih primjera) to može biti računalno prilično skupo i sporo
- **Stohastička gradijentna metoda (SGD – engl. Stochastic Gradient Descent), koji se također često naziva iterativna ili online**
 - Parametre modela (težine) ažuriramo za svaki pojedinačni primjer trening podatka
 - Obično puno brže
 - Može lakše izbjeći plitke lokalne minimume ako radimo s nelinearnim kriterijskim funkcijama
 - Trening podaci se moraju miješati za svaku epohu (1 epoha ovdje ima onoliko iteracija koliko postoji trening podataka u skupu)

Verzije gradijentnog spusta

- **Mini-batch učenje**
 - Kompromis između batch i SGD
 - Mini-batch učenje može se shvatiti kao primjena batch metode na manje podskupove trening podataka, npr. 32 trening podatka odejenom
 - Češće ažuriranje parametrara modela (težina) u usporedbi sa batch metodom
 - Koliko iteracija ovdje sadrži jedna epoha?
 - Ukupni broj trening podataka podijeljen s veličinom mini-batcha




Usporedba metoda gradijentnog spusta



Provjerimo koliko ste shvatili ...

- Na slici je prikazan tijek optimizacije jednodimenzionalne kriterijske funkcije sa samo jednim parametrom Θ_1 . Što je od navedenog točno?



- ova kriterijska funkcija nema minimum
- slika je pogrešna, prilikom prepodešavanja parametara metodom najbržeg spusta nije moguće "preskočiti" minimum kriterijske funkcije
- prevelika je duljina koraka
- premala je duljina koraka
- algoritam je napravio previše iteracija
- početna vrijednost ne može biti na lijevoj strani kriterijske funkcije

Provjerimo koliko ste shvatili ...


Pretpostavite da je na raspolaganju skup za učenje s jednom ulaznom i jednom izlaznom veličinom. Optimiranjem parametara modela $\hat{y}(x) = h_{\theta}(x^{(i)}) = \Theta_0 + \Theta_1 x$ odredili ste parametre modela tako da je $J(\Theta_0, \Theta_1) = 0$. Što je od navedenog točno?

- $J(\Theta_0, \Theta_1) = 0$ samo ako je $\Theta_0 = 0$ i $\Theta_1 = 0$
- nemoguće jer je $J(\Theta_0, \Theta_1)$ uvijek veće od 0
- dobiveni model točno prolazi kroz svaki uzorak iz skupa za učenje
- s ovakvim modelom moguće je potpuno točno odrediti vrijednost izlazne veličine za nove uzorke ulazne veličine

Višedimenzionalna linearna regresija

Višedimenzionalna linearna regresija


- engl. *Multiple (multivariate) linear regression*
- Cilj višedimenzionalne (višestruke) linearne regresije je modelirati odnos između ulaznih varijabli (X) i kontinuirane izlazne vrijednosti (y)
- To je hiperravnina koja najbolje odgovara odnosu između ulaznih varijabli (X) i izlazne varijable (y)



Višedimenzionalna linearna regresija

Primjer višedimenzionalne linearne regresije

- Dvije ulazne veličine
 - Godine obrazovanja
 - Senioritet (iskustvo)
- Želimo modelirati ovisnost primanja u ovisnosti o tim dvjema ulaznim veličinama
 - Na osnovu ulaznih trening podataka koje imamo na raspolaganju (crveni kružići)
 - Zašto to želimo?



Višedimenzionalna linearna regresija

- Gotovo uvijek je na raspolaganju veći broj ulaznih veličina (ne samo jedna)
- U tom slučaju model je oblika (engl. *multiple linear regression*):

$$\hat{y}(\mathbf{x}^{(i)}) = h_{\theta}(\mathbf{x}^{(i)}) = \Theta_0 + \Theta_1 x_1^{(i)} + \Theta_2 x_2^{(i)} + \dots + \Theta_m x_m^{(i)} = \Theta_0 + \sum_{j=1}^m \Theta_j x_j^{(i)}$$

gdje je $\mathbf{x}$ vektor koji sadrži uzorak ulaznih veličina: $\mathbf{x}^{(i)} = [x_1^{(i)}, x_2^{(i)}, \dots, x_m^{(i)}]^T$

- Uobičajeno je ovakav model proširiti dodatnom ulaznom veličinom koja je iznosa 1

$$x_0^{(i)} = 1 \quad \text{za} \quad i = 1, \dots, n$$

- Pa se vektor koji sadrži uzorak ulaznih veličina i vektor parametara zapisuju kao:

$$\mathbf{x}^{(i)} = [x_0^{(i)}, x_1^{(i)}, x_2^{(i)}, \dots, x_m^{(i)}]^T \in \mathbb{R}^{m+1}$$

$$\Theta = [\Theta_0, \Theta_1, \dots, \Theta_m]^T \in \mathbb{R}^{m+1}$$

Višedimenzionalna linearna regresija

- Uz pomoću *dummy* veličine ($x_0^{(i)}=1$) model se može zapisati u obliku:

$$\hat{y}(\mathbf{x}^{(i)}) = h_{\theta}(\mathbf{x}^{(i)}) = \sum_{j=0}^m \Theta_j x_j^{(i)} = \Theta^T \mathbf{x}^{(i)}$$

- Određivanje optimalnih vrijednosti vektora parametara Θ provodi se na jednak način kao i kod linearne regresije s jednom ulaznom veličinom:

$$J(\Theta) = \frac{1}{2n} \sum_{i=1}^n (h_{\theta}(\mathbf{x}^{(i)}) - y^{(i)})^2$$

$$\Theta_{ML} = \arg \min_{\Theta} J(\Theta)$$

Višedimenzionalna linearna regresija

Metoda najbržeg spusta

- iterativni postupak za traženje optimalnih parametara modela
 1. Odaberi početnu vrijednost vektora parametara Θ ; definiraj duljinu koraka α
 2. Ažuriraj svaki element vektora Θ

$$\Theta_j := \Theta_j - \alpha \frac{\partial J(\Theta)}{\partial \Theta_j} \quad \text{za } j = 1, \dots, m$$

3. Ako nije zadovoljen kriterij zaustavljanja tada idi na 2.; u suprotnom zaustavi optimiranje
- Parcijalne derivacije kriterijske funkcije po parametrima modela u slučaju višedimenzional

$$\frac{\partial J(\Theta)}{\partial \Theta_j} = \frac{1}{n} \sum_{i=1}^n (h_{\theta}(\mathbf{x}^{(i)}) - y^{(i)}) \mathbf{x}_j^{(i)} \quad \text{za } j = 0, \dots, m$$

Polinomska regresija

Polinomska regresija

- Proširenje linearne regresije moguće je u smislu nelinearne transformacije ulaznih veličina - na taj način model može opisati i nelinearne odnose između ulaznih veličina i izlazne veličine
- Radi jednostavnosti, za početak se analizira model s jednom ulaznom veličinom
- Transformacijom ulazne veličine korištenjem funkcije

$$\phi_k(x) = x^k \quad \text{gdje je} \quad k = 1, \dots, K$$


- Dobiva se model oblika:

$$\hat{y}(x^{(i)}) = h_{\theta}(x^{(i)}) = \Theta_0 + \sum_{k=1}^K \Theta_k \phi_k(x) = \sum_{k=0}^K \Theta_k \phi_k(x) \quad \text{uz} \quad \phi_0(x) = 1$$

- Problem optimizacije i dalje ima jedan minimum $\rightarrow$ metoda gradijentnog spusta

Polinomska regresija

- U skupu podataka *Cars* nalaze se mjerenja za 392 vozila
- Dostupna su mjerenja težine vozila (*weight*) i potrošnje (*mpg* - miles per gallon)
- Odnos ove dvije veličine je nelinearan te je prikladnije koristiti polinomsku regresiju umjesto linearne regresije



$$\hat{mpg}(weight) = \Theta_0 + \Theta_1 weight + \Theta_2 weight^2$$

Metoda gradijentnog spusta - zaključak

- Potrebno je odabrati duljinu koraka α , početnu vrijednost vektora parametara Θ te kriterij zaustavljanja
- Često potrebno mnogo iteracija
- Prikladna za probleme gdje je broj uzoraka velik ($n > 10000$), pogotovo stohastička metoda najbržeg spusta
- Potrebno je skalirati veličine prije optimizacije ?!?


Skaliranje ulaznih veličina

Skaliranje ulaznih veličina


- Skaliranje ulaznih veličina je vrlo važno kod izgradnje modela jer različita dimenzija ulaznih veličina može uzrokovati probleme prilikom optimizacije kriterijske funkcije
- Stoga je skaliranje ulaznih veličina potrebno provesti prije učenja modela (korak predobrada raspoloživih mjerenja)
- Primjer: potrošnja automobila se mjeri u litrama na 100 km (npr. 8 l/100km) dok se težina automobila mjeri u kilogramima (npr. 1500 kg)
- Ovo može uzrokovati probleme prilikom optimizacije, npr. u slučaju metode najbržeg spusta, konture kriterijske funkcije budu jako izdužene, što uzrokuje sporu konvergenciju algoritma

Skaliranje ulaznih veličina

Unnormalized



Normalized



Skaliranje ulaznih veličina

- Postoji nekoliko načina skaliranja veličina od kojih su najpoznatija standardizacija i Min-Max skaliranje
- Standardizacija je skaliranje svake ulazne veličine ($j=1,\dots,m$) na način da rezultatni podaci imaju srednju vrijednost 0 i varijancu jednaku 1:


$$\tilde{x}_j = \frac{x_j - \bar{x}_j}{\sigma_j} \quad \text{gdje je} \quad \bar{x}_j = \frac{1}{n} \sum_{i=1}^n x_j^{(i)} \quad , \quad \sigma_j = \sqrt{\frac{1}{n} \sum_{i=1}^n (x_j^{(i)} - \bar{x}_j)^2}$$

- Min-Max skaliranje je skaliranje vrijednosti ulaznih veličina na interval $[0,1]$ ili $[-1,1]$

$$\tilde{x}_j = \frac{x_j - xMin_j}{xMax_j - xMin_j} \quad \text{gdje je} \quad \begin{array}{l} xMin_j = \min(x_j) \\ xMax_j = \max(x_j) \end{array}$$

- Napomena: skaliranje veličina u nekim programskim funkcijama za strojno učenje je već implementirano ili postoje gotove funkcije

Skaliranje ulaznih veličina



Metrike performansi za regresiju

Metrike performansi za regresiju

- **Mean Squared Error (MSE)** – srednja kvadrata pogreška

- Izračunava prosječnu kvadratnu razliku između stvarnih i predviđenih vrijednosti

$$\text{MSE}(y, \hat{y}) = \frac{1}{n_{\text{samples}}} \sum_{i=0}^{n_{\text{samples}}-1} (y_i - \hat{y}_i)^2.$$

- Neograničena, ponekad teško procijeniti performanse modela
- Interpretacija MSE-a ovisi o skupu podataka i skaliranju atributa
- Npr. ako su cijene kuća predstavljene kao višestruki broj tisuća (sa sufiksom K), isti model daje niži MSE u usporedbi s modelom koji je koristio neskaliране attribute
 - Npr cijene kuća izražene kao 10K-15K ili 10000-15000

- **Root Mean Squared Error (RMSE)** – korijen srednje kvadratne pogreške

- Kvadratni korijen srednje kvadratne pogreške (MSE)
- Ima istu jedinicu kao izlazna varijabla

Metrike performansi za regresiju

- **Mean Absolute Error (MAE)** – srednja apsolutna pogreška
 - prosjek apsolutne razlike između stvarnih i predviđenih vrijednosti

$$MAE(y, \hat{y}) = \frac{1}{n_{samples}} \sum_{i=0}^{n_{samples}-1} |y_i - \hat{y}_i|$$

- **Mean Absolute Percentage Error (MAPE)**
 - Ideja ove metrike je da bude osjetljiva na relativne pogreške

$$MAPE(y, \hat{y}) = \frac{1}{n_{samples}} \sum_{i=0}^{n_{samples}-1} \frac{|y_i - \hat{y}_i|}{\max(\epsilon, |y_i|)}$$

Metrike performansi za regresiju

- R² score, koeficijent određivanja
 - Može se razumjeti kao standardizirana verzija MSE-a, za bolju interpretaciju performansi modela
 - Predstavlja udio varijance u y koji je objašnjen nezavisnim varijablama u modelu
 - Što je vrijednost veća, model je bolji
 - Najbolji mogući rezultat je 1.0 i može biti negativan

$$R^2(y, \hat{y}) = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}$$

$$\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$$

Underfitting i Overfitting

Polinomska regresija vs. Linearna regresija

- Primjer: želimo sustav koji može procijeniti cijenu automobila na temelju atributa: marka, godina proizvodnje, cijena novog vozila, tip motora, prijeđena kilometraža, potrošnja i sl.
- Zbog jednostavnosti, koristi se samo jedna ulazna varijabla – npr. kilometraža


- Model je oblika:

$$\hat{y}^{(i)} = h(\mathbf{x}^{(i)}) = \Theta_0 + \Theta_1 x$$

gdje su θ_0 i θ_1 parametri koje treba naučiti odnosno odrediti iz dostupnih podataka (ovo je primjer LINEARNE REGRESIJE)

- Do parametara je moguće doći minimizacijom kriterijske funkcije (ona zapravo ukazuje na veličinu pogreške procjene)

Polinomska regresija




- Na raspolaganju imamo mjerenja - crvene x-ice kao ulazne podatke, a želimo doći do nekog generalnog modela ovisnosti cijene o prijedenoj kilometraži
 - Zašto nam to treba?
 - Zanima nas kolika bi bila cijena za neku kilometražu koju nemamo u dostupnom skupu ulaznih podataka
- Početna ideja → pokušamo pomoću polinoma 1. reda (linearna funkcija) doći do generalnog modela

$$\hat{y}^{(i)} = h(\mathbf{x}^{(i)}) = \Theta_0 + \Theta_1 x$$

- Želimo što jednostavniji model, ali...
- Prilična pogreška na mjernim podacima

Polinomska regresija




- Sljedeći korak → moguće je uzeti funkciju višeg reda kao aproksimacijsku funkciju (kao npr. kvadratnu)

$$\hat{y}^{(i)} = h(\mathbf{x}^{(i)}) = \Theta_0 + \Theta_1 x + \Theta_2 x^2$$

- Kako se red polinoma povećava, pogreška na skupu za učenje opada
- Što se događa ako koristim polinom još višeg reda, npr. 6. reda?

Polinomska regresija



- Polinom 6. reda daje nabolju aproksimaciju na ulaznim (trening) podacima
 - No, je li on i doista najbolji?
- Polinom 6. reda dovodi do savršenog prolaska kroz točke (zbog dovoljnog broja trening podataka na raspolaganju), no vrlo je malo vjerojatno da je stvarna krivulja tog oblika
- Krivulja 2. reda bolje ukazuje na trend u ovim trening podacima nego krivulja 6. reda

Zaključak...

- Kako se red polinoma povećava, pogreška na skupu za učenje opada
- Međutim, polinom visokog reda prati individualne podatke jako dobro, umjesto da aproksimira generalni trend koji postoji u podacima
 - Podsjetnik: mi imamo na raspolaganju ograničen skup podataka pri samom treniranju modela, u odnosu na sve moguće podatke za koje želimo stvoriti model
- Ovo implicira da treba biti oprezan kada se radi fino podešavanje kompleksnosti modela → kompleksnost hipoteze/modela treba biti što sličnija kompleksnosti funkcije koja je generirala podatke
- Ovdje dolazimo do vrlo bitnih pojmova
 - UNDERFITTING
 - OVERFITTING

Podusklađivanje ili Underfitting

- Ako je model manje kompleksnosti od generirajuće funkcije – događa se podusklađivanje na podatke (engl. *underfitting*)
 - Npr. pokušavamo *fitati* pravac na podatke dobivene od polinoma trećeg reda
 - U takvom slučaju povećanjem kompleksnosti smanjuje se i pogreška na skupu podataka za učenje


$$y(x, \Theta) = \theta_0 + \theta_1 x + \theta_2 x^2 + \dots + \theta_M x^M = \sum_{j=0}^M \theta_j x^j$$

Pretjerano usklađivanje ili Overfitting

- Međutim, ako je model presložen za dani problem, trening podaci nisu dovoljni kako bi ga ograničili, što može rezultirati u lošim modelom
 - Događa se pretjerano usklađivanje na podatke (engl. *overfitting*)
 - Npr. kod regresije fitanje polinomom 9. stupnja na podatke dobivene iz kvadratne, kubne ili neke druge ovisnosti reda nižeg od 9.
- U potonjem problemu povećanje broja podataka može pomoći, ali samo do određene granice

Underfitting & Overfitting - primjer

- Objasnimo *underfitting* i *overfitting* na primjeru polinomske regresije
 - Zelena krivulja predstavlja idealnu krivulju nekog procesa kojeg mi želimo modelirati, a plavi kružići su dostupni podaci skupa za treniranje modela




- Npr. odabrali smo polinomni model
- Treba nakon toga odabrati red polinoma M


$$y(x, \theta) = \theta_0 + \theta_1 x + \theta_2 x^2 + \dots + \theta_M x^M = \sum_{j=0}^M \theta_j x^j$$

Underfitting & Overfitting - primjer


0th Order Polynomial




1st Order Polynomial




3rd Order Polynomial




9th Order Polynomial



Underfitting & Overfitting - primjer



Pogreška vs. Kapacitet modela




Odabir modela i generalizacija

- Generalizacijska sposobnost nekog modela može se izmjeriti na temelju podataka koji nisu korišteni u procesu učenja → validacijski skup podataka
- Obično se dostupni skup podataka podijeli u skup podataka za treniranje i validacijski skup za testiranje generalizacijskih sposobnosti
- Uz pretpostavku da je validacijski skup dovoljno velik, model s danim parametrima koji postiže najbolje performanse na validacijskom skupu smatra se najboljim


Odabir modela i generalizacija

- Faze procesa kod strojnog učenja



Testni skup podataka

- Ako se želi izvijesiti o pogrešci, odnosno kolika je očekivana pogreška najboljeg modela, treba se koristiti novi skup podataka – testni skup podataka
- Naime, budući da je validacijski skup podataka korišten za odabir najboljeg modela, on je time efektivno postao dio skupa za učenje



Testni skup podataka

- **Analogija iz naših života – pohađanje nastave:**
 - Na predmetu nastavnik rješava primjere što predstavlja skup podataka za učenje
 - Ispitna pitanja su validacijski set
 - Problemi koje polaznik nastave rješava kasnije u profesionalnom životu su testni skup podataka
- Osim toga, ne možemo stalno imati jednaku podjelu na skup za učenje i validacijski skup (kao kada nastavnik daje svake godine iste ispite – studenti će to shvatiti i samo će te zadatke naučiti; neće se zamarati sa cijelim gradivom)

P i t a n j a ?