

Nadzirano učenje - klasifikacija



Sadržaj

- Binarna klasifikacija
- Učenje više klasa (više-klasna klasifikacija)
- Logistička regresija za rješavanje problema klasifikacije
 - Linearni klasifikator slika
- Metrike za evaluaciju klasifikacijskih modela

Nadzirano učenje – binarna klasifikacija

- Razmatrat će se problem nadziranog učenja i to na jednostavnom primjeru učenja klase na temelju pozitivnih i negativnih podatkovnih primjera
- Binarna klasifikacija
 - Podatkovni primjer pripada u jednu od dvije moguće klase
 - Primjer – Klasifikacija „Spam“ ili „Not spam“
 - Navedite primjere binarne klasifikacije kada je ulaz:
 - Digitalna slika, zvuk, razne numeričke veličine (npr. podaci o osobi), tekst
 - Kako se kodira izlazna (ciljna) veličina?



Nadzirano učenje – višeklasna klasifikacija

- Višeklasna klasifikacija
 - Podatkovni primjer pripada u jednu od nekoliko mogućih klasa
 - Primjer – Klasifikacija rukom pisanih znamenki




- Navedite nekoliko primjera višeklasne klasifikacije kada je ulaz:
 - Digitalna slika, zvuk, razne numeričke veličine (npr. podaci o osobi), tekst
- Kako se kodira izlazna (ciljna) veličina?

Logistička regresija za rješavanje problema binarne klasifikacije

Jednostavan problem binarne klasifikacije

- Fokus je trenutno na binarnoj klasifikaciji, $y \in \{0,1\}$
- Kako odvojiti dane primjere?
- Kako biste vi definirali klasifikator?



Odabir klasifikacijskog algoritma

- Odabir prikladnog klasifikacijskog algoritma za neki problem zahtijeva poznavanje algoritama, praksu i iskustvo
 - Algoritmi imaju nekakve pretpostavke
 - Neki su pogodniji za određeni tip problema i sl.
- Pojednostavljeno, glavni koraci prilikom nadziranog učenja (pa i kod rješavanja problema binarne klasifikacije) jesu:
 - Priprema podatkovnog skupa za učenje i skupa za testiranje
 - Odabir modela i pripadne kriterijske funkcije
 - Optimizacijski postupak
 - Evaluacija performansi modela (vrjednovanje modela)

Linearna regresija kao klasifikator?

- Trenutno u potpunosti poznajemo linearnu regresiju pa ćemo nju pokušati primijeniti na problem binarne klasifikacije (ali pojednostavljen, samo s jednom ulaznom veličinom)


- Primjer:** na temelju trajanja konekcije na web stranici (*session duration*), treba odrediti hoće li korisnik napraviti pretragu ili ne

- Podaci su linearno separabilni

- Model je oblika


$$\hat{y}(x) = h_{\theta}(x^{(i)}) = \Theta_0 + \Theta_1 x$$

- Ako je $h_{\theta}(x) \geq 0.5$ dodijeljuje se klasa "1" ili "Da", u suprotnom "0" ili "Ne"



Linearna regresija kao klasifikator?

- Međutim, ako se pojavi odudarajuća (stršeća) vrijednost (engl. *outlier*), klasifikator daje pogrešnu klasifikaciju za neke uzorke iz skupa za učenje premda je skup podataka za učenje linearno odvojiv
- Zašto ovako izgleda granica odluke?
- Što napraviti?




Logistička regresija kao klasifikator?



- Kako bi se povećala robusnost linearne regresije kao klasifikatora, ona se koristi „zajedno” s logističkom funkcijom:
- Ideja - koristiti logističku funkciju na način:

$$h_{\theta}(\mathbf{x}) = g(\Theta^T \mathbf{x}) \quad \text{gdje je} \quad g(z) = \frac{1}{1 + e^{-z}}$$

- Premda je model nelinearan, on predstavlja linearnu granicu u ulaznom prostoru
- $h_{\theta}(\mathbf{x})$ ograničena na interval $[0,1]$
derivabilna funkcija




Logistička regresija kao klasifikator?



- Ovakva bi granica odluke ona dva pogrešna crvena podatka s prošlog slajda svrstala ispravno

Logistička regresija kao klasifikator?

- Kako je definirana granica odluke?
- Kolike su vrijednosti za primjere koji su daleko od granice odluke?
- Što se događa ako mijenjamo prag odluke?






Logistička regresija za rješavanje problema višeklasne klasifikacije

Logistička regresija za višeklasnu klasifikaciju

- Često postoji više klasa:
 - Analiza sentimenta komentara: pozitivan, negativan, neutralan
 - Predikcija vremena: vruće, hladno, kišovito, maglovito, ...
- U slučaju $K > 2$, postoje dvije strategije:
 - **"jedan naspram ostalih"** (engl. *one-vs-rest*) ili OVR
 - Potrebno je izgraditi K binarnih klasifikatora, svaki je između C_k i ostatka
 - **"jedan naspram jedan"** (engl. *one-vs-one*) ili OvO
 - Potrebno je izgraditi $K(K-1)/2$ binarnih klasifikatora, svaki klasifikator razdvaja dvije klase

Logistička regresija za višeklasnu klasifikaciju

- Obje metode (OVR i OVO) su nedorečene jer postoje dijelovi za koje nije jasno kojoj klasi pripadaju
- Kako dobiti u oba slučaja konačnu predikciju?



$$h_{\theta}^{(k)}(\underline{x}) = p(y=k | \underline{x}, \theta)$$
$$k = 1, 2, \dots, K$$
$$\max_k h_{\theta}^{(k)}(\underline{x})$$

Samostalno skicirajte OvO pristup

Višeklasna klasifikacija

- Primjer: klasifikacija objekata detektiranih prednjom kamerom na vozilu



C_1 -auto



C_2 -kamion




C_3 -znak

...

...

...

...



C_9 -pješak



C_{10} -semafor

- Kodiranje izlazne veličine najčešće se provodi pomoću 1-od-K kodiranja:

$$x \in C_1 \quad y = (1, 0, 0, \dots, 0, 0, 0)$$

$$x \in C_2 \quad y = (0, 1, 0, \dots, 0, 0, 0)$$


$\vdots$

$$x \in C_{K-1} \quad y = (0, 0, 0, \dots, 0, 1, 0)$$

$$x \in C_K \quad y = (0, 0, 0, \dots, 0, 0, 1)$$

Linearni klasifikator slika/objekata

- Primjer: klasifikacija objekata detektiranih prednjom kamerom na vozilu



Linearni klasifikator slika/objekata

- x je stupac vektor s 3072 reda (3072×1)
- W je matrica dimenzija 10×3072 (to su parametri modela koji se žele odrediti)
- b se naziva *bias* i ima dimenzije 10×1 (isto parametri modela)
- Nakon provedene operacije s prethodnog slajda (na ulaznoj slici), na izlazu će se dobiti vektor od 10 vrijednosti (dimenzije 10×1)
 - Npr. ako je vrijednost na 3. mjestu u tom vektoru najveća (npr. 0.1, 0.2, 300, 7, ... 0.8) → znak
 - Npr. ako je vrijednost na 1. mjestu u tom vektoru najveća (npr. 563, 38, 10, 7, ... 0.8) → auto
- Ovo se naziva ELEMENTARNI LINEARNI KLASIFIKATOR
- Predstavlja prvi korak ka dubokom učenju (engl. *Deep Learning* – DL)

Linearni klasifikator slika/objekata


- U ovom primjeru imamo 10 klasa (VIŠEKLASNA KLASIFIKACIJA), a 3072 ulazne varijable
 - Radi se o 3072-dimenzionalnom prostoru – toliko imamo ulaznih veličina
- Model je linearan (linearne operacije s matricama i vektorima)
- Model dobiven strojnim učenjem bi nam u ovom slučaju trebao reći što je rješenje i kolika je vjerojatnost da je to točno rješenje

Logistička regresija. *Softmax* klasifikator

- Funkcija koja daje rezultat $s = f(x_i; W)$
- Za linearni klasifikator funkcija koja daje rezultat je $s = f(x; W) = Wx$
 - Zanemarili smo b (*bias*) u ovom trenutku (ne igra nam ulogu)

- Vjerojatnost pripadania klasi k ($k = 1, \dots, 10$ u našem primjeru)

$$P(Y = k | X = x_i) = \frac{e^{s_k}}{\sum_j e^{s_j}} \quad \rightarrow \text{Soft funkcija}$$



Logistička regresija. *Softmax* klasifikator

- Linearni klasifikator + *Softmax* funkcija (koja nije linearna funkcija)
- Ako imam na izlazu vektor
 - $(0,0,1,0,0,0,0,0,0)^T \rightarrow$ rezultat je jasan
 - $(0.1, 0.15, 0.15, 0.1, 0.15, 0.15, 0.05, 0.05, 0.05, 0.05)^T \rightarrow ???$
- **Strojno učenje $\rightarrow$ iterativni postupak $\rightarrow$ treniranje parametara**
 - Vježbe
 - Gdje je inteligencija razmatranog sustava ?
 - W
 - *Softmax* samo daje vjerojatnost klase na izlazu
- **Kako doći do parametara W ? Kako se oni istreniraju?**


Logistička regresija. *Loss function & trening*

- Vjerojatnost pripadanja klasi k

$$P(Y = k|X = x_i) = \frac{e^{s_k}}{\sum_j e^{s_j}}$$

- Umjesto da se maksimizira log vjerojatnosti, minimizira se negativni log vjerojatnosti ispravne klase

$$L_i = -\log P(Y = y_i|X = x_i)$$




Logistička regresija. *Loss function & trening*

- Krećemo od nekog sasvim slučajnog W - odaberemo parametre potpuno slučajno (slično kao što smo Θ_0 i Θ_1 ranije slučajno birali)
- Dobijemo neke rezultate na izlazu
 - Nećemo sigurno u prvom koraku dobiti točne rezultate s velikom pouzdanošću
- Što dalje radimo?
 - Za vrijeme treninga znamo koja je klasa za ulaznu sliku (**nadzirano učenje**)
 - Ako je na ulazu auto (C_1), znamo da idealni izlazni vektor treba biti (1,0,0,0,0,0,0,0,0,0)
 - Na osnovu vektora koji smo dobili nakon prvog koraka (upotrebom trenutnog klasifikatora) i idealnog vektora za koji znamo kako treba izgledati, pronađemo grešku
 - Ta se greška koristi da bi se **gradijentnom metodom** mijenjali koeficijenti u matrici W

(sjetite se koliko smo parametara trenirali u primjerima spomenutim do sada !!!)

Logistička regresija. *Loss function & trening*

- Razmotrimo primjer rezultata nakon prvog koraka ... (radi jednostavnosti proračun samo za 3 klase, a ne za 10)



Logistička regresija. *Loss function & trening*

- Auto 13%, pješak 87 %, semafor 0 % $\rightarrow$ nije dobro istrenirano (početni W)
- Međutim mi znamo da je na ulazu auto $\rightarrow -\log(0.13) = 0.89$
 - Da je na izlazu umjesto 0.13 pisalo 1, koliko bi iznosilo $-\log(1.0)$?
 - Greška bi bila 0 !
- Na osnovu tih rezultata treniramo W (minimiziramo grešku)
 - Mnoštvo iteracija ne velikom skupu podataka

Pristup vođen podacima

1. Skupiti bazu podataka slika i poznatih rezultata (labela) – npr. 50000 slika
2. Koristiti strojno učenje da se istrenira klasifikator
3. Ocijeniti klasifikator pomoću novog skupa slika - npr. 10000 novih slika

Naziv detektora	Primjeri slika korištenih prilikom procesa učenja		
Detektor prednje i stražnje strane automobila			
Detektor bočne strane automobila			

Pristup vođen podacima

1. Skupiti bazu podataka slika i poznatih rezultata (labela) – npr. 50000 slika
2. Koristiti strojno učenje da se istrenira klasifikator
3. Ocijeniti klasifikator pomoću novog skupa slika - npr. 10000 novih slika

Detektor prednje i stražnje strane autobusa i kamiona			
Detektor prometnih znakova opasnosti			
Detektor prometnih znakova izričitih naredbi koje karakterizira plava pozadina			
Detektor prometnih znakova izričitih naredbi koje karakterizira crveni rub			

Detektor prometnog znaka obveznog zaustavljanja			
Detektor prometnog znaka raskrižja s cestom koja ima prednost prolaska			
Detektor pješaka			
Detektor semafora			

Metrike za evaluaciju klasifikacijskih modela

Pojasnit ćemo sljedeće pojmove...

- Intersection over Union (IoU)
- Točnost
- Pogreška
- Specifičnost
- Preciznost
- Odziv
- F1
- Matrica zabune

Što je granični okvir (BB) ? Što je IoU?

- Prisjetimo se...
- Mjera kvalitete detekcije objekta → ***Intersection over Union (IoU)***
- BB_{gt} - površina stvarnog graničnog pravokutnika (engl. *ground truth*)
- BB_p – površina detektiranog graničnog pravokutnika

$$IoU = \frac{površina(BB_{gt} \cap BB_p)}{površina(BB_{gt} \cup BB_p)} \text{ tj.}$$



$IoU = 0.7$



$IoU = 0.95$

Što je granični okvir (BB) ? Što je IoU?

- Izlaz iz modela je predviđeni granični pravokutnik (engl. *Predicted*)
- Stvarni granični pravokutnik je ručno označen na slici (tijekom prikupljanja podataka)
- U praksi je vrlo mala vjerojatnost da će se predviđeni upotpunosti poklapati sa stvarnim graničnim pravokutnikom



- Uobičajene vrijednosti za detekciju:
 - $\text{IoU} \geq 0.5$
 - $\text{IoU} \geq 0.6$
 - $\text{IoU} \geq 0.75$



$\text{IoU} = 0.7$



$\text{IoU} = 0.95$

Matrica zabune (Engl. *Confusion matrix*)

- Tehnika mjerenja performansi klasifikacije kod strojnog učenja
- Tablica/Matrica koja ukazuje na rezultate klasifikacijskog modela zasnovanog na strojnom učenju na skupu podataka za koji su nam poznate prave vrijednosti

		Actual	
		Positive	Negative
Predicted	Positive	True Positive	False Positive
	Negative	False Negative	True Negative


Što su TP, FP, FN, TN kod detekcije objekata?

- TP – *true positive*, detekcije koje su proglašene objektom, a one to jesu
- FP – *false positive*, detekcije koje su proglašene objektom, a one to nisu
- FN – *false negative*, detekcije koje nisu proglašene objektom, a one to jesu
- TN – *true negative*, detekcije koje nisu proglašene objektom, a one to nisu

		Actual	
		Positive	Negative
Predicted	Positive	True Positive	False Positive
	Negative	False Negative	True Negative

Što su TP, FP, FN, TN ?

- Zašto su prikazane detekcije na slici označene kao FP i FN?
- Imamo li koji TP na slici?
- Imamo li koji TN na slici?



Točnost

- Točnost (engl. *Accuracy*) - definira se kao

$$točnost = \frac{TP + TN}{TP + FP + FN + TN}$$

- Što nam kaže ova mjera?
 - Od svih predviđanja modela, koliko ih je bilo točno (*true*)?
- U kojem se rasponu može kretati ova mjera?
- Ne bi ju trebalo koristiti na neuravnoteženim skupovima, npr.

		Predicted/Classified	
		Negative	Positive
Actual	Negative	998	0
	Positive	1	1

Kolika je točnost?

→ 99.9%

Pogreška

- Pogreška (engl. *Error*) - definira se kao

$$\textit{pogreška} = \frac{FP + FN}{TP + FP + FN + TN}$$

ili kao

1 - Točnost

- Što nam kaže ova mjera?
 - Od svih predviđanja modela, koliko ih je bilo pogrešnih (*false*)?
- U kojem se rasponu može kretati ova mjera?

Specifičnost

- Specifičnost - definira se kao

$$\textit{specifičnost} = \frac{TN}{TN + FP}$$

- Što nam kaže ova mjera?
 - Od svih stvarno negativnih vrijednosti, koliki je postotak točno predviđenih negativnih vrijednosti
- U kojem se rasponu može kretati ova mjera?

Preciznost

- Preciznost (engl. *Precision*) - definira se kao

$$\textit{preciznost} = \frac{TP}{TP + FP}$$

- Što nam kaže ova mjera?
 - Od svih primjera koji su modelom predviđeni kao pozitivni, koliko je detekcija bilo korektno?
- U kojem se rasponu može kretati ova mjera?

Odziv

- Odziv (engl. *Recall*), često se naziva i Osjetljivost (engl. *Sensitivity*)—definira se kao

$$\text{odziv} = \frac{TP}{TP + FN}$$

- Što nam kaže ova mjera?
 - Od svih stvarnih pozitivnih primjera koje sam trebao detektirati, koliko ih je odabrani model detektirao?
- U kojem se rasponu može kretati ova mjera?

F1 mjera


- F1 mjera – definira se kao harmonijska sredina preciznosti i odziva

$$F1 = 2 * \frac{\textit{preciznost} * \textit{odziv}}{\textit{preciznost} + \textit{odziv}}$$

- Kada je potreban balans između preciznosti i odziva
- U kojem se rasponu može kretati ova mjera?

Prag klasifikatora – kako utječe na preciznost/odziv?

- Vrijednosti preciznosti i odziva ovisi o korištenom pragu klasifikatora
- Primjer prikazuje 30 predikcija email klasifikatora
 - Desno od granice klasifikator predviđa kao spam; lijevo not spam (regularni email)




$$\text{Precision} = \frac{TP}{TP + FP} = \frac{8}{8 + 2} = 0.8$$

$$\text{Recall} = \frac{TP}{TP + FN} = \frac{8}{8 + 3} = 0.73$$

Prag klasifikatora – kako utječe na preciznost/odziv?

- Ako se poveća prag klasifikatora:



$$\text{Precision} = \frac{TP}{TP + FP} = \frac{7}{7 + 1} = 0.88$$

$$\text{Recall} = \frac{TP}{TP + FN} = \frac{7}{7 + 4} = 0.64$$

Preciznost se povećava s povećanjem praga, odziv se smanjuje!

Što nam je bitnije? Preciznost ili odziv?

- Idealan scenarij – visoka preciznost i visoki odziv
 - Često je to teško postići

$$\textit{preciznost} = \frac{TP}{TP+FP}$$

$$\textit{odziv} = \frac{TP}{TP+FN}$$

- **Praktične aplikacije – što je bitnije? Visoka preciznost ili visoki odziv?**
 - Kad si ne smijemo priuštiti da imamo FN (kad ne želimo propustiti velik broj detekcija), onda dajemo prednost visokom odzivu
 - Kad si ne smijemo priuštiti da imamo FP (kad ne želimo imati neispravne detekcije), onda dajemo prednost visokoj preciznosti

Što nam je bitnije? Preciznost ili odziv?

Realni slučajevi...

- Medicinski testovi (npr. detekcija raka) – Što je bitnije? Visoka preciznost ili visoki odziv?
 - Visoki odziv. Zašto?
 - Bolje je klasificirati zdravu osobu kao osobu koja ima rak (lažno pozitivno) i poslati ju na dodatne medicinske testove, ali definitivno nije prihvatljivo propustiti identificirati bolesnika s rakom tj. klasificirati pacijenta s rakom kao zdravog (lažno negativnog), budući da život te osobe je u pitanju.

Što nam je bitnije? Preciznost ili odziv?

Realni slučajevi...

- Sustavi za preporuku (npr. TV sadržaja za gledanje) – Što je bitnije? Visoka preciznost ili visoki odziv?
 - Visoka preciznost. Zašto?
 - Bolje je propustiti preporučiti nešto što bi gledatelj inače volio pogledati, a da pritom ono ostalo što se preporuči bude interesantno gledatelju. Ako mu preporučate sve i svašta uključujući i ono što se njemu ne sviđa (FP), on neće vaš sustav za preporučivanje doživljavati kao uspješan.

Što nam je bitnije? Preciznost ili odziv?

Realni slučajevi...

- Predviđanje pogodnog dana u smislu vremenskih uvjeta za lansiranje satelita – Što je bitnije? Visoka preciznost ili visoki odziv?
 - Visoka preciznost. Zašto?
 - Bolje je propustiti predvidjeti dobro vrijeme, jer loše predviđanje vremena određenog dana (FP) može biti katastrofalno za lansiranja satelita.

Što nam je bitnije? Preciznost ili odziv?

Realni slučajevi...

- Osuda na smrtnu kaznu – Što je bitnije? Visoka preciznost ili visoki odziv?
 - Visoka preciznost. Zašto?
 - Bolje je propustiti nekog kazniti smrtnom kaznom, nego na smrt osuditi nevinu osobu (FP).

Što nam je bitnije? Preciznost ili odziv?

Realni slučajevi...

- Detekcija spam e-mailova – Što je bitnije? Visoka preciznost ili visoki odziv?
 - Visoka preciznost. Zašto?
 - Bolje je propustiti detektirati neki e-mail kao spam nego neki bitan e-mail poslati u spam mapu (FP).

Što nam je bitnije? Preciznost ili odziv?

Realni slučajevi...

- Izdavanje kredita određenom klijentu – Što je bitnije? Visoka preciznost ili visoki odziv?
 - Visoka preciznost. Zašto?
 - Bolje je propustiti klasificirati pogodnog klijenta za kredit, nego kredit dati nekom tko je loš klijent (FP) i vjerojatno nikada neće vratiti kredit.

Što nam je bitnije? Preciznost ili odziv?


Realni slučajevi...

- Detekcija lažnih transakcija – Što je bitnije? Visoka preciznost ili visoki odziv?
 - Visoki odziv. Zašto?
 - Bolje je propustiti klasificirati ispravnu transakciju kao lažnu – to se uvijek može provjeriti dodatnim provjerama. Ali nije prihvatljivo klasificirati lažnu transakciju kao ispravnu (FN).

ROC krivulja (engl. Receiver Operating Characteristic)


- Mijenja se prag klasifikatora i računaju se vrijednosti TPR i FPR
- Klasifikator je učinkovitiji što je veća površina ispod krivulje (eng. *Area Under Curve* – AUC)

$$TPR = \frac{TP}{TP + FN}$$
$$FPR = \frac{FP}{FP + TN}$$



Preciznost odziv krivulja (engl. *precision-recall curve*)

- Mijenja se prag klasifikatora i računaju se vrijednosti preciznosti i odziva
- Često se koristi za usporedbu dvaju modela
- Prikladnija za nebalansirane skupove podataka (jer se fokusira samo na pozitivnu klasu)



Metrike za evaluaciju klasifikacijskih modela

- Kako ćemo pristupiti u slučaju višeklasne klasifikacije budući da su sve navedene metrike izvedene u slučaju binarnog klasifikacijskog problema?
- Idemo pokušati analizirati primjer s trima klasama i izračunati
 - Točnost
 - Prosječna preciznost, odziv i F1 mjera

Matrica zabune...primjer

- Npr. naš model strojnog učenja ima za zadatak klasificirati 300 slika vozila u tri skupine – automobil, kombi, kamion
- Neka je naš model dao sljedeće rezultate prikazane u obliku matrice zbunjenosti
 - Stupac – rezultat klasifikatora
 - Redak – ispravna klasa

	Automobil	Kombi	Kamion
Automobil	79	19	2
Kombi	25	70	5
Kamion	1	1	98

Matrica zabune

- Stupac – rezultat klasifikatora
- Redak – ispravna klasa

	Automobil	Kombi	Kamion
Automobil	79	19	2
Kombi	25	70	5
Kamion	1	1	98

- Razmotrimo za klasu Automobil TP, TN, FP i FN vrijednosti...
- Za Automobil bi bile sljedeće vrijednosti
 - $TP = 79$
 - $TN = (70+5)+(1+98) = 174$
 - $FP = 25 + 1 = 26$
 - $FN = 19 + 2 = 21$
- Sada možemo lako izračunati sve mjere koje smo do sada naučili za klasu Automobil

Matrica zabune

- Stupac – ispravna klasa
- Redak – rezultat klasifikatora

	Automobil	Kombi	Kamion
Automobil	79	19	2
Kombi	25	70	5
Kamion	1	1	98

- **Samostalno izračunajte sve mjere za ostale klase**
- Na kraju možemo izračunati srednje mjere (sve koje znamo) za sve 3 klase zajedno, npr.
 - Pogreška (Automobil) = 0,15667
 - Pogreška (Kombi) = 0,16667
 - Pogreška (Kamion) = 0,03
 - Ukupna pogreška je prosjek te tri vrijednosti → 0,11778

P i t a n j a ?