

Nenadzirano učenje – smanjivanje dimenzionalnosti



Sadržaj

- Nenadzirano učenje
 - Smanjivanje dimenzionalnosti podataka
 - Analiza glavnih komponentata (PCA)

Nenadzirano učenje

Nenadzirano učenje

- Nenadzirano učenje (engl. *unsupervised learning*) je vrsta strojnog učenja gdje je cilj izvući zaključke o raspoloživom skupu podataka koji se sastoji samo od ulaznih veličina, bez odgovarajuće izlazne veličine (npr. otkriti interesantna svojstva)
 - Mogu li se otkriti grupe u podacima?
 - Može li se otkriti skrivena struktura u podacima?
 - Mogu li se podaci predstaviti na drugačiji način?
 - Mogu li se podaci efikasno komprimirati?
- Za mjerni uzorak ulaznih veličina ne postoji odgovarajući izlaz pa se učenje naziva „nenadzirano”
- Dva najvažnija problema nenadziranog učenja:
 - Smanjivanje dimenzionalnosti (engl. *dimensionality reduction*)
 - Grupiranje podataka (engl. *clustering*)


Smanjivanje dimenzionalnosti podataka

Smanjivanje dimenzionalnosti podataka

- Kod izgradnje modela nadziranim učenjem (klasifikacija ili regresija) pretpostavljamo da ulazni podaci sadrže informacije od interesa (za sustav koji donosi odluku)
- Idealno, nije potrebno raditi
 - odabir ulaznih varijabli ili
 - izvlačenje značajki

kao zaseban proces u okviru učenja, model bi sam trebao koristiti samo značajke koje su korisne dok bi trebao odbaciti irelevantne


Nadzirano učenje



Smanjivanje dimenzionalnosti podataka

- Međutim, postoje različiti razlozi iz kojih bismo htjeli smanjiti dimenzionalnost ulaznih podataka u okviru posebnog koraka
- Korak predobrade (engl. *preprocessing*) – dolazi nakon skaliranja

Nadzirano učenje – u praksi



Smanjivanje dimenzionalnosti podataka

- Razlozi za smanjivanje dimenzionalnosti ulaznih podataka:
 1. Kod većine algoritama kompleksnost raste s porastom broja ulaznih veličina kao i s porastom veličine skupa za učenje; kako bi se smanjili memorijski i računalni zahtjevi potrebno je smanjiti dimenzionalnost problema (smanjena ulazna dimenzionalnost smanjuje i kompleksnost izračuna kod eksploatacije modela)
 2. Jednostavniji modeli su robusniji na manjim skupovima podataka. Imaju manju varijancu tj. manje ovise o specifičnom skupu podataka uključujući šum, stršće vrijednosti (*outliere*) itd.
 - ako izbacimo neke podatke iz trening skupa, model se neće puno promijeniti, dok se složeni model sve više prilagođava podacima koji su ostali u skupu

Smanjivanje dimenzionalnosti podataka

- Razlozi za smanjivanje dimenzionalnosti ulaznih podataka:
3. Kada se podaci mogu opisati s manje značajki (engl. *feature*), onda možemo dobiti i bolju ideju o procesu koji je generirao podatke i moguća je ekstrakcija znanja. Ove varijable mogu se interpretirati i kao skrivene ili latentne varijable (faktori) čijom se kombinacijom dobivaju opaženi podaci
 4. Kada se podaci mogu prikazati u nekoliko dimenzija, bez značajnog gubitka informacije, onda se mogu i prikazati grafički (preko grafičkih prikaza se može analizirati struktura podataka, detektirati *outlieri* i sl.)

Odabir/Izvlačenje značajki

- Kod ODABIRA ZNAČAJKI (ulaznih veličina) pokušava se odrediti k značajki od ukupno d na način da nam tih k značajki donosi većinu informacija o problemu, a preostalih $(d-k)$ se odbacuju
- Npr. odabir podskupa značajki (engl. *subset selection*)
 - Spada u grupu nadziranog učenja jer se koristi zajedno s algoritmom nadziranog učenja
- Kod IZVLAČENJA ZNAČAJKI pokušava se pronaći novi skup značajki veličine k koji se dobiva kombinacijom d originalnih značajki
- Najpoznatija metoda za izvlačenje značajki je ANALIZA GLAVNIH KOMPONENTATA (engl. *Principal Component Analysis-PCA*)
 - Pripada grupi nenadziranog učenja


Analiza glavnih komponentata

(Principal Component Analysis -PCA)

Analiza glavnih komponentata (PCA)

- Analiza glavnih komponentata (PCA) je vrlo popularna metoda za smanjivanje dimenzionalnosti podataka
- Pripada grupi metoda koje provode projekciju ulaznog prostora iz originalnog prostora dimenzije d u novi (niže-dimenzionalni) prostor dimenzije k **na način da se što je moguće više informacija preslika iz originalnog u novi prostor**
- Pripada nenadziranom učenju jer kod određivanja smjerova projekcije ne koristi informacije o nekoj izlaznoj veličini – kriterij je maksimizirati varijancu u novom prostoru (odrediti smjer u kojem se podaci najviše „raspršuju“ – pogledati sljedeći slajd)

Analiza glavnih komponentata (PCA)




Analiza glavnih komponentata (PCA)

- Metoda je korisna kada su podaci izrazito korelirani (slični) pa se ulazni prostor može prikazati s manjim brojem veličina koje opisuju većinu varijacija u ulaznom prostoru
- Smjerovi projekcije se nazivaju glavne komponente (engl. *principal components*) – smjerovi u kojima je prisutno najviše varijacija
- Razmotrimo dva primjera gdje se koristi PCA
 - Detekcija ljudskog lica koristeći PCA (nadzor vozača)
 - Klasifikacija vozila koristeći PCA (prednja/bočna/stražnja kamera u vozilu)

PCA – Detekcija ljudskog lica


- Na raspolaganju imamo skup slika lica
- Ideja – napraviti PCA i vidjeti možemo li smanjiti dimenzionalnost podataka tj. reducirati količinu korisnih podataka
- Svaka slika je zapisana u vektor Γ_i
 - Ako je slika 32x32 elementa slike $\rightarrow$ 1024 elementa
 - Složeni u stupčasti vektor
- Izračunati „srednje lice“ pomoću trening skupa

$$\Psi = \frac{1}{M} \sum_{i=1}^M \Gamma_i$$



PCA – Detekcija ljudskog lica

- „Srednje lice“ dobiveno pomoću trening skupa



PCA – Detekcija ljudskog lica

- Oduzeti vektor „srednjeg lica“ od svakog lica iz trening skupa

$$\Phi_i = \Gamma_i - \Psi$$

- Za svako lice iz trening skupa dobili smo njegovu razliku u odnosu na „srednje lice“
- Izračunati **matricu kovarijance** **C** za vektore Φ_i zajedno

$$\mathbf{C} = \frac{1}{M} \sum_{i=1}^M \Phi_i \Phi_i^T$$

- LINEARNA ALGEBRA
 - Matlab/Python (numpy biblioteka)
 - Proračun svojstvenih vrijednosti (λ) i svojstvenih vektora (v) matrice
- Računaju se svojstvene vrijednosti i svojstveni vektori matrice kovarijance C

PCA – Detekcija ljudskog lica – pitanje za vas!

- Ako je naša ulazna slika bila 32x32 piksela → zapisali smo ju u stupčasti vektor Γ_i od 1024 elementa (1024 x 1)

- Kojih je su dimenzija $\Psi = \frac{1}{M} \sum_{i=1}^M \Gamma_i$ i $\Phi_i = \Gamma_i - \Psi$?
 - 1024 x 1**

- Kojih je dimenzija matrica kovarijance ?
 - 1024 x 1024
 - Napomena – C je računata pomoću svih slika lica

$$C = \frac{1}{M} \sum_{i=1}^M \Phi_i \Phi_i^T$$

- Izračunati svojstvene vrijednosti matrice kovarijance C

PCA – Detekcija ljudskog lica

- Izračunati svojstvene vrijednosti matrice kovarijance C
- Svaki svojstveni vektor (*eigenvector*) matrice kovarijance C odgovara jednoj svojstvenoj vrijednosti (*eigenvalue*)
- Svaki svojstveni vektor ima također 1024 elementa kao i ulazna slika
- Činjenica u realnim skupovima podataka (slike, audio,...)
 - Samo vodeći svojstveni vektori (oni koji pripadaju najvećim svojstvenim vrijednostima) nose najvažnije informacije o ulaznim podacima
 - Ostali svojstveni vektori nose manje važne informacije

PCA – Detekcija ljudskog lica

- Samo vodeći svojstveni vektori nose najvažnije informacije o ulaznim podacima
- Ostali svojstveni vektori nose manje važne informacije
- Vizualizacija → izračunati svojstveni vektori se vrata u formu slike → dobiju se *eigenfaces* prikazani desno u formi 2D slike
- Dobiva se nešto što ima karakteristike lica u početku, a kasnije se gubi struktura lica



Srednje lice i prva četiri *eigenfaces*



Eigenfaces 15, 100, 200, 250, 300



Eigenfaces 400, 450, 500, 1024

PCA – Detekcija ljudskog lica

- Kod obrade slike svojstveni se vektori mogu prikazati kao slike i na njih se može gledati kao na „predloške” za važne značajke (značajke koje su generirale dane podatke)
- **Svojstveni vektori slažu se u matricu svojstvenih vektora W prema važnosti**
 - Poredani po retcima ili stupcima
 - Najvažniji svojstveni vektor u prvom retku/stupcu



Srednje lice i prva četiri *eigenfaces*



Eigenfaces 15, 100, 200, 250, 300



Eigenfaces 400, 450, 500, 1024

PCA – Detekcija ljudskog lica

- Kako se konačno dobije podatak smanjene dimenzionalnosti, oznake z_i ???
- Ulazna i-ta slika (vektor) Γ_i

$$\Psi = \frac{1}{M} \sum_{i=1}^M \Gamma_i \quad \Phi_i = \Gamma_i - \Psi$$

$$z_i = W \Phi_i$$



Srednje lice i prva četiri *eigenfaces*



Eigenfaces 15, 100, 200, 250, 300



Eigenfaces 400, 450, 500, 1024

PCA – Detekcija ljudskog lica

- Izračunati svojstveni vektori → što sada?
- **Umjesto memoriranja pune slike kao trening podatka zapravo memoriramo samo ono što dobijemo množenjem prvih N najvažnijih svojstvenih vektora lica (možda 10, 20 ili čak i njih 100) iz matrice svojstvenih vektora W i pune ulazne slike**
- Pitanje za vas:
 - Neka je ulazna slika bila 32x32 elementa slike → vektor (1024 x 1) → Γ_i
 - Neka je nakon izračuna svojstvenih vektora matrice kovarijance odabrano 20 najvažnijih svojstvenih vrijednosti i 20 najvažnijih svojstvenih vektora (maksimalno ih može biti 1024) – ti su vektori dimenzije 1024 x 1
 - Poredamo tih 20 svojstvenih vektora u matricu svojstvenih vektora W po važnosti (npr. prvi redak najvažniji vektor) → ta je matrica W dimenzija 20 x 1024
 - Kojih će dimenzija biti preslikani ulazni podatak „ z_i “ ako ga odlučimo predstaviti samo s tih prvih 20 najvažnijih svojstvenih vektora?

- **20 x 1**

$$z_i = W \Phi_i$$

$$\Phi_i = \Gamma_i - \Psi$$

$$\Psi = \frac{1}{M} \sum_{i=1}^M \Gamma_i$$

PCA – rekonstrukcija podataka

- Može se pokazati da PCA, od svih ortogonalnih linearnih projekcija, minimizira tzv. pogrešku rekonstrukcije odnosno udaljenost između originalnih podataka i njihove rekonstrukcije iz nižedimenzijskog prostora

$$\sum_i \| \mathbf{r}_i - \hat{\mathbf{r}}_i \|^2 \quad \mathbf{z}_i = \mathbf{W} \Phi_i \quad \hat{\mathbf{r}}_i = \mathbf{W}^T \mathbf{z}_i + \Psi$$

- Pitanje za vas – zašto postoji razlika između originalnih podataka i rekonstruiranih ?**
 - Zato što se ne koriste sve svojstvene vrijednosti već samo konačni broj najznačajnijih (koji odgovaraju najvećim svojstvenim vrijednostima)

PCA – kako odabrati broj komponenata?

- Nakon ove linearne transformacije dobiva se k-dimenzionalni prostor čije su osi/dimenzije (glavne komponente) svojstveni vektori
- Koliko svojstvenih vektora (glavnih komponenti) odabrati pri smanjivanju dimenzionalnosti?
 - Kod manje-dimenzionalnih podataka vizualnom analizom obično je moguće detektirati broj komponenata nakon kojeg dodavanje preostalih komponenata značajno ne povećava varijancu ulaznog prostora
 - Drugi pristup je zadržavanje svojstvenih vektora (odnosno glavnih komponenata) koji odgovaraju svojstvenim vrijednostima koje su veće od prosjeka svojstvenih vrijednosti (tj. odbacuju se komponente čije su svojstvene vrijednosti manje od prosječne)


PCA – kako odabrati broj komponenata?

- Koliko svojstvenih vektora (glavnih komponenti) odabrati pri smanjivanju dimenzionalnosti?
- Najčešće se ipak koristi...
- **Omjer objašnjene varijance** (engl. *Explained variance ratio*) - mjera koja se koristi za procjenu koliko varijance u originalnom skupu podataka se može objasniti svakom od odabranih komponenti nakon primjene PCA metode
- Izračun i prikaz omjera objašnjene varijance pojedine svojstvene vrijednosti λ_j je prilično lako izračunati
- To je omjer svojstvene vrijednosti λ_j i ukupnog zbroja svojstvenih vrijednosti

$$\text{Explained variance ratio} = \frac{\lambda_j}{\sum_{j=1}^d \lambda_j}$$

PCA – kako odabrati broj komponenata?


- Potrebno je postaviti prag za odabir (npr. 95%)



$$\text{Explained variance ratio} = \frac{\lambda_j}{\sum_{j=1}^d \lambda_j}$$





PCA – u kojem trenutku predobrade?

- U praksi je obično potrebno skalirati ulazne veličine x_i
- Uobičajena procedura je skaliranje svake ulazne veličine tako da ima srednju vrijednost 0 i jediničnu varijancu (prisjetimo se...) - **standardizacija**
- Na tako skalirane ulazne veličine primjenjuje se PCA algoritam



PCA – pogledajmo još jednom cijeli postupak...

- Primjenu PCA na jednom realnom skupu podataka ljudski lica
 - „[Labelled Faces in the Wild \(LFW\)](#)”
 - **13233 slike rezolucije 64x64 piksela**
 - Kojih je onda dimenzija vektor Γ_i za svaku od slika iz LFW skupa podataka?
 - Odgovor: 4096 x 1
 - Primjeri slika















PCA – pogledajmo još jednom cijeli postupak...

- Nakon provedenog postupka PCA odrede se svojstveni vektori → Kako?
 - Srednje lice, matrica konarijance, svojstvene vrijednosti, svojstveni vektori...
 - Pogledajmo kako izgledaju neki svojstveni vektori za LFW bazu slika kad se prikažu u formi slike...

PCA – pogledajmo još jednom cijeli postupak...

- Pogledajmo kako izgledaju neki svojstveni vektori za LFW bazu slika kad se prikažu u formi slike...



PCA – pogledajmo još jednom cijeli postupak...

- Svojstveni vektori slažu se u matricu svojstvenih vektora W prema važnosti
 - Poredani po retcima ili stupcima
 - Najvažniji svojstveni vektor u prvom retku/stupcu
- Kako se konačno dobije podatak smanjene dimenzionalnosti, oznake z_i ?
- Ulazna i -ta slika (vektor) Γ_i



$$\Psi = \frac{1}{M} \sum_{i=1}^M \Gamma_i \quad \Phi_i = \Gamma_i - \Psi \quad \mathbf{z}_i = \mathbf{W} \Phi_i$$

- Kako se dobije rekonstruirana originalna slika iz slike smanjene dimenzionalnosti?

$$\hat{\Gamma}_i = \mathbf{W}^T \mathbf{z}_i + \Psi$$



PCA – pogledajmo još jednom cijeli postupak...

- Pogledajmo nekoliko primjera...
- Slika zapisana koristeći samo 10 najvažnijih svojstvenih vektora pa rekonstruirana





PCA – pogledajmo još jednom cijeli postupak...

- Pogledajmo nekoliko primjera...
- Slika zapisana koristeći samo 50 najvažnijih svojstvenih vektora pa rekonstruirana





PCA – pogledajmo još jednom cijeli postupak...

- Pogledajmo nekoliko primjera...
- Slika zapisana koristeći samo 100 najvažnijih svojstvenih vektora pa rekonstruirana





PCA – pogledajmo još jednom cijeli postupak...

- Pogledajmo nekoliko primjera...
- Slika zapisana koristeći samo 150 najvažnijih svojstvenih vektora pa rekonstruirana





PCA – pogledajmo još jednom cijeli postupak...

- Pogledajmo nekoliko primjera...
- Slika zapisana koristeći samo 200 najvažnijih svojstvenih vektora pa rekonstruirana





PCA – pogledajmo još jednom cijeli postupak...

- Pogledajmo nekoliko primjera...
- Slika zapisana koristeći samo 250 najvažnijih svojstvenih vektora pa rekonstruirana



PCA – pogledajmo još jednom cijeli postupak...

- Pogledajmo nekoliko primjera...
- Slika zapisana koristeći samo 577 najvažnijih svojstvenih vektora pa rekonstruirana



PCA u scikit-learn biblioteci

- PCA je implementirana u obliku klase:

```
class sklearn.decomposition.PCA(n_components=None, *, copy=True, whiten=False, svd_solver='auto', tol=0.0, iterated_power='auto', n_oversamples=10, power_iteration_normalizer='auto', random_state=None)
```

- Koristi SVD dekompoziciju kako bi pronašla smjerove projekcije
- Podaci se automatski centriraju prije primjene SVD
- Najvažniji parametar je `n_components` – koliko da se komponenti zadrži; ako je `None`, onda se zadržavaju sve komponente prema:
 - `n_components = min(n_samples, n_features)`

PCA u scikit-learn biblioteci

- Najvažniji atributi su:
 - **components_** - komponente (sortirane prema objašnjenoj varijanci)
 - **explained_variance_** - količina varijance objašnjene svakom od odabranih komponenti
 - **explained_variance_ratio_** - postotak objašnjene varijance od svake odabrane komponente
 - **singular_values_** - singularne vrijednosti koje odgovaraju odabranim komponentama
 - **mean_** - srednja vrijednost svake značajke (procjena na temelju skupa za učenje)
 - **n_components_** - broj komponentata
 - **n_features_** - broj značajki u skupu za učenje
 - **n_samples_** - broj primjera u skupu za učenje

PCA u scikit-learn biblioteci

- Najvažnije metode su:
 - `fit(X[, y])` – procijeni model na temelju podataka X
 - `fit_transform(X[, y])` – procijeni model na temelju podataka X i primijeni smanjivanje dimenzionalnosti na X
 - `transform(X)` – primijeni smanjivanje dimenzionalnosti na X
 - `inverse_transform(X)` – transformiraj podatke „nazad” u originalni prostor
- Primjer upotrebe:

```
pca = PCA()  
pca.fit(X)
```

P i t a n j a ?


PCA – Klasifikacija vozila koristeći PCA

- Motivirano uspjehom korištenja *Eigenfaces* analize u problemu detekcije lica
- Ponovimo...
 - *Eignefaces* su skup *eigenvektora* izvedenih iz matrice kovarijance visokodimenzijskog vektorskog prostora ljudskih lica iz baze podataka ljudskih lica
 - Ti *eigenvektori* se koriste u računalnom vidu za prepoznavanje ljudskih lica
 - *Eigenfaces* su invarijantne karakteristike ljudskog lica za danu bazu podataka
 - Za generiranje *Eigenfaces* koristio se mehanizam zvan PCA
- Sličnost između prepoznavanja lica i klasifikacije vozila
 - Oba problema analiziraju 2D objekt slike i pokušavaju pronaći invarijantne značajke objekata slike unutar iste klase (npr. prepoznati lice iste osobe, identificirati vozilo iste klase,...)

PCA – Klasifikacija vozila koristeći PCA



- *Eigenvehicles* umjesto *Eignfaces* za klasifikaciju vozila → Zašto ne?
- Na raspolaganju trening skup podataka 2D objekata vozila iste klase dobiven izdvajanjem okvira iz videa nadzornog sustava prometa
- Generiranje *Eigenvehicles* (postupak kao za *Eigenfaces*) – skup *eigenvektora* za pojedinu klasu automobila

PCA – Klasifikacija vozila koristeći PCA



Trening
uzorci za
putnički
automobil


„Srednji
putnički
automobil“



6 najvažnijih
Eigenvehicles
za tip „putnički
auto“

PCA – Klasifikacija vozila koristeći PCA

- Eksperiment



Ostale metode smanjivanja dimenzionalnosti

- Multidimensional scaling
- Factor Analysis
- Linear Discriminant Analysis
- Isomap
- Locally linear embedding
- Laplacian Eigenmaps

P i t a n j a ?