

Konvolucijske neuronske mreže



Sadržaj

- Podsjetimo se...
 - Tradicionalni računalni vid vs. Duboko učenje
 - Duboke neuronske mreže
- **Konvolucijske neuronske mreže**

Podsjetimo se...

**Tradicionalni računalni vid *vs.*
Duboko učenje**

Duboko učenje u praksi



- Duboko učenje koristi se u rješavanju mnogih problema:
 - Obrada slike i računalni vid (detekcija objekata, oduzimanje pozadine, bojanje slika, ...)
- Generiranje opisa videa (engl. *video description generation*)
- Prepoznavanje akcije i aktivnosti (engl. *action and activity recognition*), procjena poze kod ljudi (engl. *human pose estimation*)
- Robotika
- AI u računalnim igrama
- Obrada prirodnog jezika
- Posebno kod autonomne vožnje:
 - Detekcija objekata
 - Segmentacija scene
 - Upravljanje vozilom
 - Praćenje stanja vozača
 - ...



[Izvor](#)

Tradicionalni računalni vid i duboko učenje


- „Tradicionalni“ računalni vid zasniva se na ručnom izdvajanju značajki te učenju klasifikatora na temelju podataka
- Moderni pristup zasniva se na „*end-to-end learning*“ – značajke se također „uče“ iz dostupnih podataka



Podsjetimo se...

Duboke neuronske mreže

Višeslojne NN, Duboke NN (DNN)




Neuronska mreža s 2 sloja

Mreža s 1 skrivenim slojem

- Skriveni sloj → nije izravno izložen ulazu
- Ovo je plitka mreža – ima samo jedan skriveni sloj
- Osnovna komplikacija → dodavati sve više skrivenih slojeva (ali to je ujedno i više procesiranja)

Višeslojne NN, Duboke NN (DNN)




Neuronska mreža s 3 sloja

Mreža s 2 skrivena sloja

- Dodali smo 1 skriveni sloj → duboka mreža
- Zašto dodavati dodatne slojeve?
 - Da bi oponašali sve složenije funkcije koje trebaju točno i precizno raditi?
- Raste broj koeficijenata w_{ij} → gradijentnom metodom naći najbolje koeficijente za dani problem

Višeslojne NN, Duboke NN (DNN)




Neuronska mreža s 3 sloja

Mreža s 2 skrivena sloja

- I ovdje se obično kreće sa sasvim slučajnim odabirom početnih parametara w_{ij}
- Dodavanjem broja slojeva i funkcija je sve moćnija i moćnija
- Kako još možemo povećati kompleksnost, a time i sposobnost ANN, osim dodavanja slojeva?
 - Povećavanjem broja neurona u sloju
- Broj slojeva i neurona po sloju → određuju kapacitet mreže (modela)
- DNN → imaju više od jednog skrivenog sloja

Unaprijedne NN



Neuronska mreža s 3 sloja

Mreža s 2 skrivena sloja

- Najčešće se koriste višeslojne unaprijedne neuronske mreže
- Unaprijedne neuronske mreže su mreže u kojima se propagacija signala odvija samo u jednom smjeru, od ulaznih veličina prema izlaznoj veličina, što znači da mreža ne sadrži povratne veze

Podsjetnik...višeklasna klasifikacija

- Primjer: klasifikacija objekata detektiranih prednjom kamerom na vozilu



C₁-auto



C₂-kamion



C₃-znak

...

...




C₉-pješak



C₁₀-semafor


...

...



Duboke neuronske mreže – kompozicija funkcija

- Cilj DNN je aproksimirati funkciju $y = f(x, W)$
- Kroz proces učenja određuju se najbolji parametri W da se dobije najbolja aproksimacija $f^*(x, W)$
- Ta je funkcija zapravo kompozicija mnogo različitih funkcija (tj. slojeva)



$$y \sim f^*(x, \theta) = f^{(4)}(f^{(3)}(f^{(2)}(f^{(1)}(x))))$$

Univerzalnost neuronskih mreža


- Unaprijedne NN sa samo jednim slojem sposobne su dovoljno dobro implementirati bilo koju funkciju !!!
 - Ali moraju često sadržavati jako velik broj neurona u tom jedinom sloju
 - **UNIVERZALNO rješenje** za realizaciju bilo koje funkcije (linearne operacije + nelinearna aktivacijska funkcija)
 - Nelinearna aktivacijska funkcija smanjuje ograničenja nametnuta isključivo linearnim operacijama
- Umjesto jednog sloja s mnoštvom neurona → učinkovitije je koristiti više slojeva s manje neurona (dublje mreže) → manji je ukupni broj potrebnih neurona i operacija
- Pitanje – koji je smisao korištenja više neurona po sloju kad u sve njih ulaze isti ulazi?

P i t a n j a ?

Konvolucijske neuronske mreže


Hubel & Wiesel 1959.

- I kasniji rad (1962. i 1968.)



[Izvor](#)


- Neuronu u vizualnom korteksu reagiraju samo u malom području vizualnog polja (receptivno polje)
- Receptivno polje i lokacija se sistematski mijenjaju kroz korteks kako bi se stvorila mapa vizualnog prostora



Dva osnovna tipa stanica: *simple cells* and *complex cells*


Prvo pojavljivanje konvolucijske neuronske mreže

- Znanstveni rad: LeCun, Bottou, Bengio, Haffner. Gradient-based learning applied to document recognition, 1998.
- Predložena mreža naziva LeNet-5
- Konvolucijska neuronska mreža koja je naučena pomoću *backpropagation* algoritma; prepoznavanje rukom pisanih brojeva
- Inspiracija je otkriće lokalno osjetljivih i orijentacijski osjetljivih neurona kod vizualnog sustava mačke (Hubel and Wiesel) i NeoCognitron (Fukushima)
- Dugo vremena ovakva mreža nije korištena za složenije i veće slike već je korišten „klasični računalni vid”



Značajniji rezultat

- Abdel-rahman Mohamed, George Dahl, Geoffrey Hinton. Acoustic Modeling using Deep Belief Networks, 2010.
- George Dahl, Dong Yu, Li Deng, Alex Acero . Context-Dependent Pre-trained Deep Neural Networks for Large Vocabulary Speech Recognition, 2012.
- Alex Krizhevsky, Ilya Sutskever, Geoffrey E Hinton. Imagenet classification with deep convolutional neural networks, 2012.



IMAGENET




„We trained the network for roughly 90 cycles through the training set of 1.2 million images, which took five to six days on two NVIDIA GTX 580 3GB GPUs”

Konvolucijske neuronske mreže


- Konvolucijska neuronska mreža (CNN) sastoji se od niza slojeva (konvolucijski slojevi, *pooling* slojevi, potpuno povezani slojevi)
- Broj parametara ovisi o strukturi CNN (uobičajeno ~10M)
- Zanimljivo, prisutne su samo dvije matematičke operacije:
 - Skalarni produkt
 - Max funkcija
- **Efikasno posloženi slojevi** → uzimaju u obzir da je ulazni podatak **SLIKA**; neuroni su posloženi u tri dimenzije (*širina-width*, *visina-height*, *dubina-depth*)

Konvolucijske neuronske mreže

- Efikasno posloženi slojevi → uzimaju u obzir da je ulazni podatak slika; neuroni su posloženi u tri dimenzije (**širina-width**, **visina-height**, **dubina-depth**)



Klasična troslojna neuronska mreža



Konvolucijska neuronska mreža

Podsjetimo se... prostorno filtriranje slike (2D konvolucija)


a	b	c
d	e	f
g	h	i

P _{0,0}	P _{1,0}	P _{2,0}	P _{3,0}	P _{4,0}					
P _{0,1}	P _{1,1}	P _{2,1}	P _{3,1}	P _{4,1}					
P _{0,2}	P _{1,2}	P _{2,2}	P _{3,2}	P _{4,2}					
P _{0,3}	P _{1,3}	P _{2,3}	P _{3,3}	P _{4,3}					

$$P_{2,1}' = a * P_{1,0} + b * P_{2,0} + c * P_{3,0} + d * P_{1,1} + e * P_{2,1} + f * P_{3,1} + g * P_{1,2} + h * P_{2,2} + i * P_{3,2}$$




2D konvolucija

2D operacija



Primjeri poznatih kernela

Operation	Kernel	Image result
Identity	$\begin{bmatrix} 0 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}$	
Edge detection	$\begin{bmatrix} 1 & 0 & -1 \\ 0 & 0 & 0 \\ -1 & 0 & 1 \end{bmatrix}$	
	$\begin{bmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{bmatrix}$	
	$\begin{bmatrix} -1 & -1 & -1 \\ -1 & 8 & -1 \\ -1 & -1 & -1 \end{bmatrix}$	
Sharpen	$\begin{bmatrix} 0 & -1 & 0 \\ -1 & 5 & -1 \\ 0 & -1 & 0 \end{bmatrix}$	


Box blur (normalized)	$\frac{1}{9} \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}$	
Gaussian blur 3 × 3 (approximation)	$\frac{1}{16} \begin{bmatrix} 1 & 2 & 1 \\ 2 & 4 & 2 \\ 1 & 2 & 1 \end{bmatrix}$	
Gaussian blur 5 × 5 (approximation)	$\frac{1}{256} \begin{bmatrix} 1 & 4 & 6 & 4 & 1 \\ 4 & 16 & 24 & 16 & 4 \\ 6 & 24 & 36 & 24 & 6 \\ 4 & 16 & 24 & 16 & 4 \\ 1 & 4 & 6 & 4 & 1 \end{bmatrix}$	
Unsharp masking 5 × 5 Based on Gaussian blur with amount as 1 and threshold as 0 (with no image mask)	$\frac{-1}{256} \begin{bmatrix} 1 & 4 & 6 & 4 & 1 \\ 4 & 16 & 24 & 16 & 4 \\ 6 & 24 & -476 & 24 & 6 \\ 4 & 16 & 24 & 16 & 4 \\ 1 & 4 & 6 & 4 & 1 \end{bmatrix}$	

Konvolucijske neuronske mreže, motivacija...

- Obrada slike i računalni vid imaju mnogo “*handcrafted filters*”
 - Canny, Sobel, Gaussian blur, *moving average*, morfološki filtri, ...
- Postavlja se pitanje jesu li ovi filtri optimalni za dani problem klasifikacije?
- Mogu li se naučiti optimalni filtri iz dostupnih podataka?
- Naime, objekti se mogu pojaviti na različitim mjestima, pod različitim kutem i sl.
- Ako su slike 2D, parametri filtra također trebaju biti organizirani u 2D
 - Na taj način mogu se naučiti lokalne sličnosti (korelacije) između ulaznih veličina (piksela)
 - Moguće je iskoristiti prostornu prirodu slike


Konvolucijske neuronske mreže, motivacija...

- Ako su slike 2D, parametri filtra također trebaju biti organizirani u 2D
 - Na taj način mogu se naučiti lokalne sličnosti (korelacije) između ulaznih veličina (piksela)
 - Moguće je iskoristiti prostornu prirodu slike
- Pretpostavka: različite statistike nisu ovisne o položaju na slici (slike su stacionarne)
 - Isti filter bi trebao raditi jednako na svakom dijelu slike




Konvolucijske neuronske mreže

- Primjer arhitekture konvolucijske neuronske mreže i procesa inferencije




Konvolucijske neuronske mreže

- Konvolucijska neuronska mreža sastoji se od niza slojeva (konvolucijski slojevi, pooling slojevi, potpuno povezani slojevi)
- Broj parametara ovisi o strukturi (uobičajeno ~10M)
- Zanimljivo, prisutne su samo dvije matematičke operacije:
 - Skalarni produkt
 - Max funkcija
- Efikasno posloženi slojevi → uzimaju u obzir da je ulazni podatak slika; neuroni su posloženi u tri dimenzije (width, height, depth)



Klasična troslojna neuronska mreža




Konvolucijska neuronska mreža

Konvolucijski sloj

- Osnova konvolucijskih neuronskih mreža je konvolucijski sloj
- Primjenom konvolucijskog sloja zadržava se prostorna struktura ulaznih podataka
- Svaki neuron povezan je samo s malim područjem u ulaznoj slici (receptivno polje) ili s malim područjem u prethodnom sloju mreže

32x32x3 slika




5x5x3 filter



Konvolucija - "pomicanje po slici i računanje skalarnog produkta"


Konvolucijski sloj

- Primjena filtra na određenom dijelu slike rezultira u skalarnoj vrijednosti (skalarni produkt dijela slike i filtra)
- Filtar pokriva malo prostorno područje, **ali se prostire preko sva tri kanala ulazne slike**
- Težine (w) filtra i *bias* (b) mogu se podešavati (**to su parametri mreže; mijenjaju se tijekom učenja**)



Aktivacijska mapa


- Primjenom istog filtra na različitim pozicijama dobiva se **aktivacijska mapa** → dvodimenzionalna matrica koja sadrži odziv filtra na pojedinom dijelu ulazne slike
- Svi neuroni jedne aktivacijske mape imaju zajedničke parametre (znatno manje parametara nego kod potpuno povezanog (FC) sloja)



- Zašto je aktivacijska mapa dimenzija 28x28x1?
 - Zašto 28x28?
 - Zašto na kraju samo ...x1?
- Kojih bi dimenzija bila aktivacijska mapa da je filter bio 7x7x3?
 - 26x26x1

Aktivacijska mapa


- Svi neuroni jedne aktivacijske mape imaju zajedničke parametre (znatno manje parametara nego kod potpuno povezanog (FC) sloja)
- Moguće je primijeniti više filtera → npr. 6 filtera → dobivaju se zasebne aktivacijske mape koje se „slažu“ jedna pored druge (dobivamo drugačiju reprezentaciju ulazne slike, tzv. **volumen 28x28x6**)




U slučaju potpuno povezanog sloja broj parametara bio bi jednak: $32*32*3*28*28*6 = 14450688$ (14.5M)

Sad je možda jasnija sljedeća slika...

- Nakon prvog konvolucijskog sloja s prethodnog slajda, zapravo se nalazimo u „plavom volumenu” dimenzija 28x28x6




Klasična troslojna neuronska mreža




Konvolucijska neuronska mreža

Konvolucijska neuronska mreža

- CNN se zasniva na sekvenci takvih konvolucijskih slojeva između kojih se nalaze aktivacijske funkcije (najčešće **ReLU**)
- Svaki neuron povezan je s lokalnim područjem ulaznog volumena (prostorni opseg se često naziva receptivno polje, a odgovara veličini filtra)



Konvolucijska neuronska mreža



- Vidimo da se širina i visina volumena iz jednog konvolucijskog sloja u drugi smanjuju
 - Zašto se smanjuju?
 - Koja je mana smanjivanja širine i visine volumena?
 - Kako možemo održati širinu i visinu konstantnima?
 - Koje vrste *paddinga* poznajete?

Zero padding

- Obično se dodaje rub koji sadrži nule → na taj način se primjenom konvolucijskih slojeva ne gubi na prostornoj veličini

Zero pad the border

0	0	0	0	0	0	0	0
0							0
0							0
0							0
0							0
0							0
0							0
0	0	0	0	0	0	0	0


U praksi:

$F = 3$ i *zero pad* jednak 1

$F = 5$ i *zero pad* jednak 2


$F = 7$ i *zero pad* jednak 3

Podsjetnik: sekvencijalnom se primjenom konvolucijskih filtara mijenjaju (smanjuju) prostorne dimenzije slike



Što se postiže sekvencom konvolucijskih slojeva?


- Znanstveni rad: *M. D. Zeiler, R. Fergus Visualizing and Understanding Convolutional Networks, 2013.*
- Za vizualizaciju pojedinog sloja koristi se dekonvolucijska mreža
- Konvolucijska mreža koja je analizirana u radu vrlo je slična poznatoj AlexNet, naučena na ImageNet skupu podataka



Što se postiže sekvencom konvolucijskih slojeva?


- **Značajke**

- Prije šireg prihvaćanja CNN, početna faza većine zadataka prepoznavanja uzoraka bila je ručno izdvajanje značajki poznatim metodama, a nakon toga se primjenjivao klasifikator
- CNN → značajke se uče automatski iz trening uzoraka



Konvolucijski sloj u detalje...STRIDE

- **STRIDE** → definira za koliko se filter pomiče po aktivacijskoj mapi u svakom koraku




Filtar 2x2

Stride 1

Koje su dimenzije rezultatne aktivacijske mape?

- 5x5



Filtar 2x2


Stride 2

Koje su dimenzije rezultatne aktivacijske mape?

- 3x3

Konvolucijski sloj u detalje...STRIDE

- Uobičajeno je veličina filtera jednaka po obje koordinate i iznosi F (tj. $F \times F$)
- Uz pretpostavku da ulazni volumen dimenzije $N \times N$, veličina izlazne mape jednaka je
$$(N-F)/\text{stride} + 1$$
- Ograničen broj kombinacija (*stride*, veličina filtra i veličina ulazne slike) jer veličina izlazne mape mora biti cijeli broj



Veličina izlaza
 $(N - F) / \text{stride} + 1$

npr. $N = 7, F = 3$:


stride 1 $\Rightarrow (7 - 3)/1 + 1 = 5$

stride 2 $\Rightarrow (7 - 3)/2 + 1 = 3$

stride 3 $\Rightarrow (7 - 3)/3 + 1 = 2.33$

Sloj sažimanja (*pooling layer*)


- Kako bi se reprezentacija slike držala što manjom, uvode se slojevi sažimanja (engl. *pooling layers*)
- Ovo je operator koji se primjenjuje na svaku aktivacijsku mapu zasebno
- Praktički, ovime se provodi ***downsampling*** (smanjivanje rezolucije) svake pojedine aktivacijske mape



- Sažimanje (*pooling*) → više se vrijednosti u aktivacijskom mapi zamjenjuje jednom vrijednošću – smanjivanje detaljnosti u toj mapi

Sloj sažimanja (*pooling layer*)

- Sloj sažimanja uzima predefiniranu veličinu podmatrice i koristi jednu od operacija kako bi sažeo podatke
- Najčešći oblik sloja sažimanja je **po maksimalnoj vrijednosti** (engl. *max pooling layer*)
- Ovaj sloj nema parametre koji se određuju postupkom učenja



Prikaz operacije sažimanja s veličinom podmatrice 2×2 i pomakom 2


Softmax sloj

- Sjećamo li se što je **softmax** sloj? Koja je njegova funkcija?
- Softmax sloj zapravo je potpuno povezani sloj sa softmax aktivacijskom funkcijom
- Softmax sloj koristi se kao izlazni sloj kod mreže kojoj je namjena višeklasna klasifikacija

Višeklasna klasifikacija pomoću neuronske mreže i softmax funkcije

- Npr. mreža s tri izlazna neurona (K=3):

$$\sigma(z)_j = \frac{e^{z_j}}{\sum_{k=1}^K e^{z_k}}$$
$$\begin{bmatrix} 1.2 \\ 0.9 \\ 0.4 \end{bmatrix} \xrightarrow{\text{Softmax}} \begin{bmatrix} 0.46 \\ 0.34 \\ 0.20 \end{bmatrix}$$





Softmax sloj

- Broj izlaznih neurona neke mreže koja obavlja višeklasnu klasifikaciju, tj. broj neurona softmax sloja, jednak je broju klasa iz skupa podataka na kojemu se mreža uči
- Softmax sloj kao izlazni sloj neke mreže određuje vjerojatnosti da objekt koji se klasificira pripada pojedinoj klasi, a ukupan zbroj vjerojatnosti uvijek je jednak jedan

Višeklasna klasifikacija pomoću neuronske mreže i softmax funkcije


- Npr. mreža s tri izlazna neurona (K=3):

$$\sigma(z)_j = \frac{e^{z_j}}{\sum_{k=1}^K e^{z_k}}$$



Što se postiže sekvencom konvolucijskih i pooling slojeva?

- Primjer arhitekture konvolucijske neuronske mreže i procesa inferencije



Što se postiže sekvencom konvolucijskih i pooling slojeva?

- **Konvolucijski sloj**: korištenje kopija istog detektora (filtra) na različitim pozicijama te korištenje više filtara
 - Svaki komad slike predstavlja se na nekoliko načina
 - Replikacijom filtra znatno se smanjuje broj parametara
 - Ako je neka značajka (*feature*) korisna na jednoj lokaciji tijekom treniranja, detektori za tu značajku trebaju biti dostupni na svakoj lokaciji tijekom testiranja
 - Sa slojevima se povećava receptivno polje → doprinosi translacijskoj invarijantnosti
- **Sloj sažimanja**
 - Dobivanje male invarijantnosti s obzirom na translaciju
 - Smanjivanje ulaza za sljedeći sloj pa se može koristiti veći broj različitih mapa

Što se postiže sekvencom konvolucijskih i pooling slojeva?

- [Eric Kauderer-Abrams, Quantifying Translation-Invariance in Convolutional Neural Network, 2017.](#)

- *We obtain the surprising result that architectural choices **such as the number of pooling layers and the convolution filter size** have only a secondary effect on the translation invariance of a network. Our analysis identifies training data augmentation as the most important factor in obtaining translation-invariant representations of images using convolutional neural networks.*

[Korisno za pročitati](#)

*In all cases, pooling helps to make the representation approximately invariant to **small** translations of the input. Invariance to translation means that if we translate the input by a small amount, the values of most of the pooled outputs do not change—Deep Learning book*


*„Convolution is **not naturally** equivariant to some other transformations, **such as changes in the scale or rotation of an image.**” —Deep Learning book*

Ovo treba naučiti iz podataka (augmentacija)




Što se postiže sekvencom konvolucijskih i pooling slojeva?

- Primjer učenja rotacijske invarijantnosti...
- Pooling jedinica koja je namijenjena za učenje značajki s odvojenim parametrima može naučiti biti invarijantna na transformacije ulaza
- Pokazujemo kako skup od tri naučena filtra i max pool sažimanje mogu naučiti postati invarijantni na rotaciju
- Sva 3 filtra su namijenjena da detektiraju rukom napisanu brojku 5
- Svaki filter pokušava se uskladiti na malo drugačiju orijentaciju broja 5
- Kada se pojavi broj 5 na ulazu, odgovarajući filter će na izlazu dati najveću aktivaciju u detektorskoj jedinici
- Max pooling jedinica će tada imati veliku aktivaciju neovisno o tome koja je detektorska jedinica aktivirana




Ista ili slična arhitektura – različite primjene



- Ovaj dio se razlikuje ovisno o primjeni:
 - Različite domene detekcije objekata
 - Opis slike s rekurentnim neuronskim mrežama
 - Lokalizacija objekata na slici s rekurentnim neuronskim mrežama
 - Segmentacije slike s konvolucijskim mrežama
 - Segmentacija scene s dekonvolucijskim slojevima

Vizualizacija CNN

- Dugo vremena neuronske mreže su se smatrale potpun crnom kutijom – teško za razumijeti kako funkcioniraju zbog velikog broja međusobno povezanih dijelova (s nelinearnim funkcijama)
- Razumijevanje je posebno otežano u slučaju dubokih neuronskih mreža
- Interakcija s dubokom neuronskom mrežom omogućuje nam izgradnju intuicije (“kako mreža radi”) te na taj način možemo izgrađivati bolje mreže
- Omogućuje uvid u svaki neuron mreže (što točno izračunava i na kakav ulaz reagira)
- Sintetizira se ulaz u neuron koji uzrokuje njegovu veliku aktivaciju




[Jason Yosinski et. all. Understanding Neural Networks Through Deep Visualization, 2015.](#)

<http://yosinski.com/deepvis#toolbox>

Nedostatci CNN

- Lako ih je „prevariti”
- *Adversarial example* → „optička iluzija za ML algoritam”
 - Lijeva slika je originalna slika → CNN pravilno klasificira
 - Desna slika je lijeva slika + precizna distorzija → CNN pogrešno klasificira
- I ljudi imaju ovaj problem, ali ne u mjeri koja je prisutna kod CNN





[Izvor: Intriguing properties of neural networks](#)

Nedostatci CNN

- Lako ih je „prevariti”



Nedostatci CNN




Neprijateljski primjeri u autonomnoj vožnji

- Nicolas Papernot, Patrick McDaniel, Ian Goodfellow, Somesh Jha, Z. Berkay Celik, Ananthram Swami. [Practical Black-Box Attacks against Machine Learning](#), 2017.
 - Višeklasni Deep Neural Network (DNN) klasifikator
 - „Fizički neprijateljski prometni znakovi mogli bi se generirati zlonamjernim modifikacijama samog znaka, npr. naljepnicama ili bojanjem”



Kompresija i ubrzanje neuronskih mreža

- Smanjivanje memorijskih i računalnih zahtjeva (pa i energetske potrošnje) CNN se posebno razmatra kod *real-time* aplikacija i primjene na *embedded* uređajima s ograničenim memorijskim i računalnim resursima (npr. mobitelima)
- Npr. *residual network-50* (ResNet-50) ima 50 konvolucijskih slojeva i zahtjeva 95 MB za pohranu
- Nekoliko je načina kako smanjiti memorijske i računalne zahtjeve CNN, s prihvatljivim gubitkom na preciznosti klasifikacije
- Tipični primjeri:
 - Kvantizacija parametara/težina (*weight quantization*)
 - Dijeljenje težina (*weight sharing*)
 - Srezivanje veza (*connection pruning*)
 - Transfer znanja (*knowledge transfer*)
 - ...



P i t a n j a ?