

ML vs Neural Networks

Kada, zašto i kako birati pravi pristup u praksi

Igor Buzov, dipl. inf., viši predavač

Centar umjetne inteligencije Lipik

Što danas želimo postići

- Razumjeti razliku ML vs NN u praksi
- Naučiti kako birati pravi pristup
- Ponoviti ključne ML i NN koncepte
- Pripremiti teren za NLP

Fokus: business razmišljanje, ne matematika

Brzi check-in

- *Na skali 1–5, koliko vam je danas “mentalna baterija puna”? Već se skoro godinu dana družimo.*
- 1 = totalni burnout
5 = spreman za AI
- *dajte broj u chat*

Što danas ne radimo?

- ✓ Ne učimo nove formule
- ✓ Ne treniramo modele
- ✓ Ne ulazimo duboko u matematiku
- ✓ Ne radimo “state-of-the-art”

- ❖ Razmišljamo kao stručnjaci
- ❖ Rješavamo stvarne probleme

Zašto je ovo bitno u stvarnom poslu?

- Vrijeme i budžet su ograničeni
- Nisu svi problemi za neural network
- Overengineering = skupo i rizično
- Morate znati razgovarati s timovima i vendorima
- Najbolji model $\neq$ najkompliciraniji model

Kako izgleda dobar AI proces





ML vs Neural Networks

ML

- Manje podataka
- Strukturirani podaci
- Brzo, jednostavno
- **Interpretabilno**


NN

- Puno podataka
- Kompleksni odnosi
- Skuplje i sporije
- **Teže za objasniti**




Više podataka $\neq$ automatski bolji rezultat

- ML modeli brzo dođu do plafona
- NN nastavljaju rasti s više podataka
- Zadnjih 10% točnosti je najskuplje
- (*diminishing returns*)




Stvarni svijet ima ograničenja

- Vrijeme (rokovi)
- Ljudi (veličina tima)
- Budžet
- Infrastruktura
- Održavanje modela



Moramo znati objasniti odluku

- Business пита: *Zašto?*
 - Regulator пита: *Kako?*
 - NN često nema jasan odgovor
-
- **Ponekad je “lošiji” model bolji izbor**



Garbage in → Garbage out

- Duplikati
- Nedostajuće vrijednosti
- Pogrešni zapisi
- Outlieri
- Data leakage
- Pogrešna distribucija
- LOŠI PODACI koji daju bias



EDA utječe na izbor modela

- Malo podataka → NN postaje rizičan
- Neravnomjerna klasa → treba balansiranje
- Outlieri → utjecaj na linearne modele
- Multikolinearnost → problem za neke modele

Model koji je predobar - Predikcija churn-a (odlaska korisnika)

- 50.000 redaka podataka
 - 30 featurea
 - cilj: predvidjeti hoće li korisnik otići
 - train/test split: 80/20
-
- Model (Random Forest) daje:
 - Accuracy: 94%

Data twist – niste
pravilno očistili
podatke

- Postoji varijabla days_since_cancellation

user	churn	days_since_cancellation
A	0	0
B	0	0
C	1	12
D	1	4

Model koji je predobar – klasifikacija slika

- Vuk vs pas
- 15.000 slika vukova
- 15.000 slika pasa
- koristi se CNN
- trenira se nekoliko sati
- test accuracy: 96%

Data twist – na slikama su psi i vukovi u svom prirodnom okruženju



Case: mali tim, malo podataka


- 2 osobe
 - 7 dana
 - 5000 redaka tabličnih podataka, tjedno
 - cilj: predikcija
-
- **Pitanje: ML ili NN?**

Što su svi ML modeli koje ste učili zapravo radili?

- Linear Regression
- Decision Tree
- Random Forest
- XGBoost
- Logistic Regression

SVI ML MODELI UČE $f(x)$

- ML model = uči funkciju
- $f(x) \rightarrow y$
- Razlika je u obliku funkcije:
 - Linearna
 - Piecewise (tree)
 - Ansambl funkcija
- Ali uvijek u istom feature prostoru.



FEATURE PROSTOR JE SVE

- Kvaliteta modela ovisi o:
- Kvaliteti značajki
 - Skaliranju
 - Redukciji dimenzionalnosti
 - Uklanjanju šuma
- Zato smo radili:
 - PCA
 - Feature selection

GDJE ML POČINJE PUCATI?

- Što ako:
 - Ne znamo koje su dobre značajke?
 - Feature engineering je preskup?
 - Dimenzionalnost je ogromna?
 - Struktura podataka je hijerarhijska?
- Primjeri:
 - Slike
 - Tekst
 - Audio

NEURAL NETWORK KAO DRUGA STRATEGIJA

- Neural Network =
- Višeslojna transformacija + nelinearnost
- Svaki sloj stvara novi prostor podataka.
- To se zove:
- Representation learning

Sažetak

- ML → treba dobre značajke
NN → pokušava naučiti značajke
- Oba su alati.
Različite strategije za složenost.

Sada ste vi data science tim



Case A: Mala firma, brz rezultat

- 10 000 redaka podataka
 - tablični podaci (numerički + kategorijski)
 - cilj: predvidjeti mjesečni prihod
 - tim: 2 osobe
 - rok: 5 radnih dana
 - nema GPU-a
 - business želi “razumjeti što utječe na prihod”
-
- Koji pristup i zašto?

Case B: Kreditni scoring

- 5 milijuna zapisa
 - tablični podaci
 - cilj: hoće li klijent vratiti kredit
 - regulatorni zahtjevi
 - odluke imaju pravne posljedice
 - business traži objašnjenja
-
- ML ili NN?

Case C: Velika e-commerce platforma

- 20 milijuna zapisa
 - puno featurea
 - kompleksni odnosi
 - cilj: predvidjeti hoće li korisnik kupiti
 - tim: 10 ljudi
 - rok: 3 mjeseca
 - interpretabilnost “nice to have”
-
- ML ili NN?

Case D: OPERATIVNI FORECAST

Kontekst

- firma ima 3 godine povijesnih podataka
- 40.000 redaka
- tablični podaci (prodaja, cijena, sezonalnost, promocije)
- cilj: predvidjeti tjednu prodaju po lokaciji

Ograničenja

- model ide u produkciju za 2 tjedna
- mora se objašnjavati businessu
- model se retrainira svaki tjedan
- tim: 1 DS + 1 data analyst

Dodatni twist

- business želi znati *koje varijable najviše utječu*
- ali i traži “što veću točnost jer se planira logistika”
- **Koji pristup birate i ZAŠTO?**
Što žrtvujete svojom odlukom?

Case E: SCALE I KOMPLEKSNOST

Kontekst

- stotine milijuna zapisa
- kompleksni, nelinearni odnosi
- performance = konkurentska prednost
- interpretabilnost nije ključna

Ograničenja

- imaš GPU infrastrukturu
- imaš tim koji zna NN
- prihvaćaš veću složenost

Case F: GROWTH VS STABILNOST

Kontekst

- globalna platforma
- 25 milijuna zapisa mjesečno
- cilj: predvidjeti churn korisnika
- odluka se koristi za marketing kampanje

Ograničenja


- model mora raditi u produkciji 24/7
- performance direktno utječe na prihod
- interpretabilnost nije regulatorni zahtjev

• Dodatni twist

- ML model je stabilan, lako se održava
- NN daje bolje rezultate, ali:
 - osjetljiv je na promjene u podacima
 - teško ga je debugirati
- tim ima iskustva s ML-om, ali ne s NN-om

Neuronske mreže – representation learning

- Zamislimo mrežu
- Input – Linear – Linear – Output
- Nema aktivacijskih funkcija
- Je li to i dalje duboka mreža?




Razbijanje iluzije

- $\text{Linear}(\text{Linear}(x)) = \text{Linear}(x)$
- $y = W_2(W_1x + b_1) + b_2$
- $y = W'x + b'$
- Dvije linearne transformacije = jedna linearna transformacija.

Zašto je to problem?

- Linearni model može naučiti samo linearne granice.
- Što ako je problem nelinearan?




Stvaranje novih featura

- Svaki neuron radi:
- $z = W \cdot x + b$
- $a = \text{activation}(z)$
- Taj izlaz a je zapravo nova značajka.
- U sljedećem sloju:
- Mreža radi kombinaciju tih novih značajki i tako gradi hijerarhiju featurea
- To je upravo representation learning na mikro-razini.

Zašto sigmoid funkcija?

Aktivacijske funkcije

Sigmoid function



© Encyclopædia Britannica, Inc.


Zašto je sigmoid funkcija bila povijesno popularna?

- Inspirirana biološkim neuronima (prag aktivacije)
- Sigmoidna funkcija "gnječi" bilo koji broj između 0 i 1
- Za računanje derivacije nije potrebno mnogo računalnih resursa (backpropagation)
- Glatka

Backpropagation i chain rule

- Znate broj svoje noge
- Znate da postoji veza izmedju broja noge i težine
- Unesete svoj broj noge u NN i učite NN da predvidi vašu težinu
- Model pogleda broj noge → pogodi neku težinu → vidi stvarnu težinu → izračuna Error → radi Backpropagation (popravlja w)
- Ovo se ponavlja tisućama puta (epohe)

Cost



Random
initial value

W

W

Learning step

Minimum

- $X^*w + b = 60$

- 70

Problem sigmoidne funkcije

- Backpropagation primjenjuje lančano pravilo deriviranja
 - to je lanac parcijalnih derivacija koji uključuje:
 - derivaciju loss funkcije po izlazu
 - derivaciju aktivacije u svakom sloju
 - derivaciju linearne transformacije
 - i na kraju derivaciju po toj konkretnoj težini
- To je chain rule u punoj formi.
- Gradijent u ranom sloju je umnožak svih lokalnih derivacija kroz koje signal prolazi
 - Rani sloj – podaci bliže ulazu

Formula za update težine

$$w_{new} = w_{old} - \eta \cdot \frac{dL}{dw_{old}}$$

$$\frac{dL}{dw_{early}} = (\text{derivacija loss}) \times (\text{derivacija aktivacije sloja N}) \times (\text{derivacija aktivacije sloja N-1}) \times \dots$$

- Matematički znamo da je rezultat aktivacijske funkcije (sigmoid) uvijek između 0 i 1
- Također znamo i da je derivacija aktivacije sloja uvijek između 0 i 0,25

Update težine

- Pretpostavimo da je derivacija loss-a = 1 (radi jednostavnosti)
- Derivacija aktivacije sloja neka iznosi idealno 0,25
- Koliko iznosi:
 - $1 * 0,25 * 0,25 * 0,25 * 0,25$ (NN s 4 sloja)

$$\frac{dL}{dw_{early}} = (\text{derivacija loss}) \times (\text{derivacija aktivacije sloja N}) \times (\text{derivacija aktivacije sloja N-1}) \times \dots$$

- Koliko iznosi taj rezultat pomnožen s n (0,01)

Formula za update težine

- $W_{\text{new}} = W_{\text{old}} - 0,0000390625$
- Je li došlo zaista do updatea naše težine? I ovo je idealna situacija gdje su derivacije aktivacijskog sloja jako visoki
- Imamo situaciju vanishing gradient problem
- Zato su se počele uvoditi i druge aktivacijske funkcije kao što je ReLu

Evolucija neuronskih mreža

- Plitke mreže + sigmoid
- Problem dubine → ReLU
- Problem slike → CNN
- Problem sekvence → RNN / LSTM
- Problem dugih ovisnosti → Attention
- Skaliranje → Transformer
- Skaliranje + podaci → LLM

I za kraj ...

- Vaš model je kao ulaz dobio sljedeću rečenicu, želite analizirati značenje
- **"Ovaj proizvod je odličan!"**
- Što on zapravo vidi?

Obrada teksta – najteži feature prostor

- Tablični podaci → featurei su jasni
 - Slike → pikseli
 - Tekst → ?
-
- Što je feature u tekstu?

Pitanje iz publike – kako očistiti slike

- Provjera duplikata – izračunati hash i maknuti slike s istim hashom za svaku sliku
- <https://github.com/mattpodolak/duplicate-img-detection>
- Zamućenost – korištenje Sharpness metrika (Laplacian)
- <https://www.geeksforgeeks.org/computer-vision/how-to-check-for-blurry-images-in-your-dataset-using-the-laplacian-method/>
- Loša ekspozicija (pretamno/presvijetlo) – histogrami
- chrome-extension://efaidnbmnnnibpcajpcgglefindmkaj/https://warwick.ac.uk/fac/sci/dcs/events/past/miua2010/proceedings/paper_2.pdf