

Ponavljjanje

Word embeddings – proces pretvaranja teksta u brojke kako bi ih računala mogla razumjeti.

Tehnike:

BoW – Bag of Words

Pretvara tekst u brojke na osnovu učestalosti riječi. Svaka rečenica se pretvara u vektor na temelju broja pojavljivanja riječi iz vocabularya. Ignorira gramatiku i redoslijed riječi, fokusirajući se isključivo na broj riječi u tekstu.

TF-IDF – Term Frequency – Inverse Document Frequency

Također gleda učestalost riječi u tekstu, ali pri tome daje veću važnost riječima koje se rijede pojavljuju u cijelom skupu dokumenata.

Problem kod obje tehnike je što ne hvataju kontekst (značenje). Također, reprezentacija teksta sadrži mnogo nula (sparse reprezentacija), jer se mnoge riječi pojavljuju rijetko ili samo u malom dijelu tekstova.

Word2Vec

Tehnika gdje se na osnovi vocabularya, korištenjem jednostavne neuronske mreže otkrivaju dimension (features) svake riječi te se računa odnos između svake riječi i featurea. Model u stvarnosti uči numeričke reprezentacije riječi (vektore) iz velikog korpusa teksta tako da riječi koje se pojavljuju u sličnom kontekstu imaju slične vektore. Pojedine dimenzije vektora nemaju unaprijed definirano značenje – model sam uči reprezentaciju iz podataka.

Primjer (pojednostavljeno za razumijevanje): vocabulary: king, queen, apple; dimenzije (intuitivno): royal, gender, food. King i queen će imati slične vrijednosti u nekim dimenzijama, dok će apple biti značajno različit. Ovo je pojednostavljeni prikaz – u stvarnosti dimenzije nemaju eksplicitno značenje. Vrijednosti u vektorima mogu biti pozitivne, negativne ili blizu nule.

Relacije između riječi: računskim operacijama tipa king – male + female $\approx$ queen mogu se pronaći riječi koje su najbližnje rezultatu unutar postojećeg vocabularya.

Korištenjem ove tehnike puno bolje se hvataju relacije između riječi i njihovo značenje u odnosu na druge riječi.

Primjena: BoW, TF-IDF i Word2Vec mogu se koristiti za klasifikaciju i clustering, a za summary samo u jednostavnim (extractive) pristupima, ali nisu standard za to.